

## Algorithmique Avancée

Michèle Soria

Michele.Soria@lip6.fr

Master Informatique M1-STL

<http://www-master.ufr-info-p6.jussieu.fr/2012>  
<http://www-master.ufr-info-p6.jussieu.fr/2012/algav>

Année 2012-2013

Transparents de cours – Partie 2


1 / 73

Michèle Soria

Algorithmique Avancée

### Généralités-1

- Compression = Codage + Modélisation (statistique ou dictionnaire)
- Abréger les redondances, réduire la taille
- Motivations : Archivage et Transmission
- *Algorithmes* pour réduire la *place* occupée, sans perdre trop de temps
- Compression conservative (sans perte d'information)
  - fonction de compression réversible (injective)→ compression de textes, de données scientifiques, de code compilé de programmes



3 / 73

Michèle Soria

Algorithmique Avancée

## CHAPITRE 4 : COMPRESSION

### CHAPITRE 4 : Compression Statistique et par Dictionnaire

- Compression - Théorie de l'information
- Compression Statistique
  - Algorithme de Huffman
  - Huffman adaptatif
- Compression par Dictionnaire
  - Méthode de Lempel-Ziv
  - Algorithme de Lempel-Ziv-Welch
- Applications

2 / 73


Michèle Soria

Algorithmique Avancée

### Généralités-2

#### Compression non conservative

- transformation (inversible) des données
- quantification (perte d'information)
- compression conservative



#### Applications : approximation acceptable

- compression de données analogiques (images, son)
- transmission(télécopie), archivage (doubleur de disque)

4 / 73

Michèle Soria

Algorithmique Avancée

## Entropie – Quantité d'information

ASCII 7bits (128 car) – ASCII-étendu 8bits (256 car) :  
 $\lfloor \log_2 n \rfloor$  bits pour coder  $n$  symboles différents.

**Théorie de l'information** :  $S$  source produit  $n$  symboles différents  $a_1, \dots, a_n$  avec probabilité  $p_1, \dots, p_n$ , avec  $\sum p_i = 1$ .

- **Quantité d'information**  $QI$  ou **entropie** du symbole  $a_i$  = Nombre de bits pour coder  $a_i$ . Si  $a_i$  a probabilité  $p_i$ , alors  $QI = \log_2(1/p_i)$  (aléatoires  $\rightarrow QI = \lfloor \log_2 n \rfloor$ )
- **entropie** de  $S$  = valeur moyenne de la quantité d'information des symboles :  $H = -\sum_{i=1}^n p_i \log_2 p_i$ . Entropie max quand tous symboles équiprobables (source aléatoire). Plus entropie grande, plus grande est information transmise.

**Théorèmes de Shannon** : source  $S$  émet messages longueur  $N$ .

- le codage d'un message de longueur  $N$  est toujours  $> HN$ .
- qd  $N \rightarrow \infty$ , il existe un codage dont la longueur  $\rightarrow HN$ .

5/73

Michèle Soria

Algorithmique Avancée

## Compression conservative

$T$  texte sur un alphabet  $A$ , et codage  $C : T \rightarrow C(T)$

- Encodage des répétitions
- Méthodes statistiques –  $C : A \rightarrow \{0, 1\}^*$
- Codage arithmétique –  $C : \text{Texte} \rightarrow \text{Reel}$
- Méthodes avec dictionnaire –  $C : A^* \rightarrow \{0, 1\}^*$

Souvent les progiciels utilisent plusieurs méthodes à la fois.

### Encodage des répétitions

- **Principe** : remplacer suite de  $n$  symboles  $a...a$  par  $a\#n$
- **Algorithmes** : Run Length Encoding (RLE) et variantes
- **formats bitmap** : n&b, BMP(format natif Windows)

7/73

Michèle Soria

Algorithmique Avancée

## Exemple

Source émet 2 symboles  $a$  et  $b$ , avec  $p_a = 0,8$  et  $p_b = 0,2$ .  
Entropie  $H = -(p_a \log p_a + p_b \log p_b) \sim 0,7219$ .

*Comment coder au plus court un message de taille  $N$  ?*

- $a \rightarrow 0$  et  $b \rightarrow 1$  : le code a même taille que le message
  - grouper par 2 :  $aa \rightarrow 0, ab \rightarrow 11, ba \rightarrow 100, bb \rightarrow 101$   
taille moyenne du code 0,75 $N$  :  
 $(1 * 0,64 + 2 * 0,16 + 3 * 0,02 + 3 * 0,16) * N/2$
  - grouper par 3 :  $aaa \rightarrow 0, aab \rightarrow 100, aba \rightarrow 101, baa \rightarrow 110, abb \rightarrow 11100, bab \rightarrow 11101, bba \rightarrow 11110, bbb \rightarrow 11111$   
taille moyenne du code 0,728 $N$  :  
 $(1 * 0,64 + 3 * 3 * 0,128 + 3 * 5 * 0,032 + 1 * 5 * 0,008) * N/3$
- Représentation par arbre digital, décodage de 011011101100011110

**Remarque** : (Source, Probabilités)  $\sim$  (Texte, Fréquences)

$T$  texte de  $N$  lettres sur un alphabet  $A = a_1, \dots, a_n$ .

$f_i$ , fréquence de  $a_i$  dans  $T = \#a_i$  dans  $T/N$ .

6/73

Michèle Soria

Algorithmique Avancée

## Méthodes statistiques

- **Principe** : symboles fréquents codés sur petit nombre de bits
- **Algorithmes** : Shannon–Fano (48), Huffman (50), Huffman dynamique (Gallager 78) : algorithme adaptatif
- **Programmes** : CCITT–fax (H), COMPACT Unix-(HD)

**Codage arithmétique** : le texte est codé par un nombre réel, l'algorithme produit un code pour un texte entier –et non pour un symbole–

Meilleur que les autres en gain de place, mais peu rapide.

8/73

Michèle Soria

Algorithmique Avancée

- **Principe** : code un groupe de symboles par son index dans un dictionnaire – statique ou adaptatif–
- **Algorithmes** : Lempel-Ziv77, Lempel-Ziv78, Lempel-Ziv-Welch
- **Programmes** :
  - **compression de fichiers** COMPRESS Unix+ (LZW)
  - **formats d'image** GIF (graphic interchange format) et TIFF (Tagged image file format)
  - **archivage** LHarc (LZ77+HD)– free, PKZIP , ARC, ARJ – (MS-DOS)

## Compression statistique – Huffman

Symbole fréquent == code court,

Symbole rare == code long

Au mieux : coder un symbole avec le nombre de bits d'information qu'il contient  $\log_2(1/p(i))$ , (mais ici nombre de bits *entier*).

Connaître les fréquences

- Table de probabilité universelle (d'ordre 0, 1, ...)
- Table de probabilité statique pour chaque texte à compresser : meilleure compression mais surcoût (calcul des fréquences + transmission de la table) → Algorithme de Huffman
- Fréquences calculées au fur et à mesure (codage d'un symbole évolue) → Algorithme de Huffman adaptatif  
Adaptativité inversible (fonction de décompression)

- 1 Algorithme de Huffman statique
  - Principes et Définitions
  - Construction de l'arbre de Huffman
  - Optimalité du code
  - Compression : algorithme et complexité
  - Décompression : algorithme et complexité
- 2 Huffman Adaptatif
  - Principes et Définitions
  - Modification de l'arbre de Huffman adaptatif
  - Compresseur et décompresseur

## Code préfixe

Huffman : code préfixe de longueur variable.

Alphabet  $A = \{a_1, \dots, a_n\}$ . Codage  $C : A \rightarrow \{0, 1\}^+$ .

$P$  ensemble de mots de  $\{0, 1\}^+$ , codages des caractères de  $A$ .

**Définition** :  $P$  code préfixe  $\stackrel{Def}{\iff}$  aucun mot de  $P$  n'est préfixe propre d'un mot de  $P : \forall w_1 \in P, w_1 w_2 \in P \rightarrow w_2 = \epsilon$ .

**Proposition** Tout code préfixe est uniquement décodable  
Aucun code d'un caractère n'est préfixe propre d'un code d'un autre caractère :  $C(xy) = C(x)C(y)$ .

**Définition :** *arbre digital (trie)*  $\stackrel{Def}{=}$  arbre binaire t.q. chaque feuille contient le codage de son chemin à partir de la racine (0 pour lien gauche, 1 pour droit).

**Définition :**  $P$  est un code préfixe ssi il est constitué des codes des feuilles d'un arbre digital.

**Définition :** Arbre digital *complet*  $\stackrel{Def}{=}$  Code préfixe *complet*

**Remarques :** Pour tout  $a \in A$ ,  $C(a)$  est un mot sur  $\{0, 1\}^+$ , de longueur  $L(a)$ . Et  $L(a)$  est égal à la profondeur de la feuille codant  $a$  dans l'arbre digital.

Texte  $T \in A^*$ . Codage  $C : T \rightarrow T(C) = T_C$ .

### Définitions

**Fréquence**  $f(a_i) = \#a_i$  dans  $T$ .

**Taille** de  $T(C) : \|T_C\| = \sum f(a_i) |C(a_i)|, a_i \in A$ .

$C$  code minimal pour  $T$  ssi  $\|T_C\| = \min\{\|T_\gamma\|, \gamma : A \rightarrow \{0, 1\}^+\}$

### Proposition

$C$  minimal pour  $T \implies < f(a_{i_1}) \leq f(a_{i_2}) \leq \dots \leq f(a_{i_n})$  et  $|C(a_{i_1})| \geq |C(a_{i_2})| \geq \dots \geq |C(a_{i_n})|$

*Preuve :* s'il existe  $a$  et  $b$  t.q.  $f(a) < f(b)$  et  $C(a) < C(b)$ , alors soit  $C'$  t.q.

$C(x) = C'(x)$  pour tout  $x \neq a, b$ , et  $C'(a) = C(b)$ , et  $C'(b) = C(a)$ .  $\|T_C\| - \|T_{C'}\| =$

$f(a)C(a) + f(b)C(b) - (f(a)C(b) + f(b)C(a)) = (f(a) - f(b)) * (C(a) - C(b)) > 0$

Contradiction avec  $C$  minimal pour  $T$ .

Mais la réciproque n'est pas vraie.

## Construction de l'arbre de Huffman

Exemple :  $T = \text{abracadabra}$ ,

$f(a) = 5, f(b) = 2, f(r) = 2, f(c) = 1, f(d) = 1$

Construction d'un arbre digital

- Peigne par fréquences croissantes,  
ex. 1, 1, 2, 2, 5  $\|T_C\| = 23$
- Utiliser les branchements  
ex. 1, 1, 2, 2, 3  $\|T_C\| = 20$  ( au lieu de 21 pour peigne par fréquences croissantes : ainsi il ne suffit pas de classer par fréquences.)

Principe de construction d'un arbre de Huffman

- Unir 2 sous-arbres de "poids minimal"
- Deux degrés de liberté : choix des 2 sous-arbres + Gauche/Droite

Exemple : plusieurs arbres de Huffman pour le texte

$T = \text{abracadabra}$

## Arbre de Huffman : Algorithme

ENTREE : Fréquences  $(f_1, \dots, f_n)$  des lettres  $(a_i)$  d'un texte  $T$ .

SORTIE : Arbre digital donnant un code préfixe minimal pour  $T$ .

- 1 Créer, pour chaque lettre  $a_i$ , un arbre (réduit à une feuille) qui porte comme poids la fréquence  $f(i)$
- 2 Itérer le processus suivant
  - choisir 2 arbres  $G$  et  $D$  de poids minimum
  - créer un nouvel arbre  $R$ , ayant pour sous-arbre gauche (resp. droit)  $G$  (resp.  $D$ ) et lui affecter comme poids la somme des poids de  $G$  et  $D$ ,
- 3 Arrêter lorsqu'il ne reste plus qu'un seul arbre : c'est un arbre de Huffman (*pas unique*)

## Structuration des données

Création arbre de Huffman contrôlée par une *file de priorité* TAS  
– éléments = arbres,  
– clés = poids attachés aux arbres (fréquences des lettres pour les feuilles et poids cumulés pour les arbres construits).

*Huffman* :  $\text{Alphabet} * \text{Fréquences} \rightarrow \text{ArbreHuffman}$   
**renvoie** l'arbre de Huffman associé ;  $f_i \neq 0$  fréquence de  $a_i$  dans  $T$   
**Fonction** Huffman(A,f1,...,fn)  
    FP=construireTas((f1,a1),...,(fn,an))  
    **Pour** i de 1 à n-1  
        *extraireMinTas rend l'arbre min, et le tas réorganisé*  
        (G,FP1)=extraireMinTas(FP)  
        (D,FP2) =extraireMinTas(FP1)  
        R=ABValué(G,D,f(G)+f(D))  
        FP=ajouterTas(R,FP2)  
    **Fin Pour**  
    **Retourne** extraireMin(FP)  
**Fin Fonction**

17 / 73

Michèle Soria

Algorithmique Avancée

## Complexité de la construction

- ❶ Construire le tas initial : ( $O(n)$ ) (ou  $O(n \log n)$  en ligne)
- ❷ A chaque itération
  - extraire 2 fois l'arbre de poids min et réorganiser le tas :  $O(\log n)$
  - fabriquer un nouvel arbre à partir des 2 précédents :  $O(1)$
  - rajouter ce nouvel arbre au tas :  $O(\log n)$
- ❸  $n - 1$  itérations

La construction de l'arbre de Huffman résultant est donc en  $O(n \log n)$  comparaisons.

Taille du texte compressé :  $\|T_h\| = W(H) = \sum_1^n f(i) \text{prof}_h(i)$

19 / 73

Michèle Soria

Algorithmique Avancée

## Définition récursive de la construction de l'arbre

*Huffman* :  $\text{Alphabet} * \text{Fréquences} \rightarrow \text{ArbreHuffman}$   
**Fonction** Huffman(A,f1,...,fn)  
*construireTas* :  $\text{Alphabet} * \text{Fréquences} \rightarrow \text{TAS}[\text{ArbreHuffman}]$   
    **Retourne** ArbreH(construireTas((f1,a1),...,(fn,an)))  
**Fin Fonction**  
*ArbreH* :  $\text{TAS}[\text{ArbreHuffman}] \rightarrow \text{ArbreHuffman}$   
**Fonction** ArbreH(FP)  
    **Si** FP contient 1 seul arbre **Retourne** cet arbre  
    **Sinon**  
        **Soient** (G, FP1)=extraireMinTas(FP)  
                (D, FP2) =extraireMinTas(FP1)  
        **Retourne**  
        ArbreH(ajouterTas(ABValué(G,D,f(G)+f(D)),FP2))  
    **Fin Si**  
**Fin Fonction**

18 / 73

Michèle Soria

Algorithmique Avancée

## Preuve de l'optimalité du code de Huffman

**Le code préfixe complet d'un arbre de Huffman est minimal i.e. meilleur que celui de tout autre arbre digital de  $A \rightarrow \{0, 1\}^+$**

*Preuve* : Par récurrence sur le nombre  $n$  de lettres de  $A$

– pour  $n = 2$ , chaque lettre codée par 1 bit donc  $\|T_h\| = \#$  caractères de  $T$   
– pour  $n > 2$ , l'algo choisit  $x$  et  $y$  de poids min, construit un nœud  $z$  de poids  $f(z) = f(x) + f(y)$  et applique récursivement la construction à  $\tilde{T}$  sur  $A - \{x, y\} \cup \{z\}$  ( $n - 1$  lettres).

On suppose que l'arbre  $\tilde{H}$  construit pour  $\tilde{T}$  produit un code minimal (hypothèse de récurrence), et on montre qu'il en est de même pour l'arbre  $H$  construit pour  $T$ . Par construction :  $W(H) = W(\tilde{H}) - f(z)p(z) + f(x)p(x) + f(y)p(y) = W(\tilde{H}) + f(x) + f(y)$   
*Démonstration par l'absurde* : on suppose qu'il existe  $H'$  avec  $W(H') < W(H)$ , et l'on montre qu'il existe alors  $\tilde{H}'$  tel que  $W(\tilde{H}') < W(\tilde{H})$ , contradiction avec  $\tilde{H}$  minimal.

– Si  $x$  et  $y$  ont même père ds  $H'$ , alors  $W(H') = W(\tilde{H}') + f(x) + f(y)$ , et

$W(H') < W(H) \Rightarrow W(\tilde{H}') < W(\tilde{H})$ .

– Sinon on construit un arbre  $H''$  où  $x$  et  $y$  ont le même père, avec  $W(H'') < W(H')$ , et on est ramené au cas précédent.

Construction de  $H''$  : soient  $b$  et  $c$  2 feuilles soeurs de  $H'$ , à prof. max., i.e.

$p(b) = p(c) \geq p(f), \forall f$  feuille de  $H'$ .  $H'$  est minimal donc  $f(x) \leq f(b)$  et  $f(y) \leq f(c)$ .

On construit  $H''$  en échangeant ( $x$  et  $b$ ), et ( $y$  et  $c$ ). On a donc finalement

$W(H'') = W(H') - [(f(b) - f(x)) \cdot (p(b) - p(x))] - [(f(c) - f(y)) \cdot (p(c) - p(y))] \leq W(H') \bullet$

20 / 73

Michèle Soria

Algorithmique Avancée

## Algorithme de compression

ENTREE : Texte T

SORTIE : Texte compressé TC et codage de l'arbre de Huffman

- 1 Parcourir T pour compter le nombre d'occurrences de chaque caractère
- 2 Construire l'arbre de Huffman à partir des fréquences des caractères
- 3 Calculer la table des codes à partir de l'arbre de Huffman
- 4 Compresser T en concaténant les codes de chaque caractère  $\rightarrow$  TC
- 5 Coder l'arbre de Huffman de façon compacte

21 / 73

Michèle Soria

Algorithmique Avancée

## Codage de Dyck

Table des codes  $\iff$  Tous les chemins de l'arbre de Huffman

**Mieux** : coder un arbre binaire complet ( $n$  feuilles et  $n - 1$  nœuds internes) un mot de Dyck (Lukasiewicz) de longueur  $2n - 1$ .

**Parcours préfixe**

- nœud interne  $\rightarrow 0$
- feuille  $\rightarrow 1$
- De plus chaque 1 est suivi de  $k$  bits (code initial du caractère)

$() - () - (( ) - ) -$

Exemple : 01a01b001d1c1r

Décodage : reconstruire l'arbre : 0 = nœuds internes et 1 = feuille, et après chaque 1 lire  $k$  bits = code initial d'un caractère

23 / 73

Michèle Soria

Algorithmique Avancée

## Analyse

Texte T :  $N$  caractères sur alphabet de  $n$  lettres,

Codage initial d'un caractère sur  $k$  bits

- 1 Parcours de T :  $O(N)$ . Stockage des fréquences :  $O(n)$ ,
- 2 Construction de l'arbre H en  $O(n \log n)$ ,
- 3 Construction table des codes :  $2n - 1 = O(n)$ . Stockage :  $kn + \sum L_i$  bits,
- 4 Parcours de T :  $O(N)$ . Taille de TC :  $\sum f_i L_i$ ,
- 5 Codage de H : Temps  $O(n)$ . Taille de l'arbre codé  $2n - 1 + kn$  bits.

22 / 73

Michèle Soria

Algorithmique Avancée

## Algorithme de décompression

ENTREE : Texte compressé TC et codage de l'arbre de Huffman

SORTIE : Texte décompressé T

- 1 Reconstruire l'arbre de Huffman ( $O(n)$ )
- 2 Parcourir TC en suivant l'arbre de Huffman ( $O(|TC|)$ )
  - suite de bits : de la racine à une feuille de l'arbre
  - produit un caractère de T
  - et l'on poursuit le parcours de TC en recommençant à la racine de l'arbre

24 / 73

Michèle Soria

Algorithmique Avancée

Inconvénients de la compression de Huffman statique

- double parcours du texte (fréquences + compression)
- mémorisation du codage (arbre de Huffman)

### Version dynamique – adaptative

- l'arbre de Huffman évolue au fur et à mesure de la lecture du texte et du traitement (compression ou décompression) des caractères.
- l'algorithme de compression (*compresseur*) et l'algorithme de décompression (*décompresseur*) modifient l'arbre de la même façon
- à un instant donné du traitement les 2 algorithmes utilisent les mêmes codes – mais ces codes changent au cours du temps.

## Arbre de Huffman adaptatif

**Définition** Numérotation hiérarchique GDBH GaucheDroiteBasHaut

**Définition** Un *arbre de Huffman adaptatif (AHA)* est un arbre de Huffman tel que le parcours hiérarchique GDBH  $((x_1, \dots, x_{2n-1}))$  donne la suite des poids en ordre croissant  $W(x_1) \leq \dots \leq W(x_{2n-1})$

**Propriété P :** Soit  $H$  un AHA et  $\varphi$  une feuille, de numéro hiérarchique  $x_{i_0}$ , dont le chemin à la racine est  $\Gamma_\varphi = x_{i_0}, x_{i_1}, \dots, x_{i_k}$  ( $i_k = 2n - 1$ ). Les noeuds du chemin  $\Gamma_\varphi$  sont dits *incrémentables* ssi  $W(x_{i_j}) < W(x_{i_{j+1}})$ , pour  $0 \leq j \leq k - 1$ .

**N.B.** le sommet  $x_{i_{j+1}}$  se situe après  $x_{i_j}$  dans le parcours GDBH.

**Proposition :** soit  $H$  un AHA,  $\varphi$  une feuille de  $H$  et  $\Gamma_\varphi$  son chemin à la racine. Si  $\Gamma_\varphi$  vérifie la **propriété P**, alors l'arbre résultant de l'incrémentement de  $\varphi$  est encore un AHA.

**Compresseur** Connaît les codes fixes ( $k$  bits) des caractères,

- Initialement, toutes fréquences nulles, et arbre  $H = \#$
- A la lecture de  $x$  dans  $T$ ,
  - si prem. occ., retourne *code# dans  $H$  + code fixe*, et ajoute  $x$  à  $H$
  - sinon retourne *code (variable) de  $x$  dans  $H$*

augmente de 1 la fréquence de  $x$  et modifie éventuellement  $H$

**Décompresseur** Connaît les codes fixes ( $k$  bits) des caractères

- Initialement lit  $k$  bits, et ajoute caractère à arbre "vide" ( $H = \#$ )
- Puis décode les bits du texte compressé sur  $H \rightarrow$  feuille
  - si feuille  $= \#$ , lit les  $k$  bits suivants de  $TC$  et ajoute le  $x$  à  $H$
  - sinon retourne le caractère  $x$  correspondant à la feuille

augmente de 1 la fréquence de  $x$  et modifie éventuellement l'arbre de Huffman de la même manière que le compresseur.

## Principe de modification

**Modification** après lecture d'un caractère de  $T$  correspondant à la feuille  $\varphi$ , de chemin  $\Gamma_\varphi$  à la racine de l'arbre de Huffman

- si  $\Gamma_\varphi$  vérifie **P**, incrémenter les poids sur ce chemin, sans modifier l'arbre,
- sinon transformer l'arbre pour qu'il vérifie **P**, puis incrémenter les poids sur le (nouveau) chemin de  $\varphi$  à la racine.

**Transformation** de l'arbre

- soit  $m$  le premier sommet de  $\Gamma_\varphi$  qui ne vérifie pas **P**, et soit  $f$  tel que  $W(x_m) = W(x_{m+1}), \dots = W(x_f)$  et  $W(x_f) < W(x_{f+1})$  ( $f$  est en fin de bloc de  $m$  : on dispose d'une fonction  $\text{finBloc}(H, m)$  qui renvoie le nœud  $f$ )
- échanger sous-arbres  $A_1$  et  $A_2$  de racines numérotées  $x_m$  et  $x_f$   
N.B. On n'échange jamais un nœud avec un de ses ancêtres
- recommencer le même traitement sur le nouveau chemin de la racine de  $A_1$  à la racine de l'arbre de Huffman



## Algorithme de modification

Feuille spéciale # de fréquence 0, et dont la position varie au cours du temps

*Modification* :  $AHA * Symbole \rightarrow AHA$

**Fonction** *Modification* ( $H, s$ )

```
.  Si  $s$  n'est pas dans  $H$ 
.    Soit  $Q$  le père de la feuille spéciale # dans  $H$ 
.    Remplacer # par un noeud interne de poids 1, dont
.    le fils gauche est la feuille "#"
.    le fils droit est une feuille " $s$ ", de poids 1
.  Sinon
.    Soit  $Q$  la feuille correspondant à  $s$  dans  $H$ 
.    Si  $Q$  est frère de # et  $pere(Q) = finBloc(H, Q)$ ,
.    Alors  $Q = pere(Q)$  Fin Si
.  Fin Si
.  Retourne Traitement( $H, Q$ )
Fin Fonction Modification
```

## Traitement

*Traitement* :  $AHA * noeud \rightarrow AHA$

**Fonction** *Traitement* ( $H, Q$ )

Soit  $Q, Q_{i1}, \dots, Q_{ik} = \Gamma_Q$  le chemin de  $Q$  à la racine

Soit  $x_{i0}, x_{i1}, \dots, x_{ik}$  la suite des numéros des nœuds de  $\Gamma_Q$

Si tous les nœuds de  $\Gamma_Q$  sont incrémentables

ajouter 1 à tous les poids sur le chemin  $\Gamma_Q$

Retourne  $H$

Sinon

Soit  $m$  le premier indice de  $\Gamma_Q$  t.q.  $W(x_m) = W(x_{m+1})$

Soit  $b = finBloc(H, m)$

ajouter 1 à tous les poids du chemin de  $Q$  à  $Q_m$

changer dans  $H$  les sous-arbres enracinés en  $Q_m$  et  $Q_b$

Retourne *Traitement* ( $H, pere(Q_m)$ )

**Fin Fonction** *Traitement*

Complexité  $O(n)$  (hauteur maximale de  $H$ )

## Algorithme de compression

ENTREE : Texte  $T$

SORTIE : Texte compressé  $TC$

- ①  $H$  = feuille spéciale #
- ② soit  $s$  le symbole suivant de  $T$ 
  - Si  $s \in H$ , alors transmettre le code de  $s$  dans  $H$   
Sinon transmettre le code de # dans  $H$  puis le code initial de  $s$
  - Modifier  $H$  :  $H = Modification(H, s)$
- ③ Recommencer l'étape 2 tant que  $T$  n'est pas vide

Complexité  $O(nN)$

Implantation en mini-projet

## Algorithme de décompression

ENTREE : Texte compressé  $TC$  (et connaît codes fixes des caractères)

SORTIE : Texte décompressé  $T$

- ①  $H = \#$ , décoder  $k$  bits  $\rightarrow s$ , et  $H = Modification(H, s)$
- ② Lire les bits de  $TC$  en suivant  $H$  à partir de sa racine  $\rightarrow$  feuille
  - Si c'est la feuille # alors lire les  $k$  bits suivant  $\rightarrow s$   
Sinon  $\rightarrow$  caractère  $s$  de la feuille
  - $H = Modification(H, s)$
- ③ Recommencer l'étape 2 tant que  $TC$  n'est pas vide

Complexité  $O(nN)$

Implantation en mini-projet



## Conclusions Huffman

- Huffman Dynamique ne calcule pas les fréquences
- Huffman Dynamique "à la volée" : décompression peut commencer avant que compression terminée
- Codage Huffman Statique minimal pour  $T_{(f)}$ , mais doit transmettre l'arbre  $\Rightarrow$  augmente taille de l'encodage
- Résultats expérimentaux sur données homogènes : Huffman Dynamique légèrement meilleur que Huffman Statique pour petits fichiers, et bien meilleur pour gros fichiers. (A tester en mini-projet !)

33 / 73

Michèle Soria

Algorithmique Avancée

## Compression avec dictionnaire

**Principe** : groupe de symboles codé par index dans dictionnaire  $C : A^* \rightarrow \{0, 1\}^*$

- 1 Dictionnaire statique  
Dictionnaire de référence, partagé par compresseur et décompresseur
- 2 Dictionnaire adaptatif  
Le dictionnaire est "défini" par le fichier à compresser : apprentissage dynamique des répétitions  
Exemple : Acronymes introduits lors de la première occurrence (CCC)  
Adaptativité inversible (fonction de décompression)  
  
J. Ziv and A. Lempel "A universal algorithm for data compression"  
IEEE Transactions on Information Theory May 1977

35 / 73

Michèle Soria

Algorithmique Avancée

## Compression par Dictionnaires

- 1 Principes de la compression par dictionnaire
- 2 Dictionnaire Statique
- 3 Dictionnaire adaptatif
  - LZ77-LZSS
  - LZW : phase stationnaire et phase adaptative

34 / 73

Michèle Soria

Algorithmique Avancée

## Dictionnaire statique

- 1 Codes postaux (corpus particulier – méthodes ad hoc)
- 2 Dictionnaire de référence : Petit Robert 1993  
Pages  $< 2^{12}$ , 2 Colonnes, Mots par colonnes  $< 2^6$   
*Algorithmes et scoubidou*  
 $\rightarrow 56/2/13//822/2/5//2055/1/5$   
25 caractères (200 bits) compressés en  
 $3 * (12 + 1 + 6) = 57$  bits
- 3 Dictionnaire par taille de mot : en français taille des mots entre 1 et 25  
On connaît distribution des mots selon leur taille (9000 mots de 6 lettres) 9000 à comparer aux  $26^6 > 100$  millions ( $\sim 2^{30}$ ) de possibilités  
 $\rightarrow$  codage sur 14 bits par mot (+ 5 bits pour taille) au lieu de 30 bits

Limitations et inconvénients : dictionnaire figé ; rendre compte des conjugaisons diverses, exceptions . . . .

36 / 73

Michèle Soria

Algorithmique Avancée

## Dictionnaire adaptatif LZ77-LZSS

LZ77-LZSS : Fenêtre fixe ou coulissante sur le fichier

Ex : AIDE-TOI-LE-CIEL-T-AIDERA 25car sur 8 bits = 200 bits

1A1I1D1E1-1T1O1I1-1L0(3,2)1C1I1E1L0(4,2)1-0(0,4)1R1A  
20 bits + 17car sur 8 bits + 3couples(*pos*, *long*) sur 5+2 bits = 177 bits

- fenêtre de taille  $2^k \Rightarrow k$  bits pour *pos* ;

- *long* sur  $n$  bits  $\Rightarrow$  on peut compresser séquences de  $2^n$  car.

Difficultés :

- gestion et représentation de la fenêtre coulissante
- compression : rechercher, en toutes positions, la plus longue séquence de la fenêtre pour coder la suite du texte. Décompression pas de pb !
- complexité :  $\text{tailleFen} * \text{longMax}$  si fenêtre structurée séquentiellement
- complexité :  $\log_2(\text{tailleFen}) * \text{longMax}$  si fenêtre structurée en arbre (suffixe).  
On peut alors doubler taille fenêtre sans augmenter trop le temps de recherche.

37 / 73

Michèle Soria

Algorithmique Avancée

## Phase stationnaire

Définition : un ensemble  $F$  de mots est dit *préfixiel* ssi lorsque  $f \in F$ , alors tous les préfixes de  $f$  sont dans  $F$ .

Le dictionnaire de LZW est un ensemble préfixiel  $F$  de séquences du texte  $T$  à coder. Chaque  $f \in F$  est codé par son index (numéro) dans la table.

**En phase stationnaire** (Le dictionnaire est connu des 2 cotés)

- La compression consiste à déterminer le plus long préfixe de  $T$  qui est dans le dictionnaire  $F$  et transmettre son index dans  $F$ , et recommencer sur la suite de  $T$ .
- Pour la décompression il suffit de remplacer chaque index reçu par son contenu dans la table.

EXEMPLE :  $T = \dots \text{ababcbababaaaaaabbababca}$

39 / 73

Michèle Soria

Algorithmique Avancée

## LZ78- LZW

LZ78- LZW : Dictionnaire = Ensemble (Hachage-Arbre digital) de toutes les séquences déjà rencontrées (potentiellement illimité).

Méthodes adaptatives : phase transitoire (gagne en compression par l'apprentissage) puis stationnaire (ne sert à rien de continuer à adapter).

Algorithme en 2 phases

- 1 Phase adaptative : construit un dictionnaire tout en commençant le codage
- 2 Phase stationnaire : le dictionnaire n'évolue plus, on l'utilise pour poursuivre le codage

Le compresseur et le décompresseur construisent le même dictionnaire !

*Dictionnaire = table associative,*

*La fonction de hachage  $h : A^+ \rightarrow [0, \dots, m-1]$  est connue par le compresseur et le décompresseur.*

38 / 73

Michèle Soria

Algorithmique Avancée

<i>index</i>	<i>f</i>	<i>(père, lettre)</i>
1	a	
2	b	
3	c	
4	ab	1b
5	ba	2a
6	abc	4c
7	cb	3b
8	bab	5b
9	baba	8a
10	aa	1a
11	aaa	10a

T= ...

ababcbababaaaaaabbababca

40 / 73

Michèle Soria

Algorithmique Avancée

$T = \dots ababcbababaaaaabbababca$

$C(T) = 4\ 6\ 9\ 5\ 12\ 10\ 2\ 9\ 6\ 1$

Fonction de hachage (collisions résolues) :

$h(a) = 1, h(b) = 2, h(c) = 3, h(ab) = 4, h(ba) = 5, h(abc) = 6, h(cb) = 7,$   
 $h(bab) = 8, h(baba) = 9, h(aa) = 10, h(aaa) = 11$

### 1 A la compression,

- pour reconnaître le plus long préfixe de  $T$  dans  $F$  : **Arbre digital**,
- stocker dans la table la valeur du père (index) et la dernière lettre (gain de place)

### 2 A la décompression

- la table est suffisante (pas besoin d'arbre digital)
- décoder le contenu (père, lettre)

## Exemple

Initialement la table contient les lettres :

$h(a) = 1, h(b) = 2, h(c) = 3$

$T = ababcbababaaaaaa$

$C(T) = 1\ 2\ 4\ 3\ 5\ 8\ 1\ 10\ 11$

Fonction de hachage (collisions résolues) :

$h(ab) = 4, h(ba) = 5, h(abc) = 6, h(cb) = 7,$   
 $h(bab) = 8, h(baba) = 9, h(aa) = 10, h(aaa) = 11$

- Compression
- Décompression

Au départ la table  $F$  contient les lettres de  $A$ .

### 1 Le compresseur

- détermine le plus long préfixe  $f$  de  $T$  dans  $F$
- transmet l'index de  $f$  dans  $F$
- ajoute dans  $F$  la séquence  $fx$  (où  $x$  est le caractère suivant dans  $T$ )
- recommence à lire  $T$  à partir de  $x$

### 2 Le décompresseur, lit le premier numéro et renvoie la lettre, puis

- Lit un numéro  $i$  et consulte la table à cet index
- s'il y a un contenu, le décode en  $w_i$ , puis ajoute à la table (par hachage) une entrée formée de  $w_{i-1}$  (ou son index), suivi de la première lettre de  $w_i$
- sinon ajoute à cet endroit  $w_{i-1}$  (ou son index), suivi de **sa** première lettre. Cas de **chevauchement** :  $w_{i-1} = bw$  et  $w_i = bwb$ .

## Statistique vs. Dictionnaire

- Dictionnaire code les redondances de séquences
- apprentissage des répétitions  $\neq$  méthodes statistiques d'ordre supérieur  
ordre infini, en ne stockant que ce qui est nécessaire.
- Exemple : fichier uniforme contenant 1000 fois le même caractère  $C$ 
  - Huffman :  $C$  codé sur 1 bit  $\Rightarrow$  1000bits,
  - LZW : A chaque étape ajoute un préfixe contenant un  $C$  de plus :  $1 + \dots + k = 1000 \Rightarrow k \sim 45$  adresses  $\Rightarrow 45 * 7\text{bits} + 8\text{bits} < 350$  bits

A l'inverse il existe des cas où la compression statistique est mieux adaptée que LZW :

Fichier d'octets  $\rightarrow$  8 fichiers binaires (le premier formé de tous les premiers bits, le deuxième formé de tous les deuxièmes bits, ...).

Compression des 8 fichiers par Huffman OK, mais pas par LZW, car en découpant en 8 "plans" on a pu casser des régularités.

### Succession de deux compressions :

- Huffman suivi de LZW : améliore souvent la compression
- LZW suivi de Huffman : NON car le hachage de LZW "cache" les fréquences.

## Présentation

- Des applications à grande échelle : vision par ordinateur, robotique, CAO, synthèse d'image
- Opérations primitives sur points et lignes non cablées (contrairement aux opérations primitives sur les nombres et les textes) et difficiles à implémenter...
- Problèmes géométriques faciles résoudre "de visu" mais algorithmiquement compliqués (ex : point à l'intérieur d'un polygone ?)
- Calculer des objets géométriques : Enveloppe Convexe existe (maths) effective (algos)
- Toujours problèmes des cas dégénérés
  - points alignés (EC)
  - intersections multiples (intérieur)

## CHAPITRE 5 : ENVELOPPE CONVEXE

### CHAPITRE 5 : Algos géométriques – Enveloppe Convexe

- Enveloppe Convexe Statique
  - Ordre polaire
  - Algorithme de Graham
  - Algorithme de Jarvis
- Enveloppe Convexe Dynamique
  - Algorithme de cône enveloppant,
  - Implantation avec Listes en  $O(n^2)$
  - Implantation avec AVL en  $O(n \log n)$

## Les bases

- Repère orthonormé  $(O, \vec{i}, \vec{j})$
- Objets de base (en dimension 2)
  - point : coordonnées (cartésiennes, polaires)
  - ligne (segment) = couple de points,
  - polygone = suite de points (contour circulaire positif)
- Ordres sur  $\mathcal{P}$ 
  - *ordre cartésien* : ordre lexicographique en coordonnées cartésiennes  
 $M \leq P \Leftrightarrow x_M < x_P, \text{ ou } x_M = x_P \text{ et } y_M \leq y_P$
  - *ordre polaire* : ordre lexicographique en coordonnées polaires (angles compris entre 0 et  $2\pi$  et normes)  
 $M \leq_{O,Ox} P \Leftrightarrow \text{angle}(Ox, OM) < \text{angle}(Ox, OP), \text{ ou } \text{angle}(Ox, OM) = \text{angle}(Ox, OP) \text{ et } |OP| \leq |OM|$   
Ordre total sur  $\mathcal{P} - \{O\}$ . Mais pas efficace.

## Implantation de l'ordre polaire

Eviter de calculer des mesures d'angles (coûteux et inverser des fonctions trigonométriques introduit erreurs d'arrondis).  
Utiliser uniquement des opérations arithmétiques pour comparer des points selon l'ordre polaire.

- *idée de base* :  $0 < (\vec{u}, \vec{v}) < \pi \Leftrightarrow \det(\vec{u}, \vec{v}) > 0, \forall$  repère orthonormé direct.
- *précédence circulaire selon O* :

$$\begin{aligned} M \preceq_O P &\Leftrightarrow \det(\vec{OM}, \vec{OP}) > 0 \\ \det(\vec{OM}, \vec{OP}) &= 0 \text{ et } \vec{OM} < > \vec{OP} \\ \det(\vec{OM}, \vec{OP}) &= 0, \vec{OM} = \vec{OP}, \text{ et } |OP| \leq |OM| \end{aligned}$$

Relation ni antisymétrique, ni transitive !!

49 / 73

Michèle Soria

Algorithmique Avancée

## Exemple

Chemin fermé simple : soient  $N$  points, trouver chemin  $C$

- qui passe par tous les points,
- ne se recoupe pas,
- revient au point de départ.

**Remarque** : pbs différents

- *voyageur de commerce* (trouver le plus court chemin)
- *enveloppe convexe* (trouver le plus court chemin qui englobe tous les points).

*Principe* : calculer l'ordre polaire de chacun des points par rapport à un point distingué  $S$ , puis trier selon cet ordre, et joindre les points en ordre.

51 / 73

Michèle Soria

Algorithmique Avancée

## Précédence circulaire, ordre polaire

**Proposition** :  $M \leq_{O, O_x} P \Leftrightarrow M$  appartient au secteur angulaire  $(\vec{Ox}, \vec{OP})$  :

- ou bien  $x \preceq_O M$  et  $M \preceq_O P$ ,
- ou bien  $x \preceq_O M$  et  $P \preceq_O x$ ,
- ou bien  $M \preceq_O P$  et  $P \preceq_O x$ ,

Calcul au plus de 3 déterminants :  $O(1)$ .

**Définition** :  $(P_1, \dots, P_n)$  est un *circuit polaire* par rapport à  $O$  ssi  $\forall i, P_i \in (OP_{i-1}, OP_{i+1})$

**Propriété** :  $(P_1, \dots, P_n)$  est un *circuit polaire* par rapport à  $O$  ssi  $\forall P_0$  fixé, il existe un *conjugué*  $(P_j, P_{j+1}, \dots, P_n, P_1, \dots, P_{j-1})$ , t.q.  $\forall k, P_k \leq_{O, OP_0} P_{k+1}$ .  
Calcul du circuit polaire de  $N$  points en  $O(N \log N)$  comparaisons (voir TD).

50 / 73

Michèle Soria

Algorithmique Avancée

## Enveloppe convexe

### Définitions

- $S$  convexe ssi  $\forall (x, y) \in S, [x, y] \subset S$
- *L'enveloppe convexe* de  $S$  est le plus petit ensemble convexe contenant  $S$

### Propriétés

- 1  $EC(S)$  existe
- 2 Si  $S$  est un ensemble fini de points,  $EC(S)$  est un polygone convexe dont les sommets sont dans  $S$

Tout point d'ordonnée minimale et tout point d'abscisse minimale de  $S$  appartiennent à l'enveloppe convexe  $EC(S)$ .

### Algorithmes

ENTREE : ensemble  $S$  de  $N$  points

SORTIE : contour positif du polygone convexe

52 / 73

Michèle Soria

Algorithmique Avancée

## Enveloppe convexe et Tri

**Propriété** : Le calcul de l'enveloppe convexe d'un ensemble de  $N$  points demande  $\Omega(N \log N)$  comparaisons.

- $N$  nombres : coordonnées polaires de  $N$  points (de même rayon) .  
L'enveloppe convexe contient ces  $N$  points, triés en ordre polaire. Donc si on savait faire l'EC en moins de  $N \log N$  comparaisons, on saurait trier en moins de  $N \log N$  comparaisons.
- $N$  points sur parabole  $y = x^2$ , dans le contour positif de l'EC les points sont triés par abscisses croissantes.

53 / 73

Michèle Soria

Algorithmique Avancée

## Algorithme de Graham

- Choisir un point  $O \notin S$ , intérieur à  $EC(S)$ .  $O(N)$
- Calculer le circuit polaire de  $S$  par rapport à  $O$ .  $O(N \log N)$
- Soit  $P_0$  le point d'abscisse max de  $S$  ( $P_0 \in EC(S)$ ).  $O(N)$
- Posons  $P = P_0$
- Tant que  $\text{succ}(P) \neq P_0$   $O(N)$ 
  - si  $(P, \text{succ}(P), \text{succ}(\text{succ}(P)))$  est un Tour Gauche alors  $\text{Avancer}(P)$
  - sinon  $\text{Supprimer}(\text{succ}(P))$ , et si  $\text{pred}(P) \neq P_0$  alors  $\text{Reculer}(P)$

Boucle en  $O(N)$  à condition que toutes opérations  $\text{pred}, \text{succ}, \dots$  en  $O(1)$

Complexité de Graham :  $O(N \log N)$  dans le pire des cas.

55 / 73

Michèle Soria

Algorithmique Avancée

## Méthode de Graham

### Propriétés

- 1 Si le point  $O$  est à l'intérieur d'un polygone convexe  $P$ , alors un contour positif de  $P$  est un circuit polaire par rapport à  $O$ .
- 2 Un polygone simple est convexe ssi pour tout triplet  $(P, Q, R)$  de sommets consécutifs en sens positif,  $Q \prec_P R$  ( $PQR$  tour gauche)

Déterminer un circuit polaire de tous les points de  $S$   
Le parcourir en supprimant tous les points  $P_i$  tels que  $(P_{i-1}, P_i, P_{i+1})$  n'est pas un tour gauche.

54 / 73

Michèle Soria

Algorithmique Avancée

## Méthode de Jarvis

Principe du paquet cadeau

**Propriété** : Si  $(P_1, \dots, P_h)$  est un contour positif de  $EC(S)$ , alors pour tout  $i$ ,  $P_{i+1}$  est un point minimal de  $S - \{P_i\}$  pour l'ordre polaire  $\prec_{P_i, \vec{P_i P_{i-1}} P_i}$

On commence avec un point d'ordonnée minimale (et s'il y en a plusieurs on choisit celui d'abscisse minimale).

56 / 73

Michèle Soria

Algorithmique Avancée

## Algorithme de Jarvis

- Soit  $P_1$  point de  $S$  d'ordonnée minimale.  $O(N)$
- $P_2$  pt min de  $S - \{P_1\}$  pour ordre polaire  $<_{P_1, Hz}$ .  $O(N)$
- Soit  $k = 2$
- Répéter  $O(Nh)$ 
  - Soit  $Q$  point minimal de  $S - \{P_k\}$  pour l'ordre polaire  $<_{P_k, P_{k-1} \rightarrow P_k}$
  - $k := k + 1, P_k := Q$
- Jusqu'à  $P_k = P_1$

Boucle en  $O(Nh)$ , où  $h$  est le nombre de points de  $EC(S)$   
 Complexité de Jarvis  $O(Nh)$  : intéressant si  $h \ll \log N$ .  
 Mais au pire  $h = N$ , donc Jarvis en  $O(N^2)$  dans le pire des cas.

57 / 73

Michèle Soria

Algorithmique Avancée

## Algorithme du cône enveloppant

Soit  $S$  un ensemble de points, et  $EC(S) = (q_0, \dots, q_k)$ .  
 Soit  $P$  un nouveau point.

- 1 si  $P \in EC(S)$  alors  $EC(S \cup \{P\}) = EC(S)$
- 2 sinon, soit  $\delta$  demi-droite issue de  $P$  et ne coupant pas  $EC(S)$ 
  - soit  $R = \min(S)$  pour l'ordre polaire par rapport à  $\delta$  ;  
 $r \in EC(S)$
  - soit  $L = \max(S)$  pour l'ordre polaire par rapport à  $\delta$  ;  
 $l \in EC(S)$
- 3  $EC(S) = (q_0, \dots, L, \dots, R, \dots, q_k)$  et  
 $EC(S \cup \{p\}) = (q_0, \dots, L, P, R, \dots, q_k)$

59 / 73

Michèle Soria

Algorithmique Avancée

## Enveloppe Convexe Dynamique

- 1 Algorithme statique en  $O(n \log n)$   
 Graham, dichotomique, ...
- 2 Ensemble dynamique : ajout et suppression de points
  - Ajouts uniquement  
 Algorithme en  $O(n \log n)$  (Preparata)
  - Ajouts et suppressions  
 Algorithme en  $O(n \log^2 n)$  (Overmars, Van Leeuwen)

Algorithme de Preparata : fondé sur algorithme de cône enveloppant, avec représentation de l'enveloppe convexe par un arbre AVL.

58 / 73

Michèle Soria

Algorithmique Avancée

## Implantation avec Listes

Liste doublement chaînée de  $EC(S) = (q_0, q_1, \dots, q_k)$  en ordre direct.

$EC(S \cup \{p\})$  se calcule en  $O(k)$  à partir de  $EC(S)$ , avec  $k \leq ||S||$

- 1 vérifier si  $p$  est à l'intérieur de  $EC(S)$  – coût  $O(k)$ ,
- 2 trouver le min et le max de  $EC(S)$  pour l'ordre polaire par rapport à  $\delta$  – coût  $O(k)$ ,
- 3 supprimer de  $L$  à  $R$  et insérer  $p$  – coût  $O(1)$ , si accès à  $L$  et  $R$ .

Donc la complexité de construction de l'EC de  $n$  points est en  $O(\sum_{k=3}^{n-1} k) = O(n^2)$

60 / 73

Michèle Soria

Algorithmique Avancée



## Implantation avec AVL

$EC(S)$  représenté par un arbre équilibré  $T$ , de hauteur  $O(\log k)$   
Circuit polaire de  $EC(S) \equiv$  Parcours symétrique de  $T$

- ❶  $p$  est à l'intérieur de  $EC(S)$  ? – coût  $O(\log k)$  (recherche dans l'arbre)
- ❷ min et max dans l'ordre polaire – coût  $O(\log k)$  (recherche dans l'arbre)
- ❸ nouvelle  $EC$  – coût  $O(\log k)$  (coupure, concaténation, insertion)

Donc la complexité de construction de l'EC de  $n$  points est en  $O(\sum_{k=3}^{n-1} \log k) = O(n \log n)$

61 / 73

Michèle Soria

Algorithmique Avancée

## Concaténation

*Concatenation* :  $AVL-EC * AVL-EC * Element \rightarrow AVL-EC$

Hypothèse :  $G \leq x < D$

**renvoie** un arbre AVL contenant  $G, x$  et  $D$

**Fonction** Concatenation(  $G, D, x$ )

**Si**  $|h(G) - h(D)| \leq 1$  **Retourne** ArbreBinaire( $x, G, D$ )

**Sinon Si**  $h(G) > h(D) + 1$  **Retourne**

Equilibrage(ArbreBinaire(rac( $G$ ), SousArbreGauche( $G$ ),  
Concatenation(SousArbreDroit( $G$ ),  $x, D$ )))

**Sinon Retourne**

Equilibrage(ArbreBinaire(rac( $D$ ), Concatenation( $G, x$ , SousArbreGauche( $D$ )),  
SousArbreDroit( $D$ )))

**Fin Si**

**Fin Fonction** Concatenation

Nombre d'appels récurifs :  $O(|h(G) - h(D)|)$

Complexité en  $O(\log n)$

63 / 73

Michèle Soria

Algorithmique Avancée

## Arbres AVL

**Définition** : un arbre AVL est un ABR tel que les hauteurs de 2 noeuds frères diffèrent au plus de 1.

**Propriété** : tout arbre AVL contenant  $n$  noeuds et de hauteur  $H$  vérifie

$$\log_2(n+1) \leq H+1 < 1,44 \log_2(n+2)$$

- Recherche d'un élément :  $O(\log n)$
- Ajout d'un élément :  $O(\log n)$  – avec au plus 1 rotation
- Suppression d'un élément :  $O(\log n)$  – avec au plus  $\log n$  rotations
- Concaténation –  $O(\log n)$  : ( $G, x, D$ ) avec  $G$  et  $D$  AVL et  $G \leq x < D$ , renvoie un AVL contenant tous les éléments
- Coupure –  $O(\log n)$  : ( $T, x$ ) avec  $T$  AVL renvoie le couple ( $G, D$ ) avec  $G$  et  $D$  AVL et  $G \leq x < D$

62 / 73

Michèle Soria

Algorithmique Avancée

## Coupure

*Coupure* :  $AVL-EC * Element \rightarrow AVL-EC * AVL-EC$

**renvoie** un couple d'arbres AVL ( $G, D$ ) tels que  $G < x$  et  $x < D$

**Fonction** Coupure(  $T, x$ )

**Si** EstVide( $T$ ) **Retourne** (vide, vide)

**Sinon Si** Estfeuille( $T$ )

**Si**  $x \leq \text{rac}(T)$  **Retourne** (vide,  $T$ )

**Sinon Retourne** ( $T$ , vide)

**Fin Si**

**Sinon Si**  $x \leq \text{rac}(T)$

**Soit** ( $G0, D0$ ) = Coupure( SousArbreGauche( $T$ ),  $x$ )

**Retourne** ( $G0$ , Concatenation( $D0$ , rac( $T$ ), SousArbreDroit( $T$ )))

**Sinon**

**Soit** ( $G0, D0$ ) = Coupure( SousArbreDroit( $T$ ),  $x$ )

**Retourne** Concatenation((SousArbreGauche( $T$ ), rac( $T$ ),  $G0$ ),  $D0$ )

**Fin Si**

**Fin Fonction** Coupure

Complexité en  $O(\log n)$

64 / 73

Michèle Soria

Algorithmique Avancée

## Représentation de l'EC par un AVL

L'arbre  $T$  qui représente l'enveloppe convexe AVL de hauteur  $O(\log k)$

- Parcours symétrique de  $T \equiv$  Circuit polaire de  $EC(S)$  double chaînage en ordre symétrique
- Le min de  $T$  est le premier élément du circuit polaire accès au min
- Chaque noeud contient la hauteur du sous-arbre dont il est la racine

EXEMPLE

## Les différents cas

18 cas possibles :  $(\overrightarrow{Pm}, \overrightarrow{PM}) (\leq \pi \text{ ou } > \pi)$ ,  $m$  est concave ou réflexe ou porteur par rapport à  $P$ ,  $M$  est concave ou réflexe ou porteur par rapport à  $P$ .

- 1 m concave, M concave et  $0 \leq (\overrightarrow{Pm}, \overrightarrow{PM}) \leq \pi$
- 2 m concave, M réflexe et  $0 \leq (\overrightarrow{Pm}, \overrightarrow{PM}) \leq \pi$
- 3 m réflexe, M réflexe et  $0 \leq (\overrightarrow{Pm}, \overrightarrow{PM}) \leq \pi$
- 4 m réflexe, M concave et  $0 \leq (\overrightarrow{Pm}, \overrightarrow{PM}) \leq \pi$
- 5 m réflexe, M réflexe et  $(\overrightarrow{Pm}, \overrightarrow{PM}) > \pi$
- 6 m réflexe, M concave et  $(\overrightarrow{Pm}, \overrightarrow{PM}) > \pi$
- 7 m concave, M concave et  $(\overrightarrow{Pm}, \overrightarrow{PM}) > \pi$
- 8 m concave, M réflexe et  $(\overrightarrow{Pm}, \overrightarrow{PM}) > \pi$

Les 10 autres cas se ramènent aux 8 cas ci-dessus.

## Position des points

Soit  $EC(S)$  l'enveloppe convexe des  $k$  points et  $P$  un nouveau point.

**Définition** : soit  $Q \in EC(S)$  :

- si  $Q = L$  ou  $Q = R$ , alors  $Q$  est dit *porteur* par rapport à  $P$
- si  $Q$  est entre  $L$  et  $R$ , alors  $Q$  est dit *réflexe* par rapport à  $P$
- si  $Q$  est entre  $R$  et  $L$ , alors  $Q$  est dit *concave* par rapport à  $P$

Calcul de la position en temps  $O(1)$

- $Q$  concave :  $(P, Q, succ(Q))$  est un tour gauche,  $det(\overrightarrow{PQ}, \overrightarrow{Psucc(Q)}) > 0$
- $Q$  réflexe :  $(P, Q, succ(Q))$  est un tour droit,  $det(\overrightarrow{PQ}, \overrightarrow{Psucc(Q)}) < 0$
- $Q$  porteur :  $det(\overrightarrow{PQ}, \overrightarrow{Ppred(Q)})$  et  $det(\overrightarrow{PQ}, \overrightarrow{Psucc(Q)})$  de même signe.

## Points porteurs du circuit

*Porteurs* : point \* AVL-EC  $\rightarrow$  point  $\cup$  {vide} \* point  $\cup$  {vide}  
renvoie le couple de points porteurs

**Fonction** Porteurs (P, T, m)

**Si** EstVide(T) **Retourne** (vide, vide) **Fin Si**

**Soient** M=rac(T) et m= min(T)

**Si** m = M **Retourne** (vide, vide) **Fin Si**

**Selon Cas**

1 ou 5 : **Retourne** Porteurs(P, SousArbreDroit(T), succ(M))

2 : **Retourne** L=chL(T-SousArbreDroit(T)) et R=chR(SousArbreDroit(T))

3 ou 7 : **Retourne** Porteurs(P, SousArbreGauche(T), m)

4 : **Retourne** L=chL(T-SousArbreGauche(T)) et R=chR(SousArbreGauche(T))

6 : **Retourne** L=chL(SousArbreDroit(T)) et R=chR(T-SousArbreDroit(T))

8 : **Retourne** L=chL(SousArbreGauche(T)) et R=chR(T-SousArbreGauche(T))

**Fin Selon**

**Fin Fonction** Porteurs

*chL* : AVL-EC  $\rightarrow$  point  
**renvoie** le le point porteur *L*

**Fonction** *chL*(*T*)  
  *C*=rac(*T*)  
  **Selon Cas**  
    *C* porteur par rapport à *P* : **Retourne** *C*  
    *C* reflexe par rapport à *P* : **Retourne** *chL*(SousArbreGauche(*T*))  
    *C* concave par rapport à *P* : **Retourne** *chL*(SousArbreDroit(*T*))  
  **Fin Selon**  
**Fin Fonction** *chL*

*chR* : AVL-EC  $\rightarrow$  point  
**renvoie** le le point porteur *R*

**Fonction** *chR*(*T*)  
  *C*=rac(*T*)  
  **Selon Cas**  
    *C* porteur par rapport à *P* : **Retourne** *C*  
    *C* concave par rapport à *P* : **Retourne** *chR*(SousArbreGauche(*T*))  
    *C* reflexe par rapport à *P* : **Retourne** *chR*(SousArbreDroit(*T*))  
  **Fin Selon**  
**Fin Fonction** *chR*

## Complexité

- 1 Remarque :  
Si *P* est intérieur à *EC* alors la fonction *Porteurs* renvoie (*vide*, *vide*).
- 2 Complexité
  - *chL* et *chR* en  $O(\log n)$  car recherche dans un AVL
  - *Porteurs* en  $O(\log n)$  car
    - soit appelle *chL* ou *chR* dans sous-arbres gauche ou droit
    - soit appelle *Porteurs* dans sous-arbres gauche ou droit

## Réorganisation de l'AVL-EC

Etant donnés *T*, *L*, *R* et *P*, modifier *T* pour qu'il soit un AVL représentant l'enveloppe convexe de  $S \cup \{P\}$ .

Deux cas de figure :

- *m* est concave par rapport à *P* ou *m*=*L*
- *m* est réflexe par rapport à *P* ou *m*=*R*

Il faut faire des coupures et/ou des concaténations dans l'AVL.  
Complexité  $O(\log n)$ .

## Algorithme de réorganisation

*Reorganisation* : : AVL-EC \* point \* point \* point  $\rightarrow$  AVL-EC  
**renvoie** l'AVL représentant l'enveloppe convexe incrémentée

**Fonction** *Reorganisation*(*T*,*L*,*R*,*P*)  
  *m*=min(*T*)  
  **Si** *m* est concave par rapport à *P* ou *m*=*L*  
    (*G1*,*D1*)= Coupure(*T*,*L*)  
    (*G2*,*D2*)= Coupure(*D1*,*R*)  
    **Retourne** Concatenation(*G1*,*D2*,*P*)  
  **Sinon** ; *m* réflexe ou *m*=*R*  
    (*G1*,*D1*)= Coupure(*T*,*L*)  
    (*G2*,*D2*)= Coupure(*G1*,*R*)  
    **Retourne** ajout(*P*,*D2*)  
  **Fin Si**  
  succ(*P*)=*R* pred(*P*)=*L* succ(*L*)=*P* pred(*R*)=*P*  
**Fin Fonction** *Reorganisation*

## Enveloppe convexe incrémentale

*AjoutEC : AVL-EC \* point  $\rightarrow$  AVL-EC*

*renvoie l'AVL représentant l'enveloppe convexe incrémentée*

**Fonction** AjoutEC( T, P)

**Soit** m = min(T)

**Soient** (L,R) = Porteurs(P,T,m)

**Si** L=R=vide **Retourne** T

**Sinon Retourne** Reorganisation(T,L,R,P)

**Fin Si**

**Fin Fonction** AjoutEC

*EnvConvIncr : : Ens de n points  $\rightarrow$  AVL-EC*

*renvoie l'AVL représentant l'enveloppe convexe des n points*

**Fonction** EnvConvIncr(p1,p2,...,pn)

**Soit** T = AVL(p1,p2,p3)

**Pour** i=4 à n T=AjoutEC(T,pi) **Fin Pour**

**Retourne** T

**Fin Fonction** EnvConvIncr                      O(nlog n)