# Architecture des Réseaux (ARES) 3/5 : **Transport**

**Olivier Fourmaux** (olivier.fourmaux@upmc.fr)

Version 6.2

# ARES : plan du cours 3/5

1. Service de base
   - Rappels sur la couche transport
   - Multiplexage et démultiplexage
   - UDP : un protocole en mode non connecté
2. Service fiable
   - Principes de transfert de données fiable
   - TCP : un protocole en mode orienté connexion
   - TCP : mécanismes de fiabilisation
3. Contrôle de congestion
   - Principes généraux
   - Mécanismes de TCP

# Couche transport

Compréhension des principes de base de la couche transport[1]

- multiplexage
- transfert fiable
- contrôle de flux
- contrôle de congestion

Etude des protocoles de transport dans l'Internet

- UDP : transport sans connexion
- TCP : transport orienté-connexion
- contrôle de congestion de TCP

[1] Nombreux emprunts au livre de J. F. Kurose et K. W. Ross, *Computer Networking : A Top Down Approach Featuring the Internet*, 3e edition (Addisson-Wesley)

# ARES : plan du cours 3/5

# Couche transport

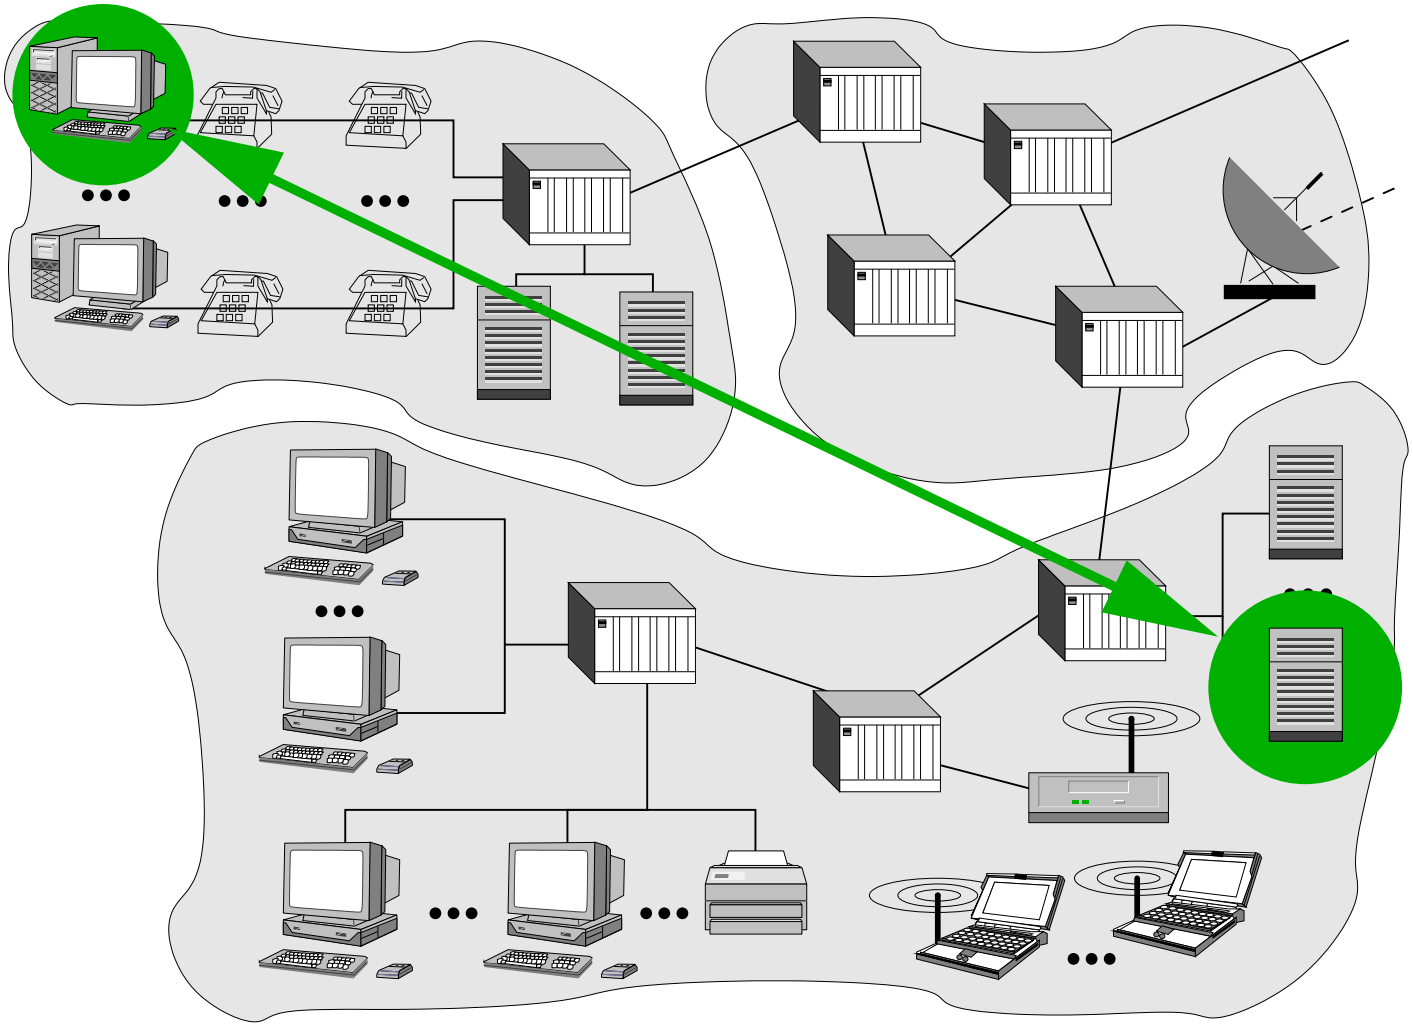

# Couche transport

La **Couche transport** permet de faire **communiquer directement** deux ou plusieurs entités sans avoir à se préoccuper des différents éléments de réseaux traversés :

- associations virtuelles entre **processus**
- communication de bout-en-bout (*end-to-end*)
  - abstraction de la **topologie** et des **technologies** sous-jacentes
  - fonctionne dans les machines d'extrémité
    - **émetteur** : découpe les messages de la couche applicative en segments et les "descend" à la couche réseau
    - **récepteur** : réassemble les segments en messages et les "remonte" à la couche application

➠ 2 **modèles** définissent les fonctionnalités associés à chaque couche...

# Couche transport : OSI

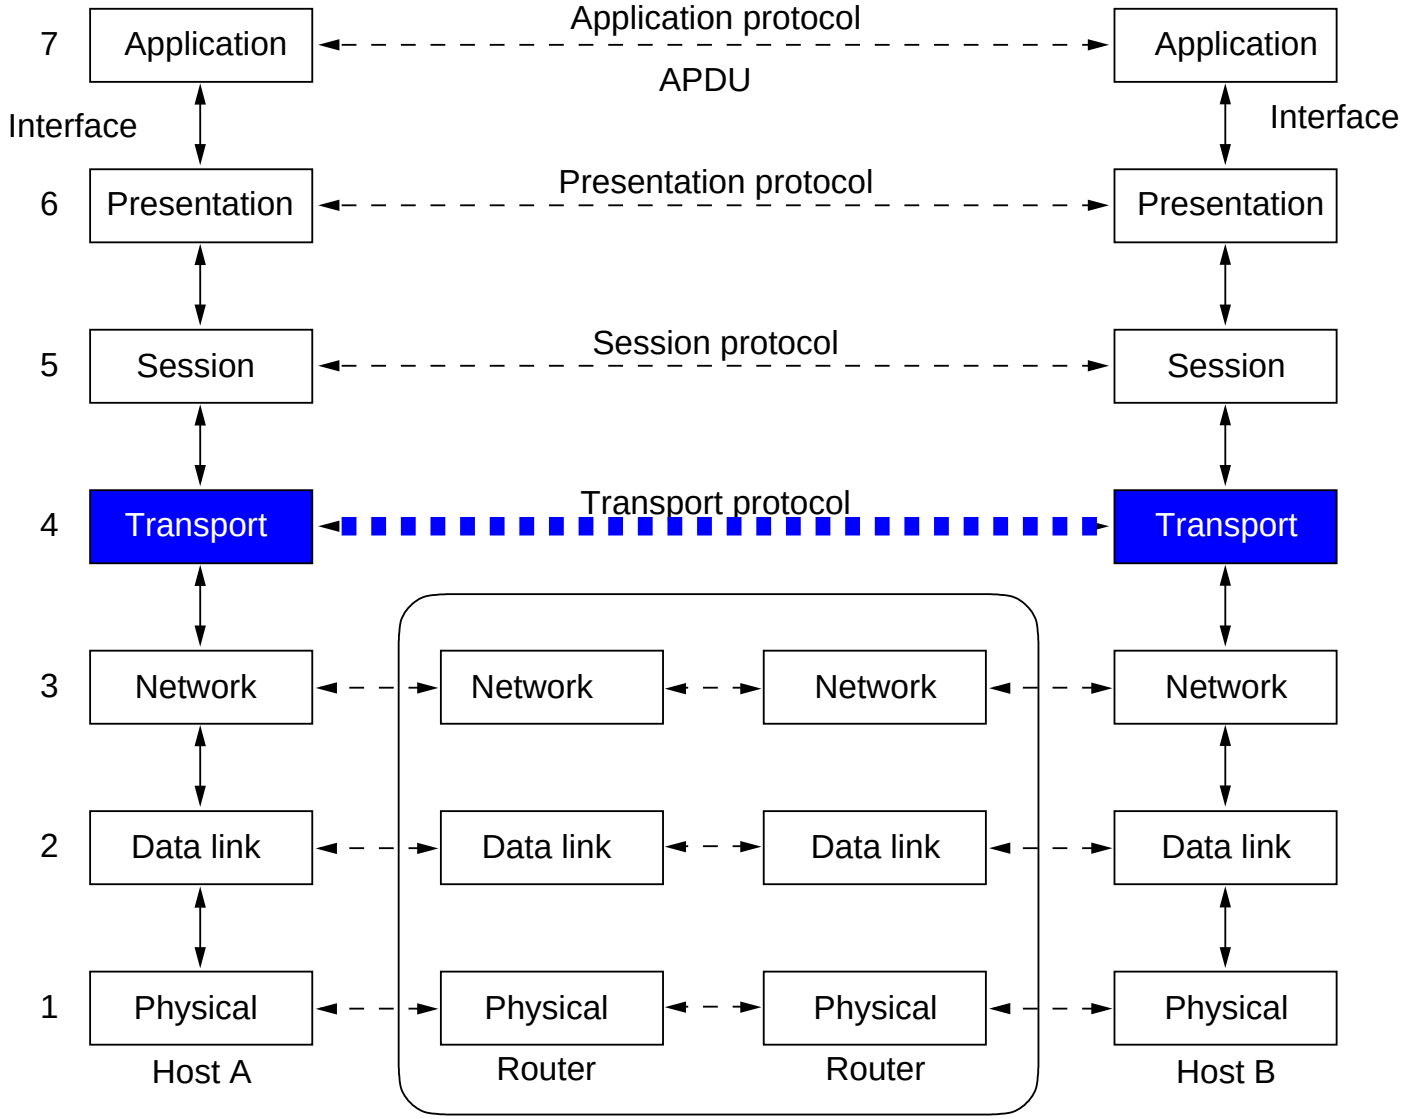

# Couche transport : TCP/IP

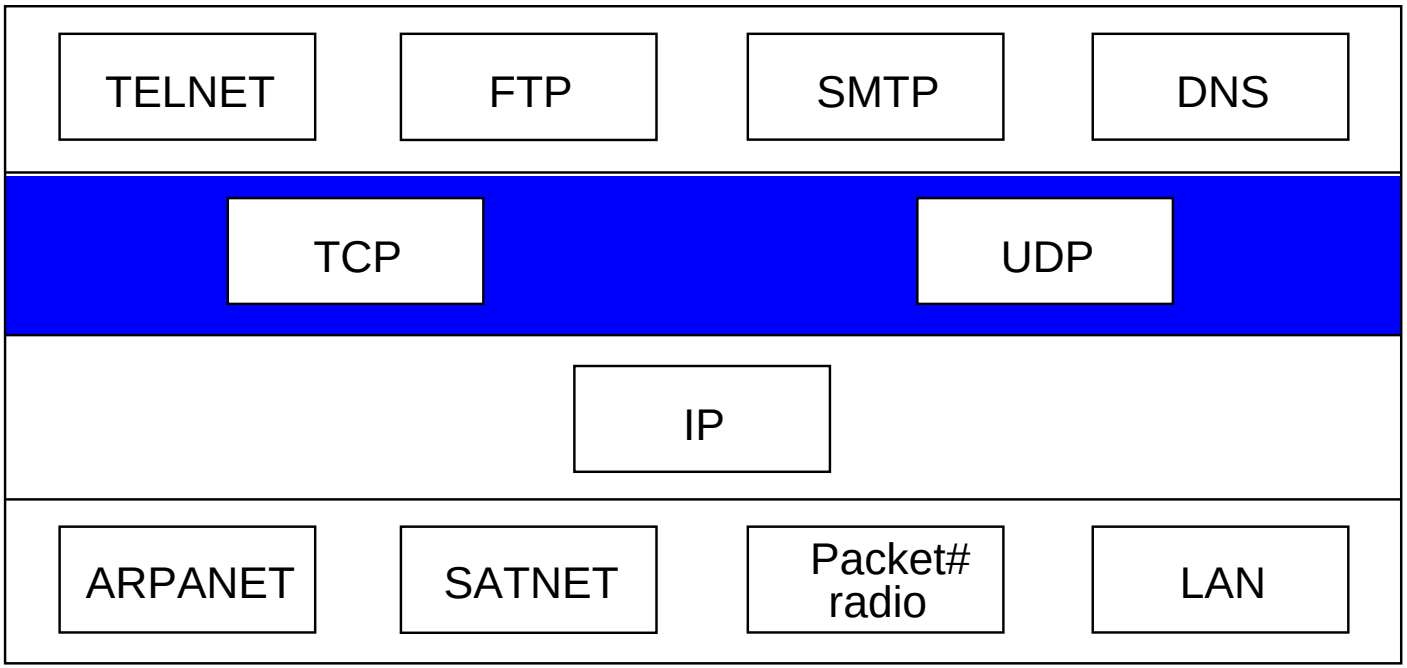

# Couche transport : Internet

2 standard transport layer protocols : TCP and UDP

- ordered, reliable transmissions : **TCP**
  - connection management
  - flow control
  - congestion control
- unordered, unreliable transmissions : **UDP**
  - *best effort* service
  - lightweight
- unavailable :
  - bandwidth guarantees
  - temporal guarantees
    - delays are unbounded
    - jitter is unpredictable

# Couche transport : 2 modes

## Mode **non connecté**

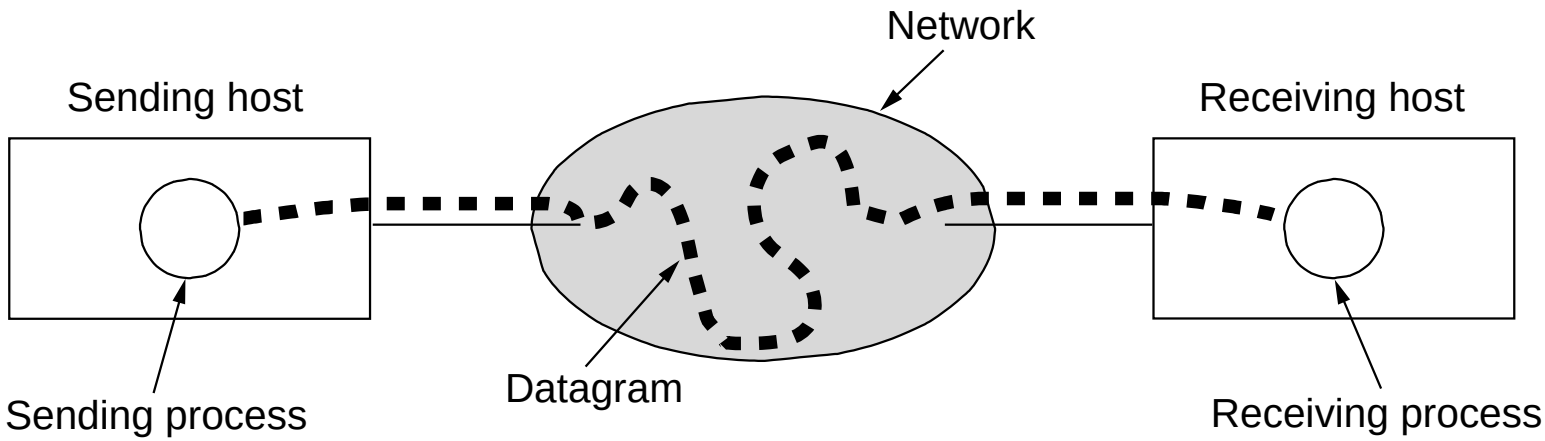


## Mode **orienté connexion**

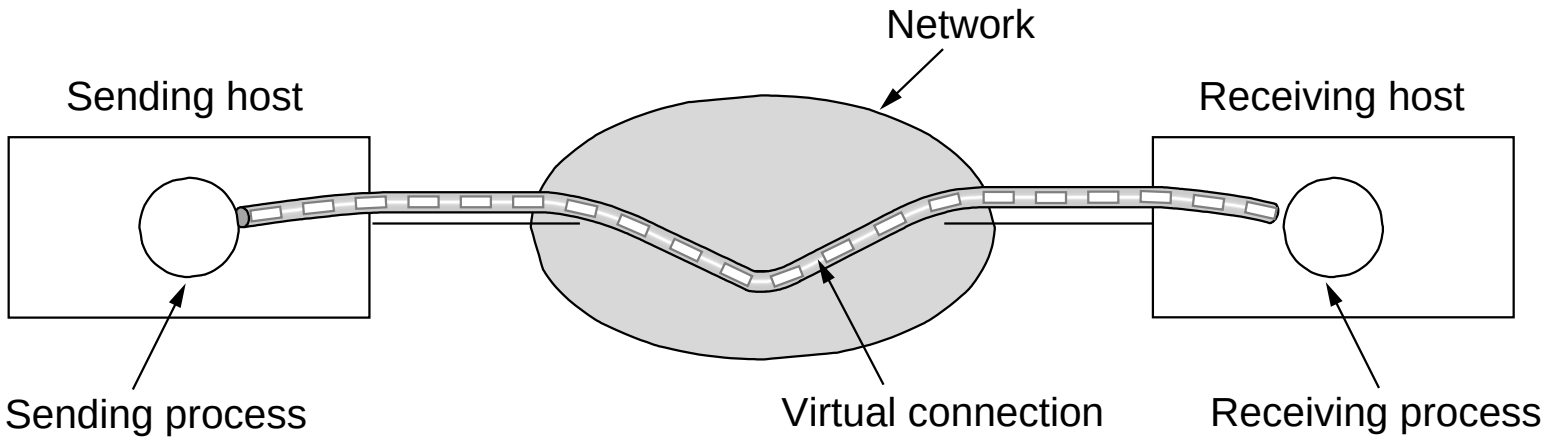

# Couche transport : primitives

Interface de **programmation** (applications ou développeurs)

- exemple de primitives de base en mode connecté :
  - LISTEN
  - CONNECT
  - SEND
  - RECEIVE
  - DISCONNECT

# Couche transport : automate de connexion

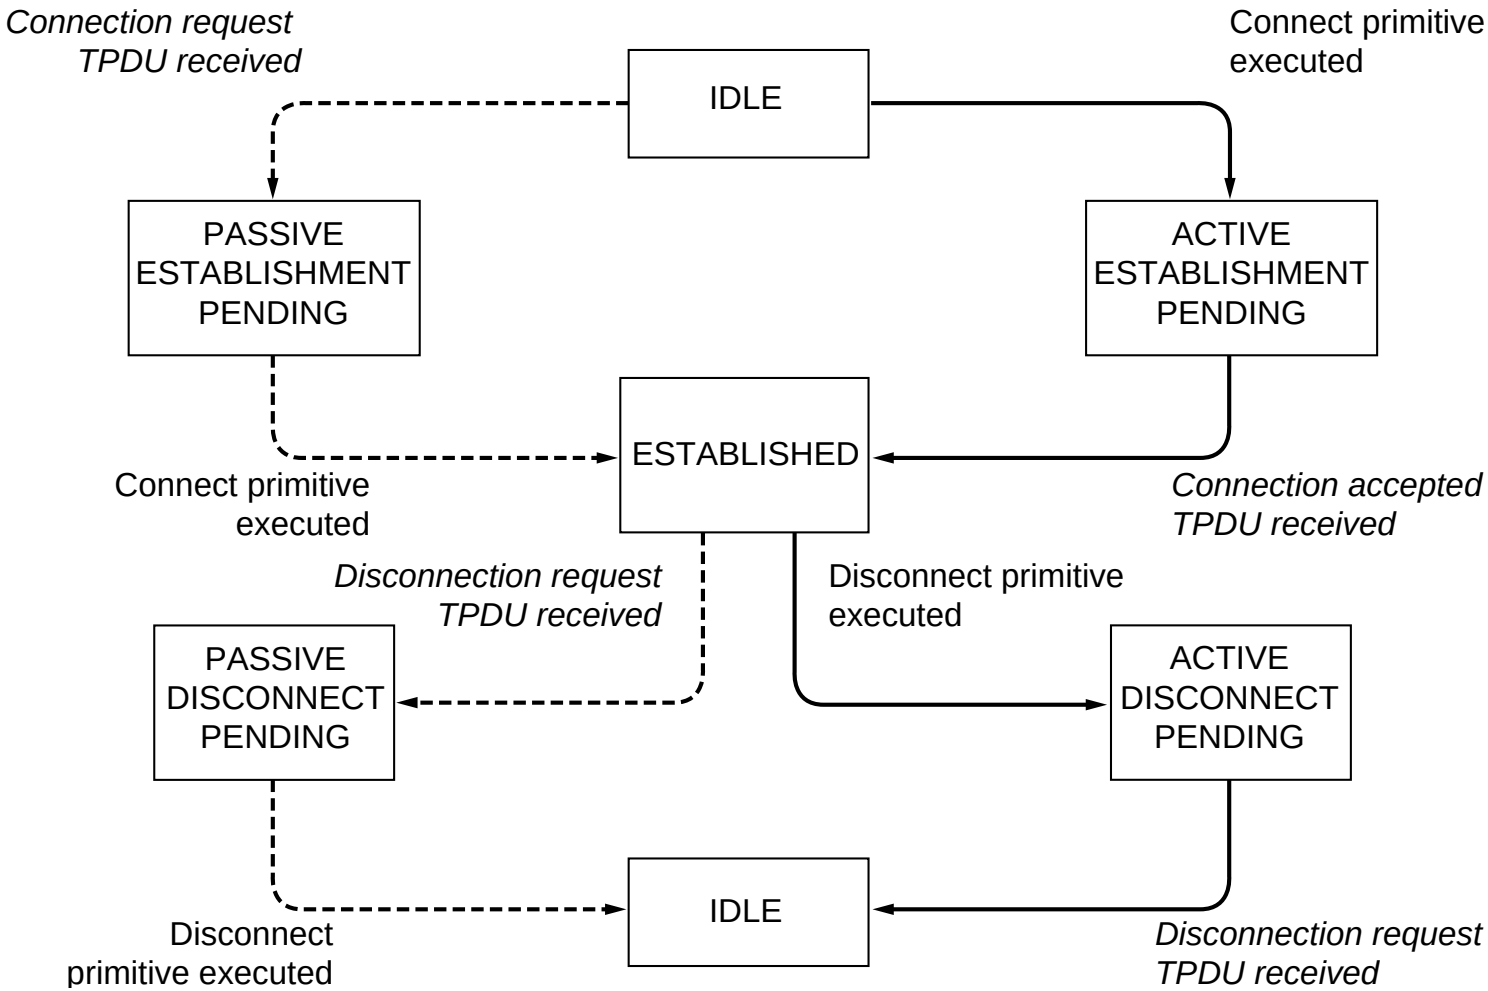


pictures from Tanenbaum A. S. *Computer Networks 3rd edition*

# Couche transport : établissement (*call setup*)

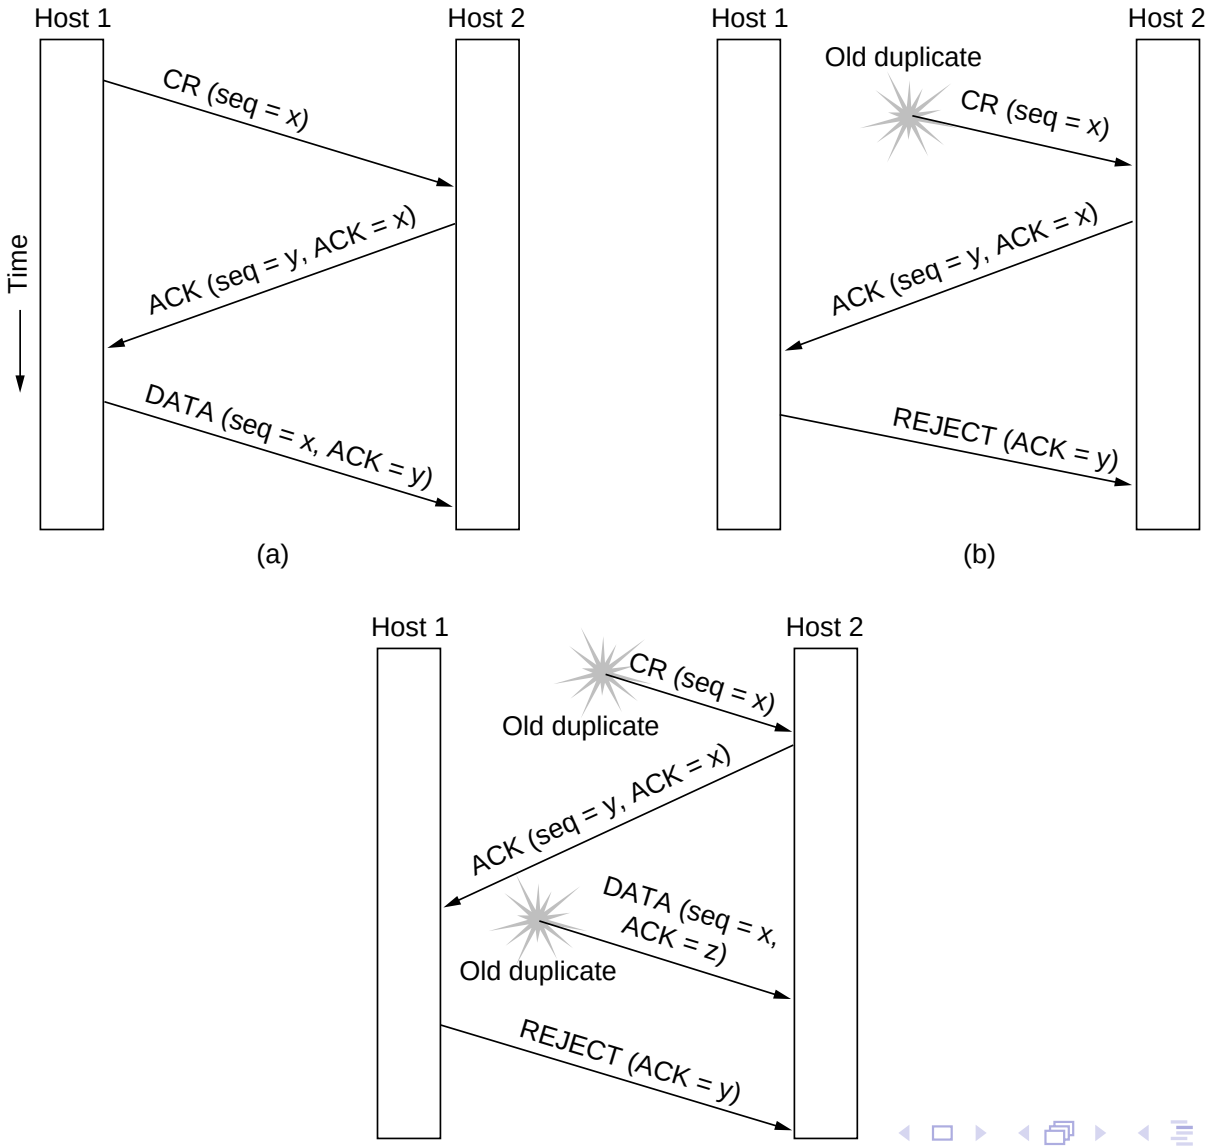

# ARES : plan du cours 3/5

# Multiplexage/démultiplexage

Les **processus** applicatifs transmettent leurs données au système à travers des **sockets** : Le **multiplexage** consiste à regrouper ces données.

- **mux** (à l'émetteur) :
  - ajout d'un entête à chaque bloc de données d'un socket
  - collecte les données de plusieurs socket
- **demux** (au récepteur) :
  - fourniture des données au socket correspondant

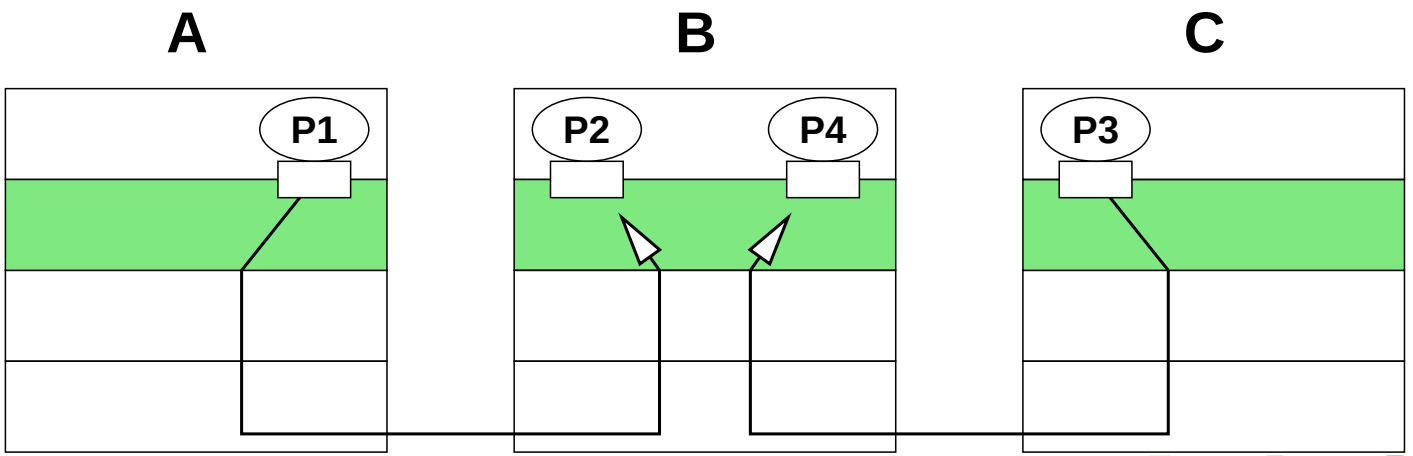

# Démultiplexage en mode non connecté

Association d'un socket avec un numéro de port

- identification du `DatagramSocket` : (`@IPdest`, `numPortDest`)
- réception d'un **datagramme** à un hôte :
  - vérification du `numPortDest` contenu
  - envoi au socket correspondant à `numPortDest`
    - $\forall$ `@IPsource`, $\forall$ `numPortSource`

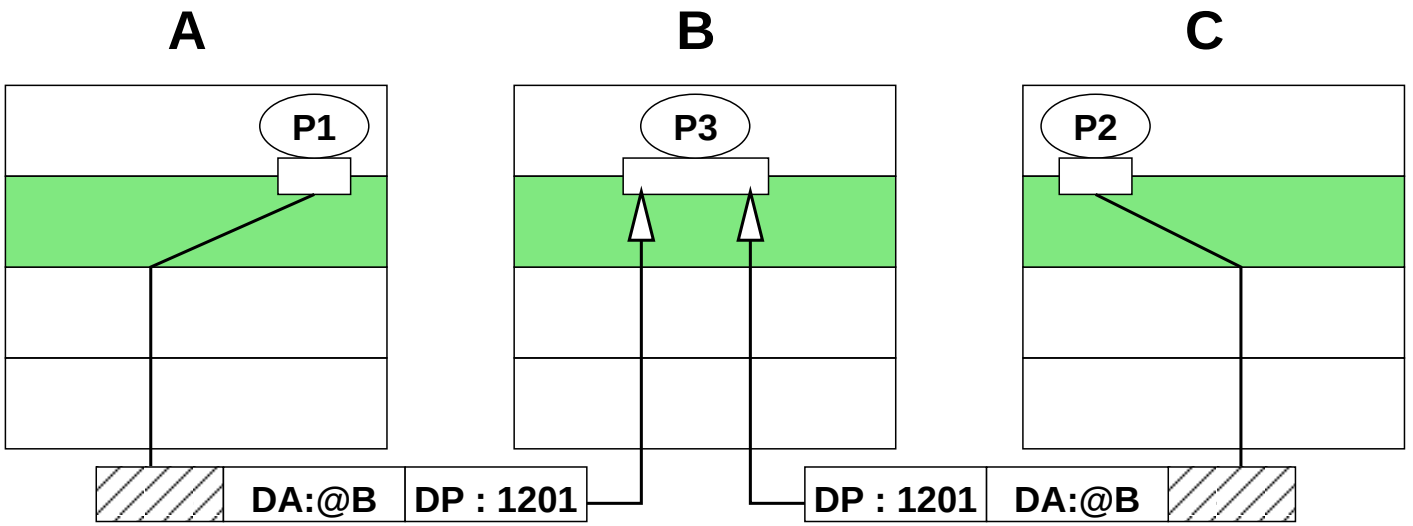

# Multiplexage en mode orienté connexion

Association relative à une **connexion** entre deux processus

- identification du `StreamSocket` par le quadruplet :
  - adresse source : `@IPsource`
  - port source : `numPortSource`
  - adresse destination : `@IPdest`
  - port destination : `numPortDest`
- réception d'un **segment** à un hôte :
  - vérification du quadruplet contenu
  - envoi au socket correspondant au quadruplet
    - un serveur web peut avoir plusieurs connexions simultanée

# Démultiplexage en mode orienté connection (1)

Serveur web classique (apache 1.x)

- un socket par connexion
  - HTTP en mode non persistant : un socket par requête !

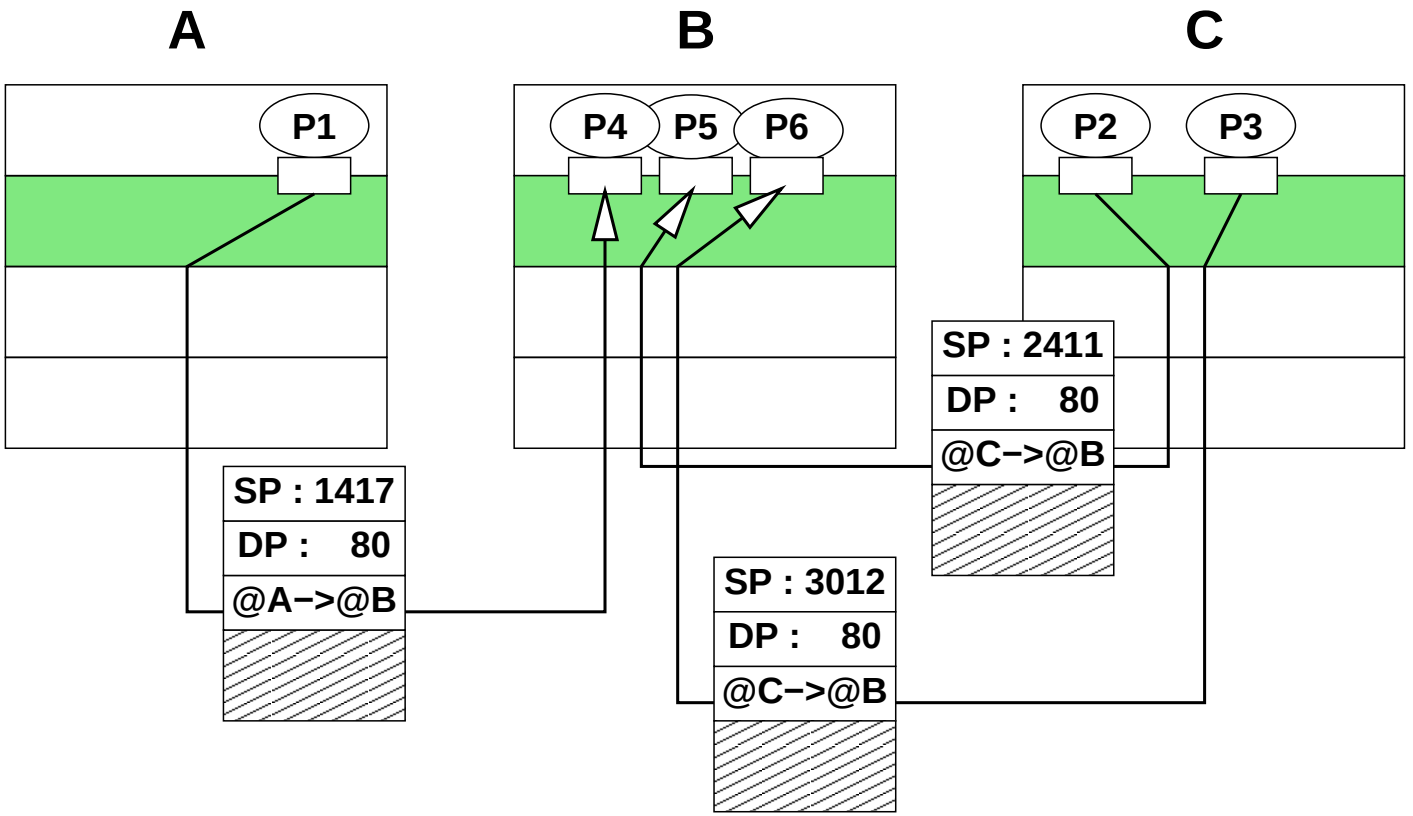

# Démultiplexage en mode orienté connection (2)

Serveur web multi-threadé (apache 2.x)

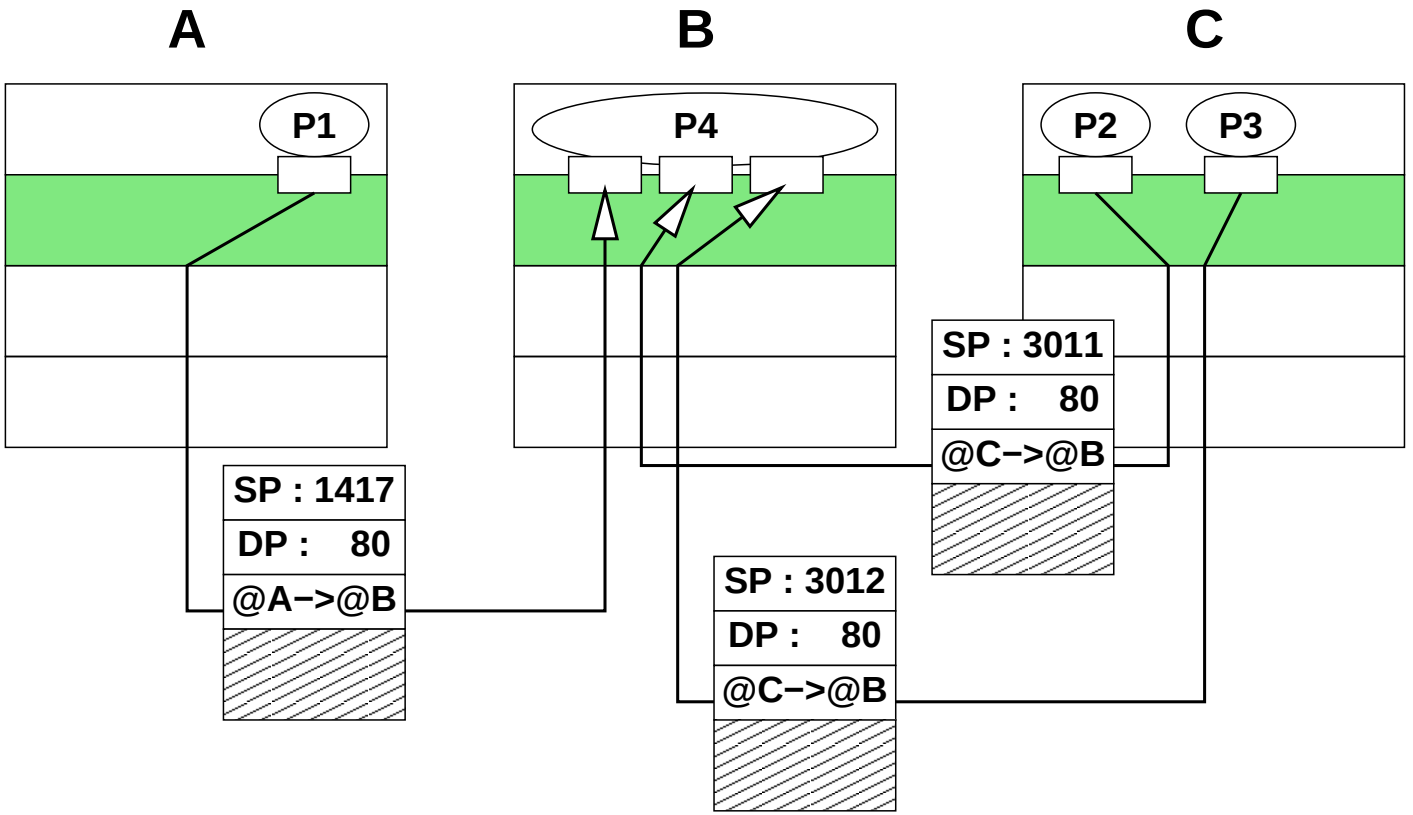

# Multiplexage : dénominations OSI

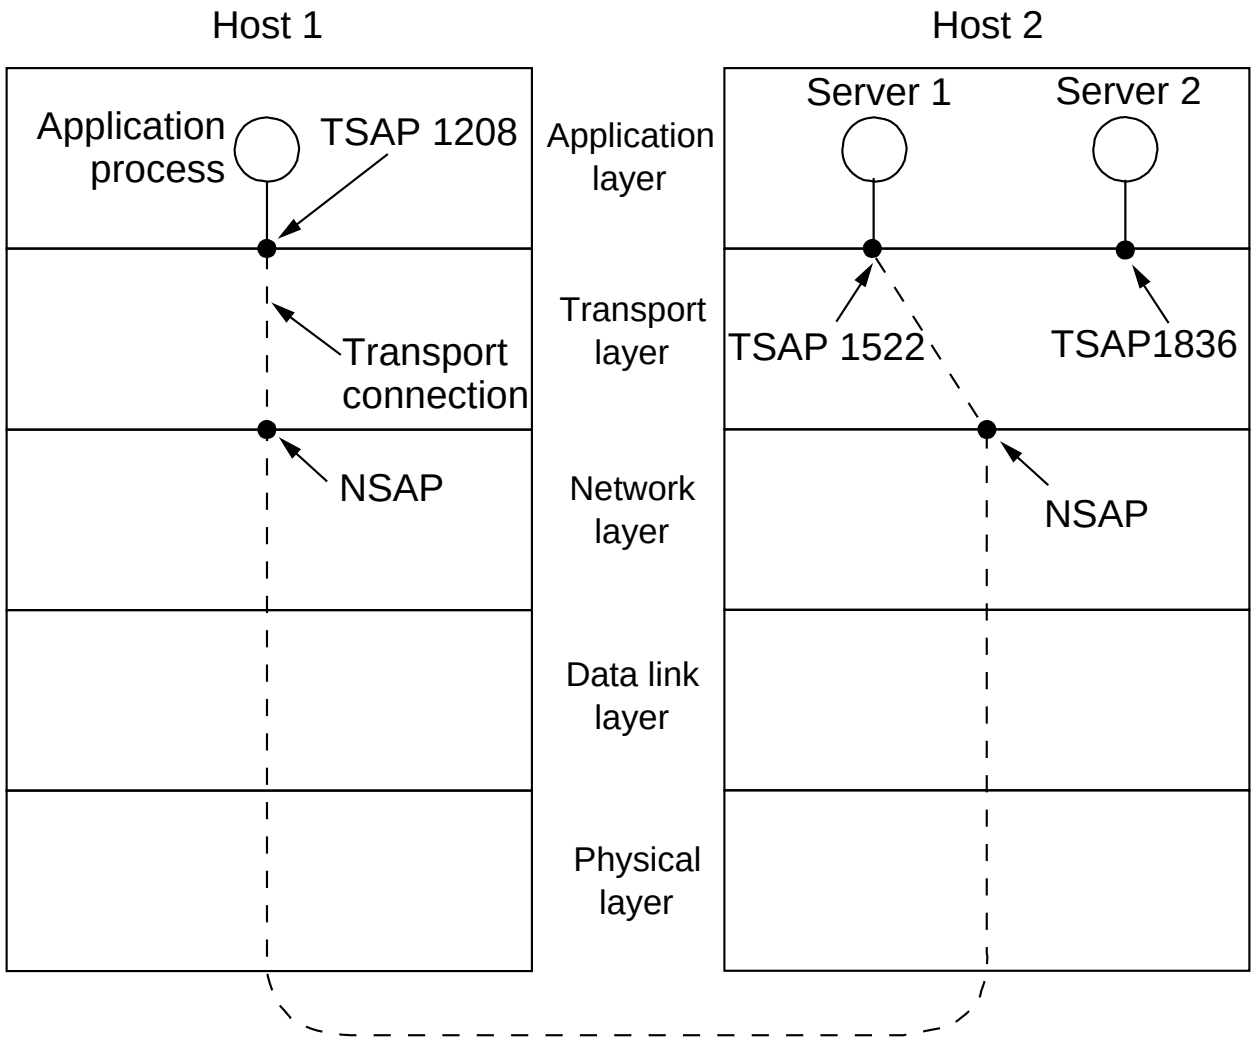

# ARES : plan du cours 3/5

# UDP

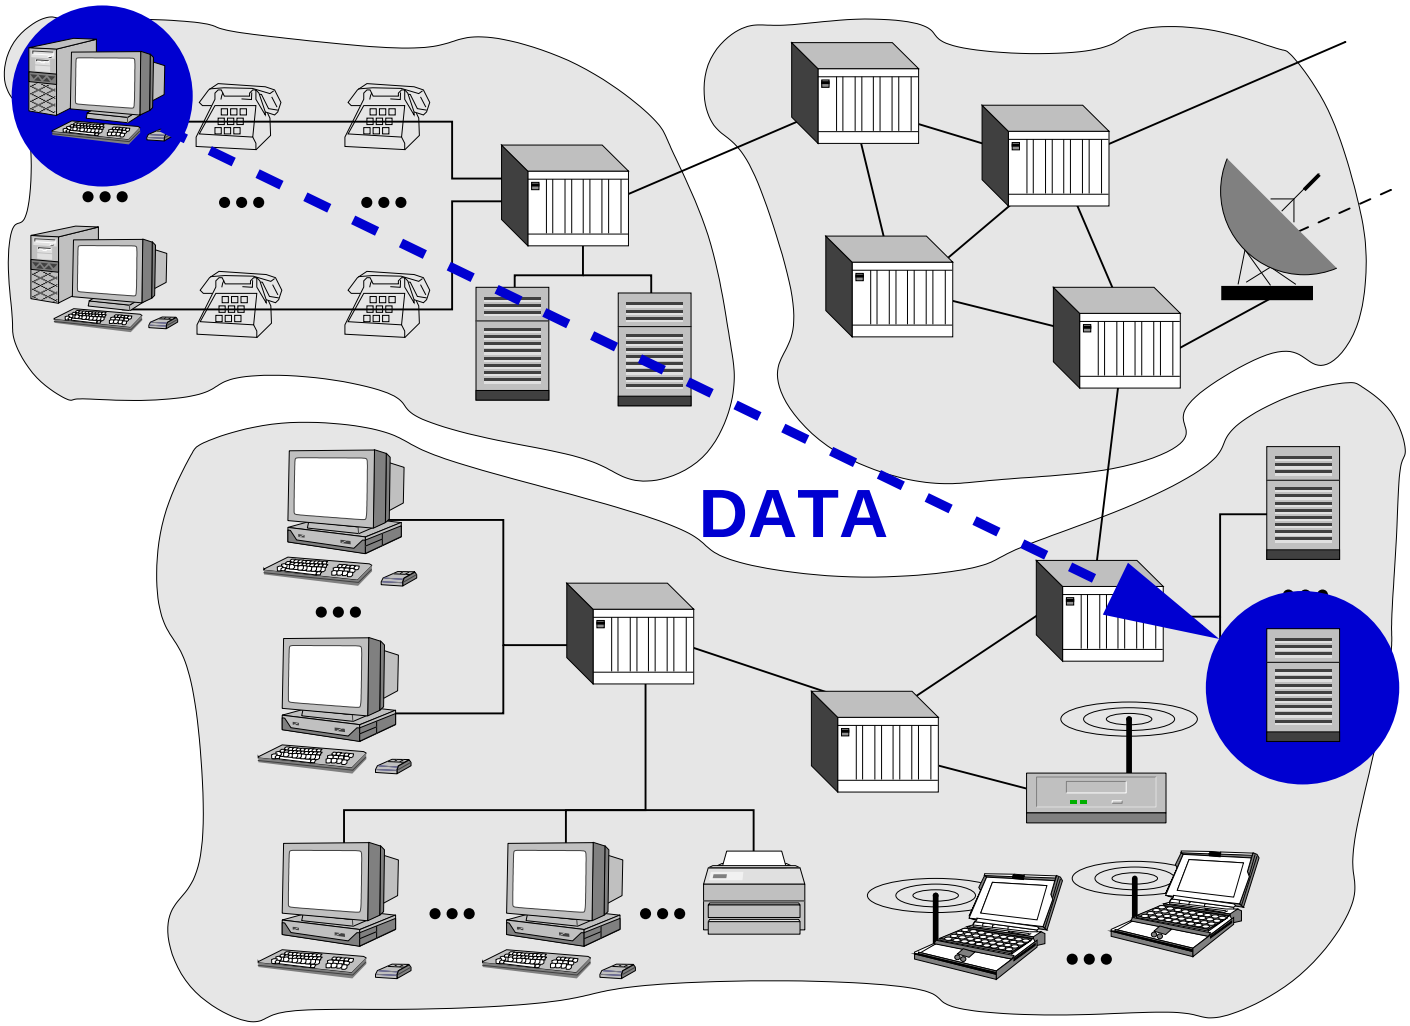

# UDP

*User Datagram Protocol* [RFC 768]

- protocole de transport Internet basique (sans fioriture)
- service *best effort* :
  - les datagrammes transférés peuvent être...
    - perdus
    - dupliqués
    - désordonnés
- service sans connexion :
  - pas d'échange préalable
  - pas d'information d'état aux extrémités
    - chaque datagramme géré indépendamment

# Datagramme UDP

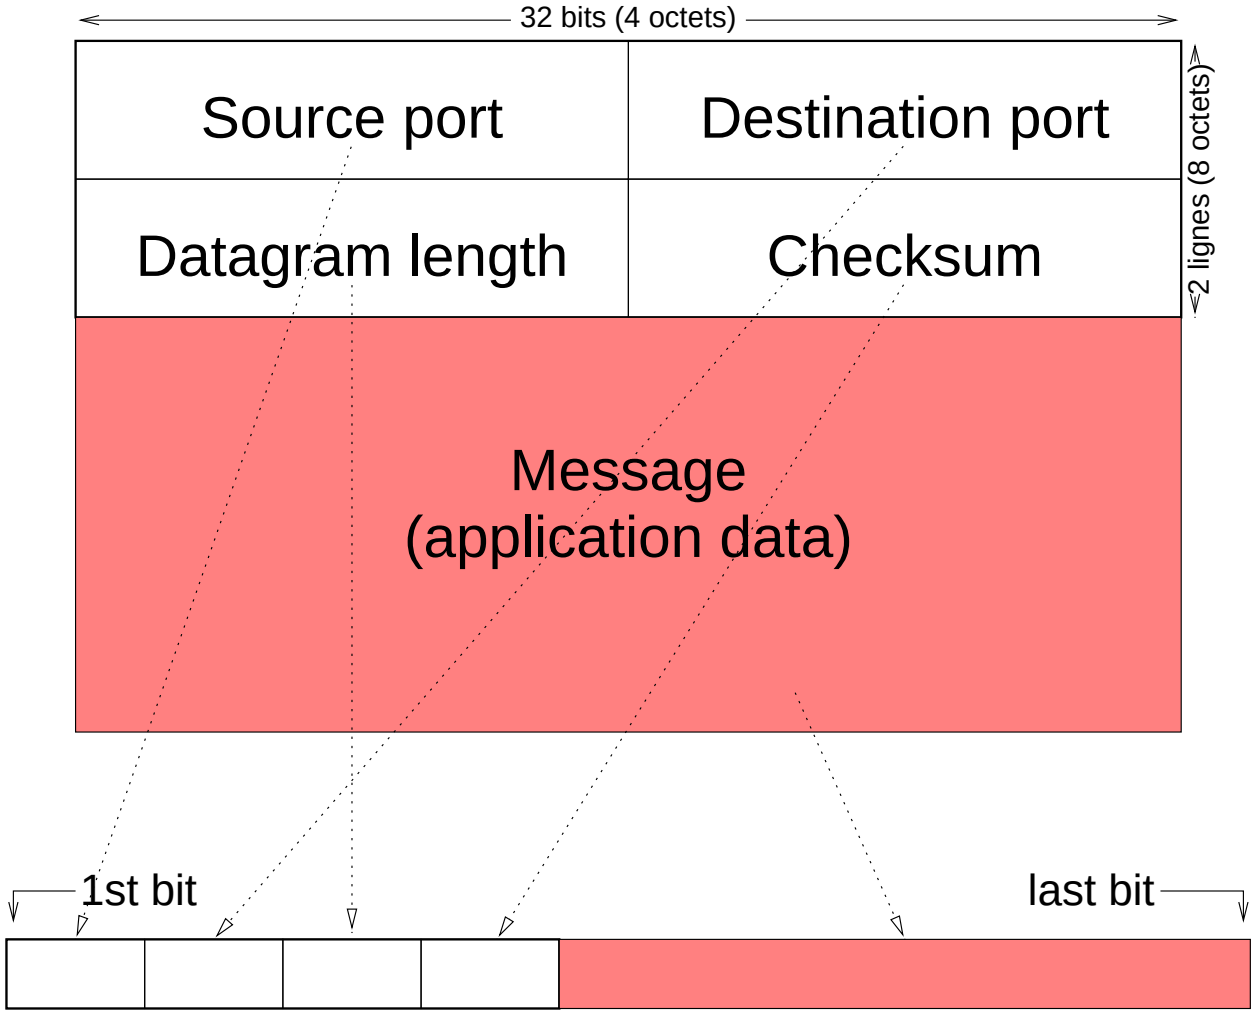

# UDP : port source

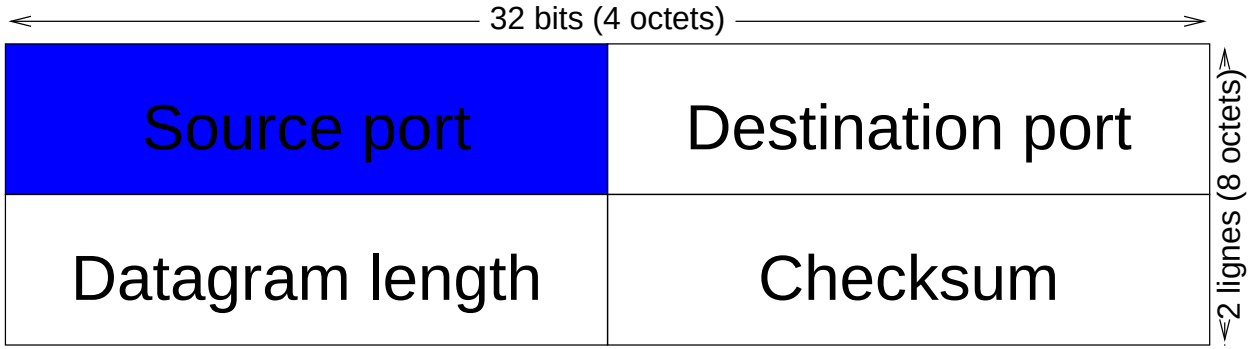


- 16 bits (65535 ports)
- **multiplexage** à la source
- identification du socket pour un retour potentiel
- allocation fixe ou dynamique (généralement dans le cas d'un client)
- répartition de l'espace des ports :
  - $0 \leq$ `numPort` $\leq 1023$ : accessible à l'administrateur
    - socket serveurs (généralement)
  - $1024 \leq$ `numPort` : accessible aux utilisateurs
    - socket clients (généralement)

# UDP : port destination

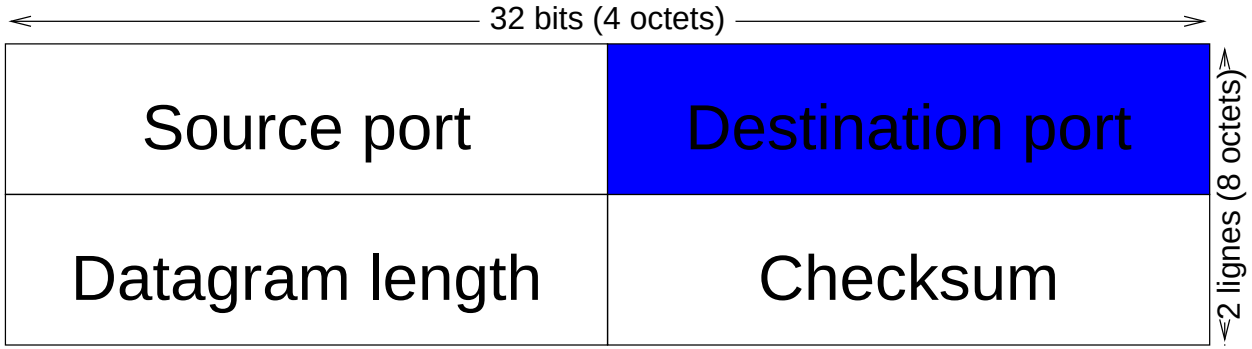


- 16 bits (65535 ports)
- **démultiplexage** à la destination
- le destinataire doit être à l'écoute sur ce port
- négociation du port ou *well-known ports* (port réservés) :

```
Unix> cat \etc\services |grep udp
echo            7/udp
discard         9/udp
daytime         13/udp
chargen         19/udp
ssh             22/udp
time            37/udp   ..
domain          53/udp
tftp            69/udp
gopher          70/udp
www             80/udp
kerberos        88/udp
snmp            161/udp
snmp-trap       162/udp  ..
```

# UDP : longueur du datagramme

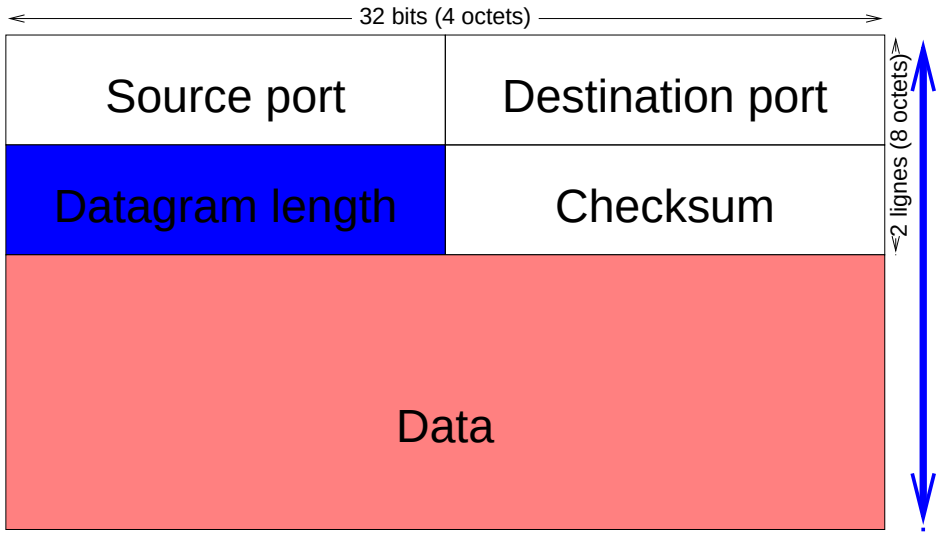


- 16 bits (64 Koctets maximum)
- longueur totale avec les données exprimée en **octets**

# UDP : contrôle d'erreur

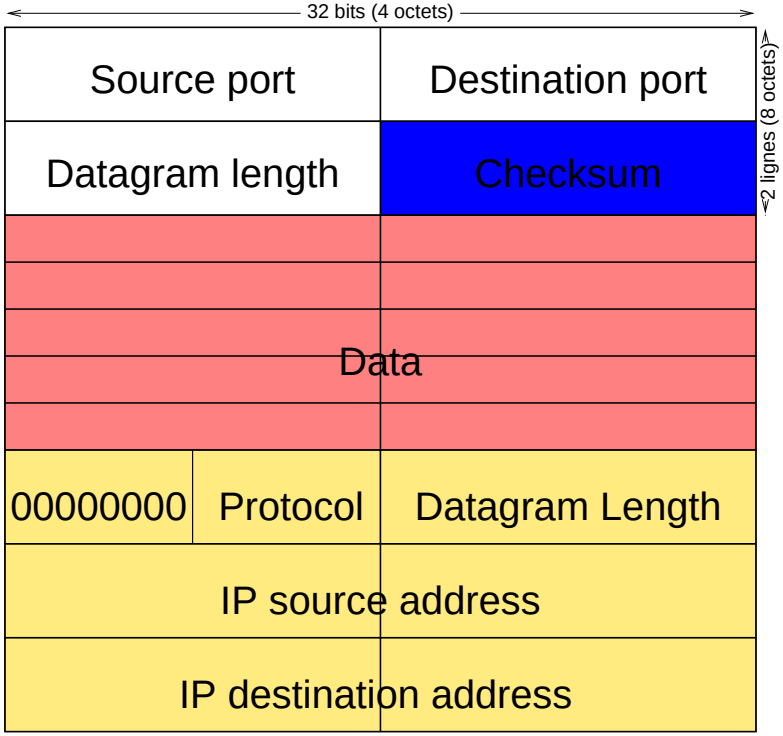


- 16 bits
- contrôle d'erreur **facultatif**
- émetteur :
  - ajout *pseudo-header*
  - $checksum^a = \overline{\sum mot_{16\text{bits}}}$
- récepteur :
  - ajout *pseudo-header*
  - recalcul de $\sum mot_{16\text{bits}}$
    - $= 0$ : pas d'erreur détectée toujours possible...
    - $\neq 0$ : erreur (destruction silencieuse)

[a] Somme binaire sur 16 bits avec report de la retenue débordante ajoutée au bit de poid faible

# UDP : arguments pour un transport sans connexion

Motivation pour le choix d'un service transport non connecté :

- ressources limitées aux extrémités
  - pile TCP/IP limitée
  - absence d'**état** dans les hôtes
  - capacité de traitement limitée
- besoin d'échange rapide
  - pas d'**établissement** de connexion
- besoin d'efficacité
  - **entête réduit**
- contraintes temporelles
  - **retransmission** inadapté
  - pas de **contrôle** du débit d'émission
- besoin de nouvelles fonctionnalités
  - remontés dans la couche application...

# UDP : exemples d'applications

- applications classiques :
  - résolution de noms (DNS)
  - administration du réseau (SNMP)
  - protocole de routage (RIP)
  - protocole de synchronisation d'horloge (NTP)
  - serveur de fichiers distants (NFS)
    - fiabilisation implicite par redondance temporelle
    - fiabilisation explicte par des mécanismes ajoutés dans la couche application
- applications *multicast* ➠ U.E. **ING**
- applications multimédia ➠ U.E. **MMQOS**
  - diffusion multimédia, *streaming* audio ou vidéo
  - téléphonie sur Internet
  - visioconférence
    - contraintes temporelles
    - tolérance aux pertes

# UDP : interface socket

```
#include <sys/types.h>
#include <sys/socket.h>

# Create a descriptor
int socket(int domain, int type, int protocol);
#   domain : PF_INET for IPv4 Internet Protocols
#     type : SOCK_DGRAM Supports datagrams (connectionless, unreliable msg of a fixed max length)
# protocol : UDP (/etc/protocols)

# Bind local IP and port
int bind(int s, struct sockaddr *my_addr, socklen_t addrlen);

# Send an outgoing datagram to a destination address
int sendto(int s, const void *msg, size_t len, int flags,
                                        const struct sockaddr *to, socklen_t tolen);

# Receive the next incoming datagram and record is source address
int recvfrom(int s, void *buf, size_t len, int flags,
                                        struct sockaddr *from, socklen_t *fromlen);

# End : dealocate
int close(int s);
```

# ARES : plan du cours 3/5

# Couche transport et fiabilité (1)

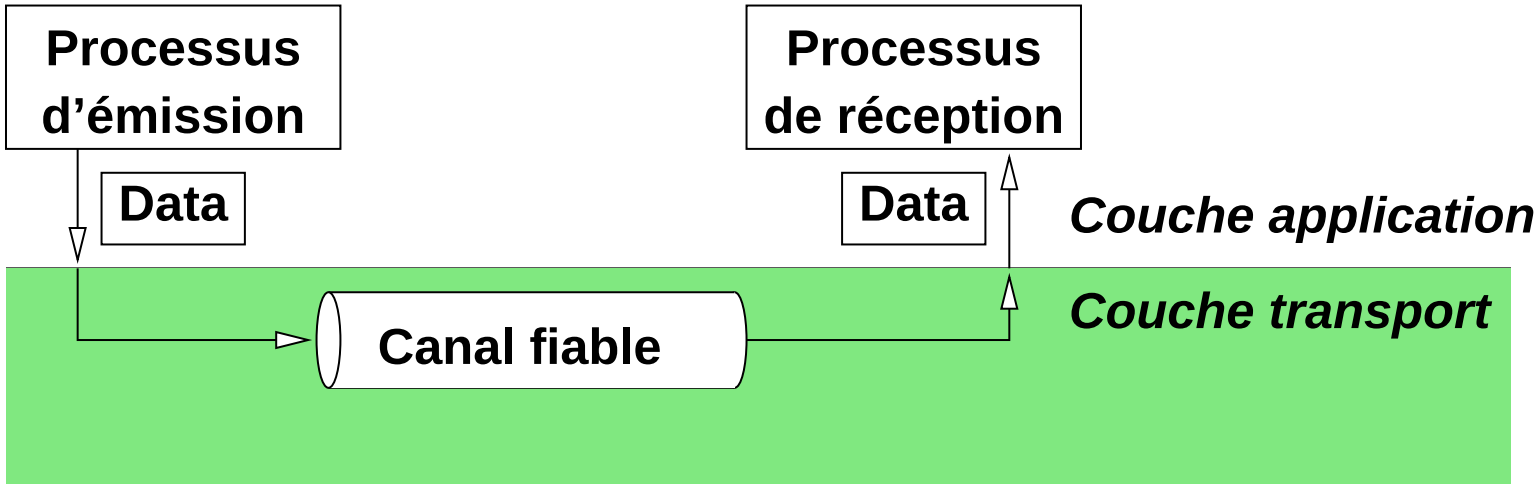


Problématique multi-couche :

- couche application
- couche transport
- couche liaison

# Couche transport et fiabilité (2)

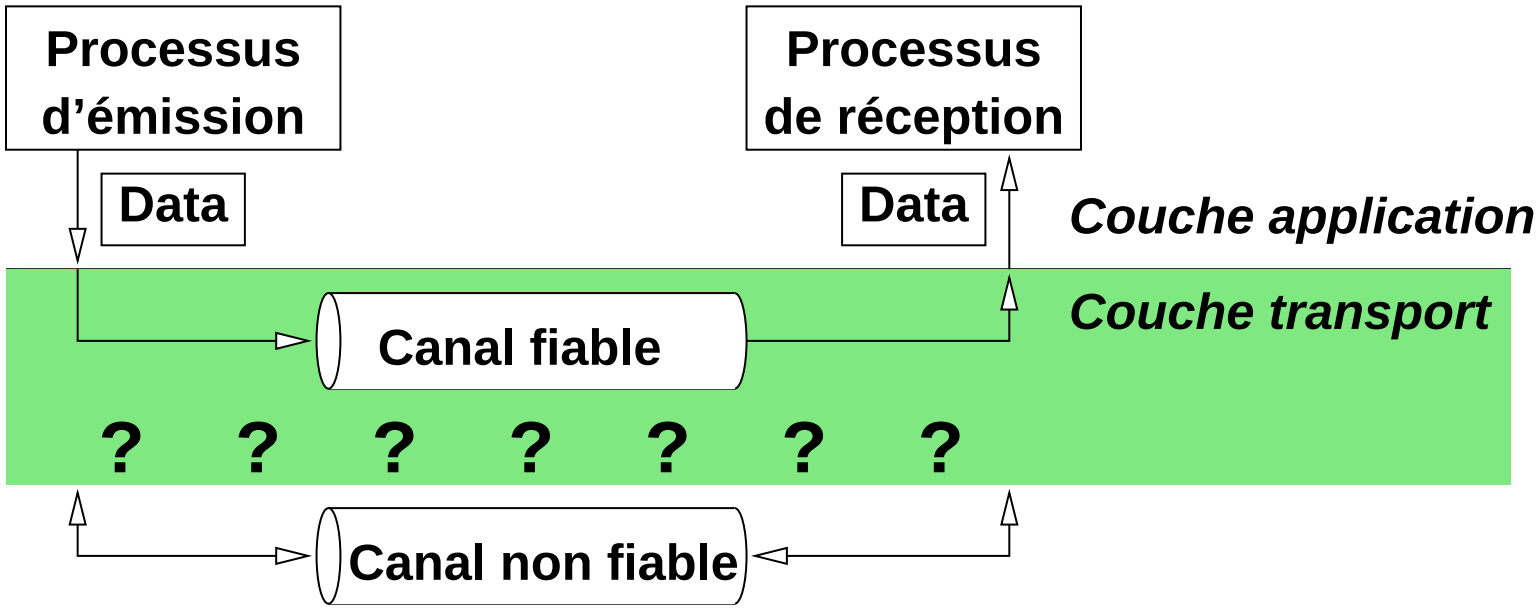


Les caractéristiques du **canal non fiable** déterminent la complexité du **protocol de transfert fiable** (PTF).

# Couche transport et fiabilité (3)

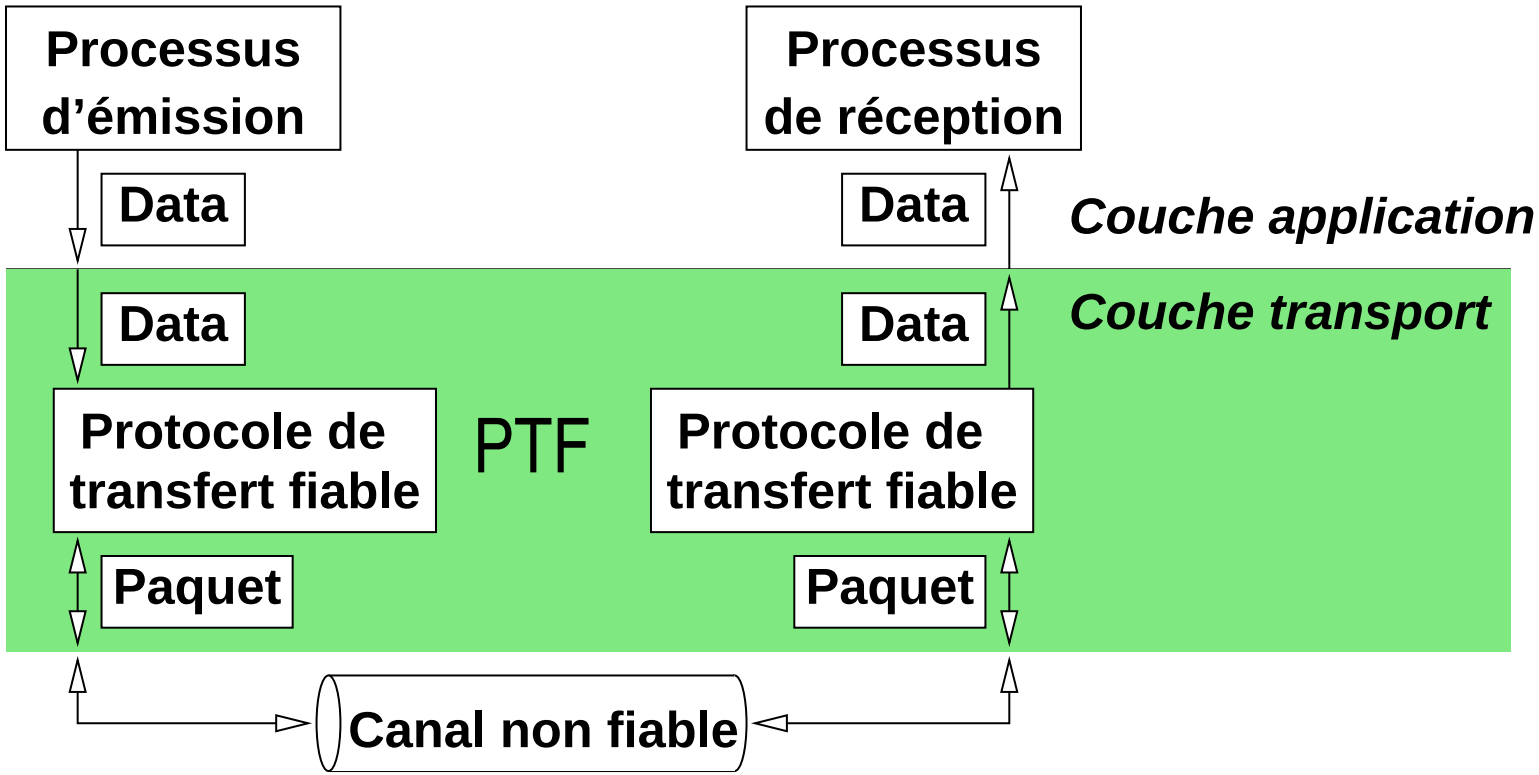

# Protocole de Transfert Fiable (PTF)

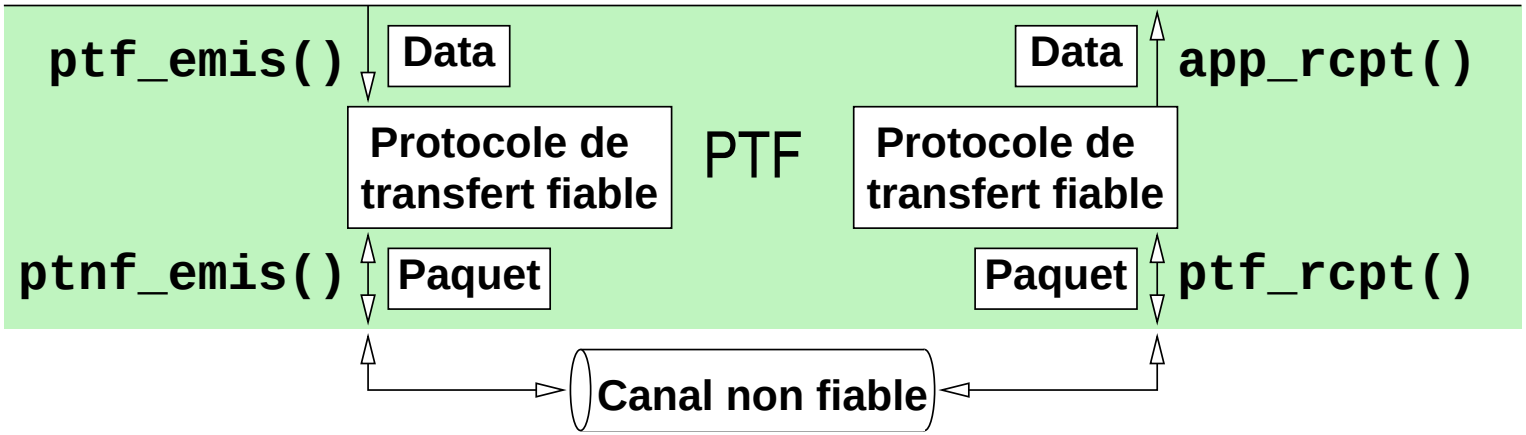


Primitives de base du PTF :

- `ptf_emis()` : appelée par la couche supérieure (application) pour envoyer des données à la couche correspondante du récepteur
- `ptfn_emis()` : appelée par le PTF transférer un paquet sur le canal non fiable vers le récepteur
- `ptf_rcpt()` : appelée lorqu'un paquet arrive au récepteur
- `app_rcpt()` : appelée par le PTF pour livrer les données

# PTF et AEF

Nous allons construire progressivement le **PTF**

- transfert de données dans un seul sens
  - information de contrôle dans les 2 directions
- spécification de l'émetteur et du récepteur par des Automates à Etats Finis (AEF) :

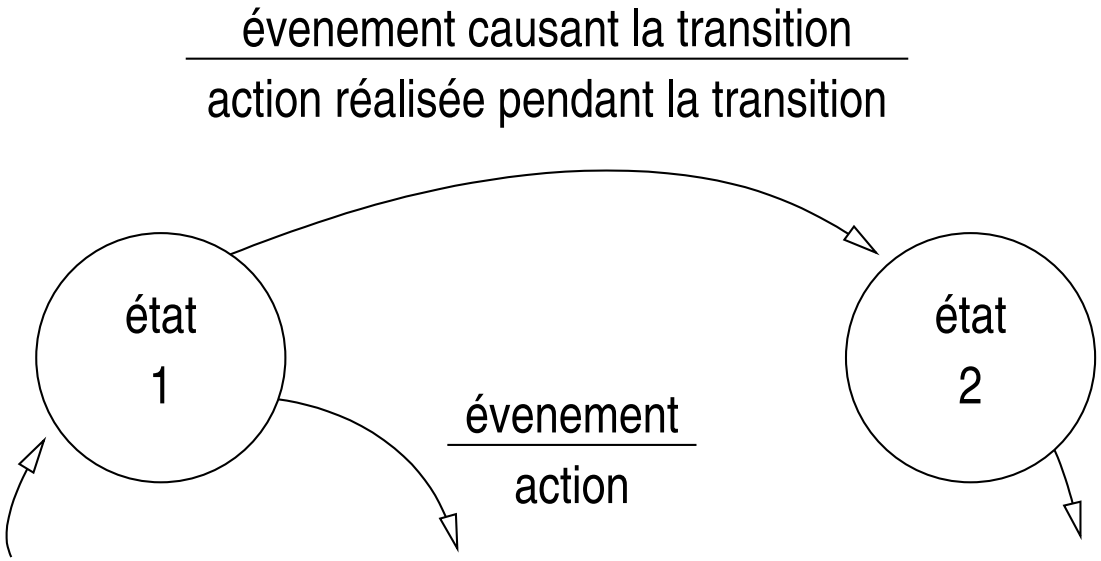

# PTF v1.0

Transfert fiable sur un canal sans erreur

- canal sous-jacent complètement fiable
  - pas de bits en erreur
  - pas de perte de paquets
- automates séparés pour l'émetteur et le récepteur :

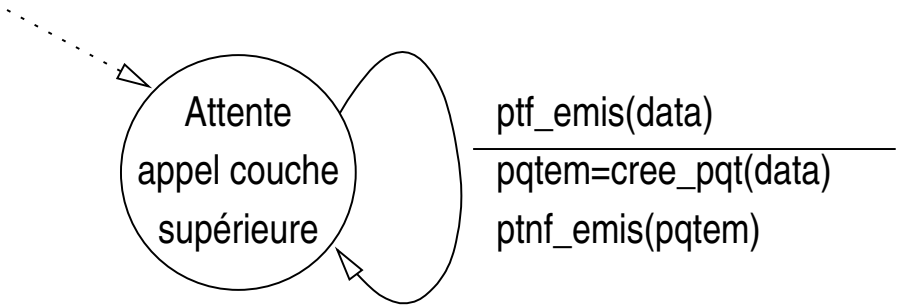


*émetteur*

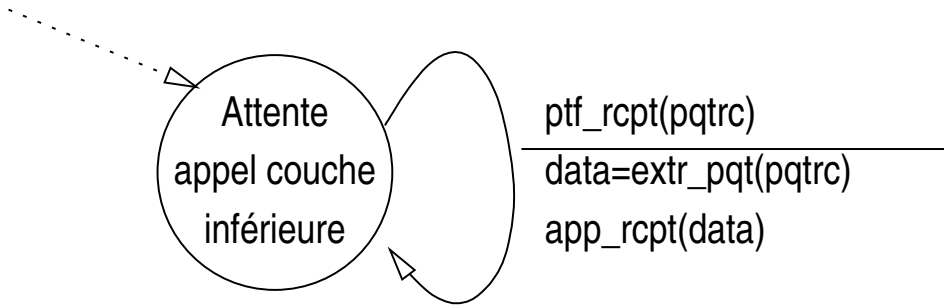


*récepteur*

# PTF v2.0

Transfert fiable sur un **canal avec des erreurs**

- canal sous-jacent pouvant changer la valeur des bits d'un paquet
  - introduction de contrôle d'erreur :
    - `ctrlerr` : redondance rajoutée au paquet
- *Comment récupérer les erreurs ?*
  - **acquittement** (ACK) : le récepteur indique explicitement la réception correcte d'un paquet
  - **acquittement négatif** (NAK) : le récepteur indique explicitement la réception incorrecte d'un paquet
    - l'émetteur ré-émet le paquet sur réception d'un NAK
- nouveau mécanisme dans PTF v2.0 :
  - détection d'erreur
    - `valide(pqt)` : vrai si le contrôle d'erreur de `pqt` est correct
    - `erreur(pqt)` : vrai si le contrôle d'erreur de `pqt` est incorrect
  - retour d'information *(feedback)* du récepteur (ACK et NAK)

# PTF v2.0

Transfert fiable sur un **canal avec des erreurs** :

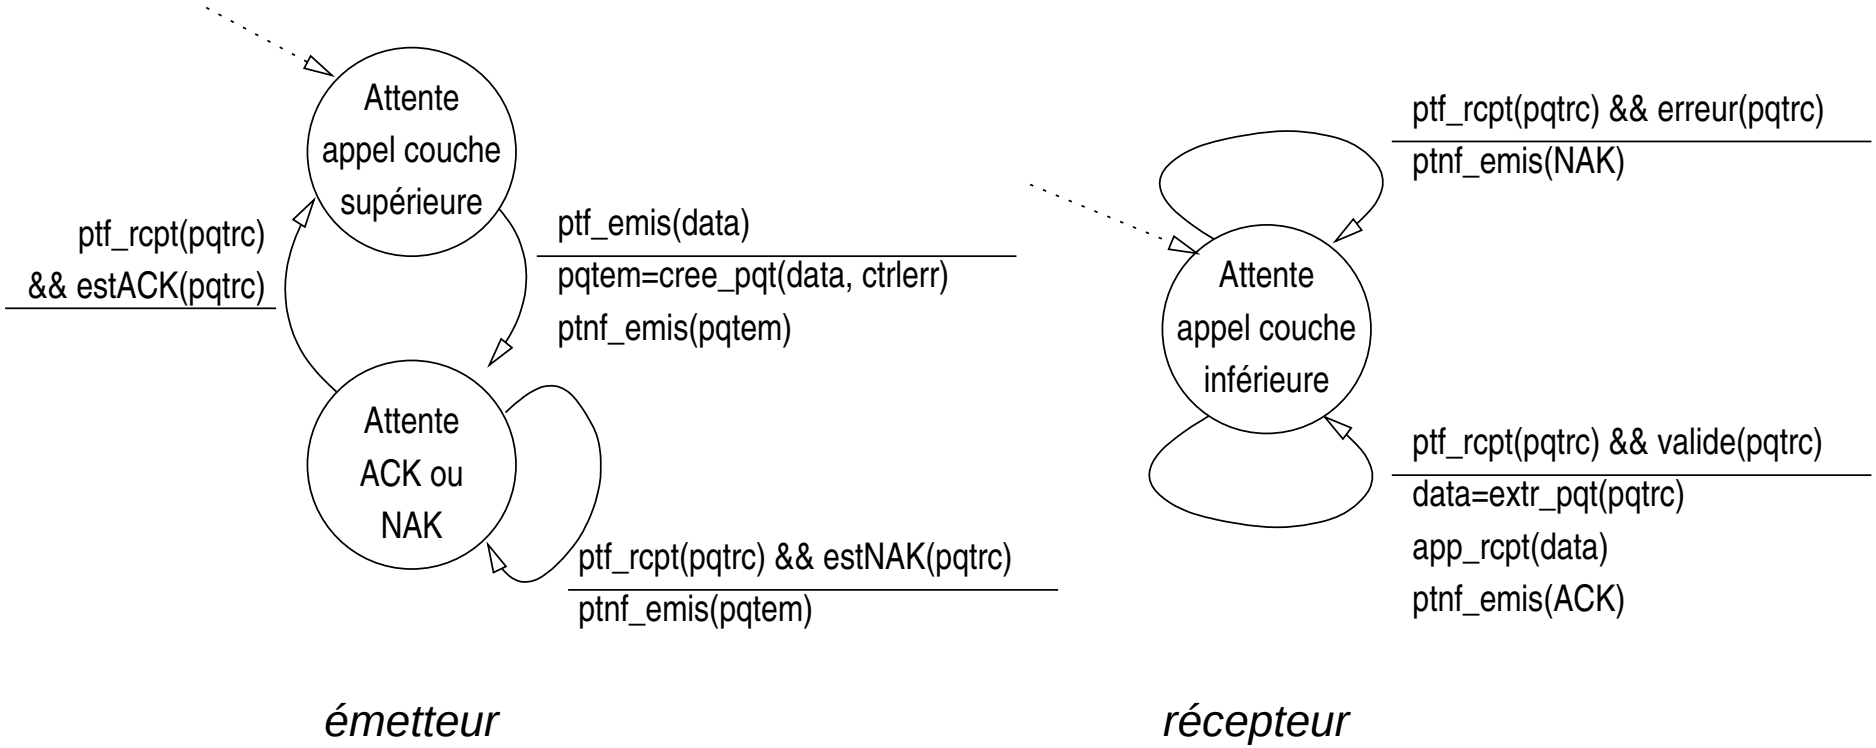

# PTF v2.0 : ACK

Transfert fiable lorsqu'il n'y a pas d'erreur :

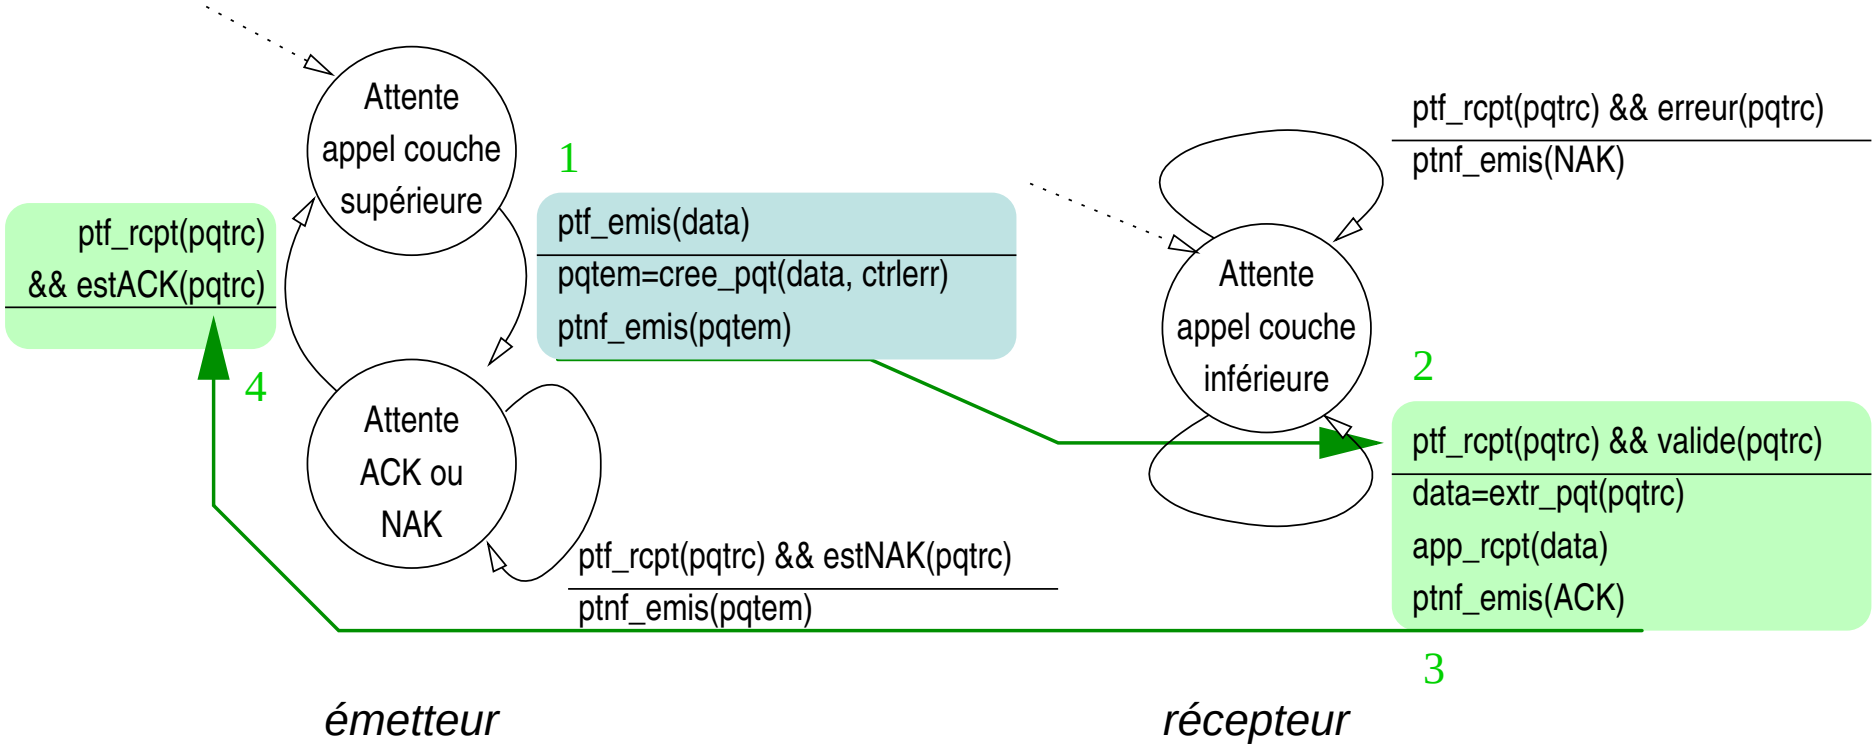

# PTF v2.0 : NAK

Transfert fiable lorsqu ?il y a une erreur :

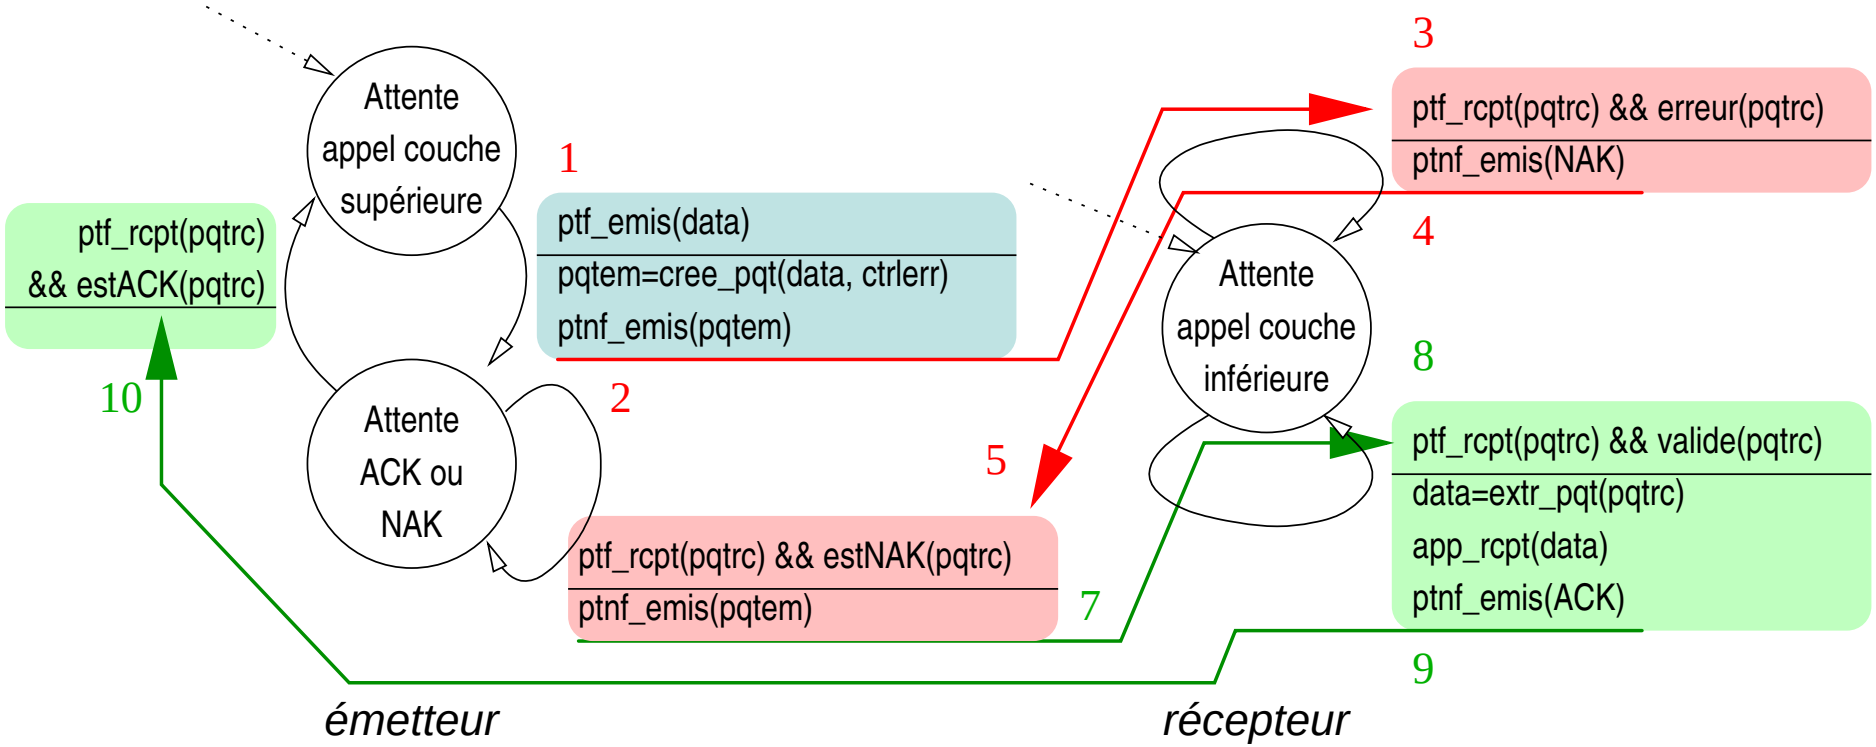

# PTF v2.0 : discussion

PTF v2.0 est un protocole *stop and wait* :

- émetteur envoi un paquet et attend la réponse du récepteur
- peu performant...

PTF v2.0 à un défaut majeur !

- *Que se passe-t-il si les ACK ou NAK sont incorrect ?*
  - pas d'information sur l'état du récepteur
  - une retransmission simple risque de dupliquer les données
- gestion des duplicats :
  - émetteur **retransmet** le paquet courant si ACK/NAK incorrect
  - émetteur insert un **numéro** de séquence à chaque paquet
  - récepteur **supprime** les paquets dupliqués
    - inclu dans **PTF v2.1**

# PTF v2.1 : émetteur

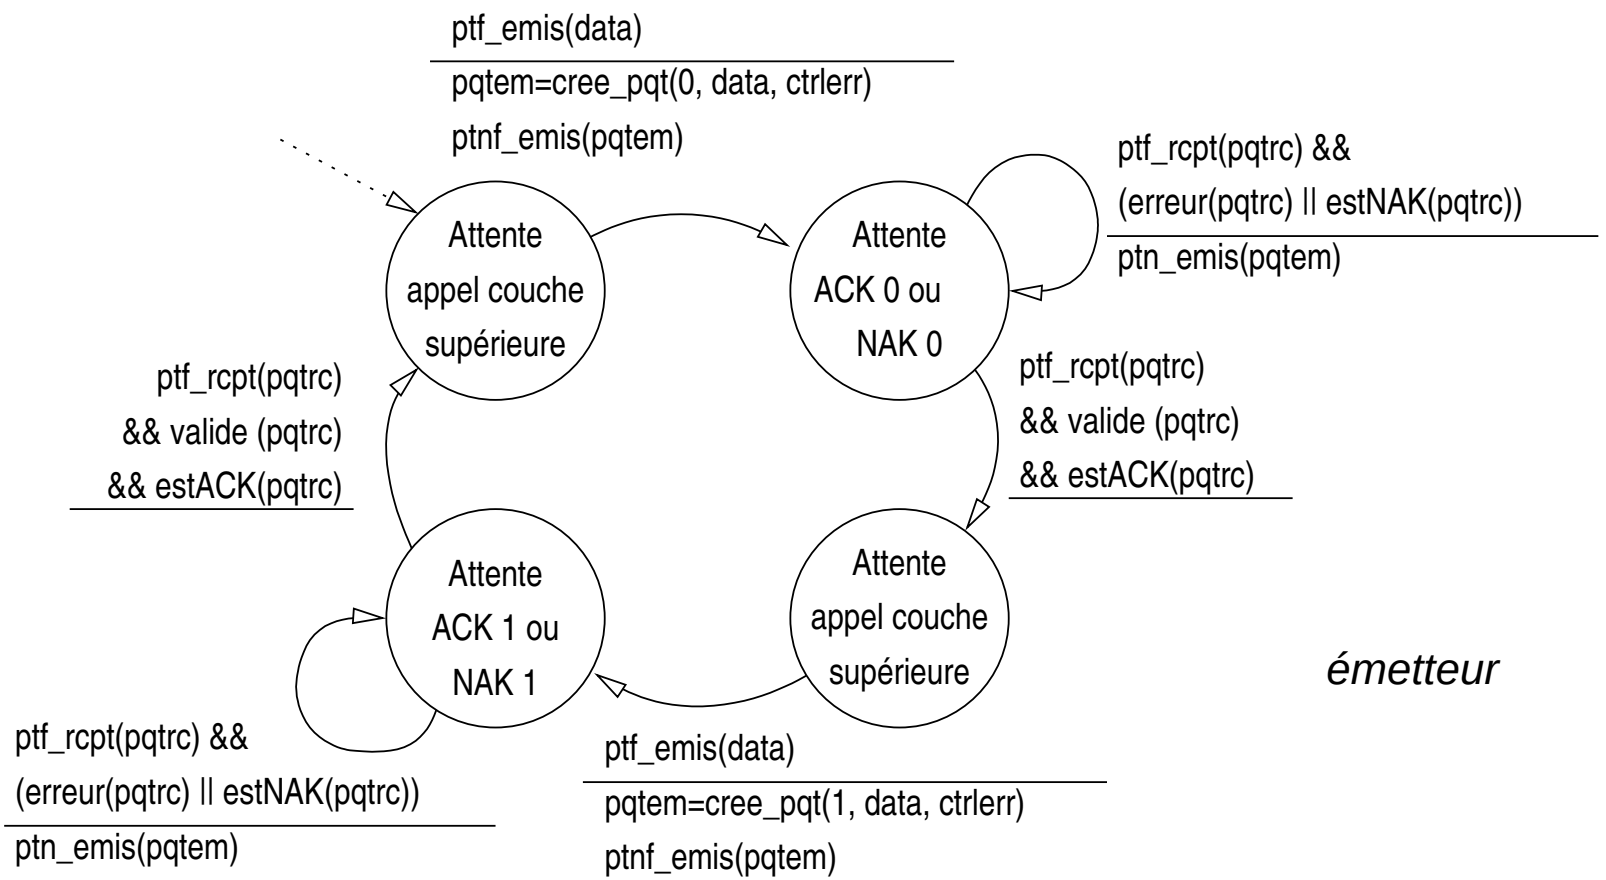


*émetteur*

# PTF v2.1 : récepteur

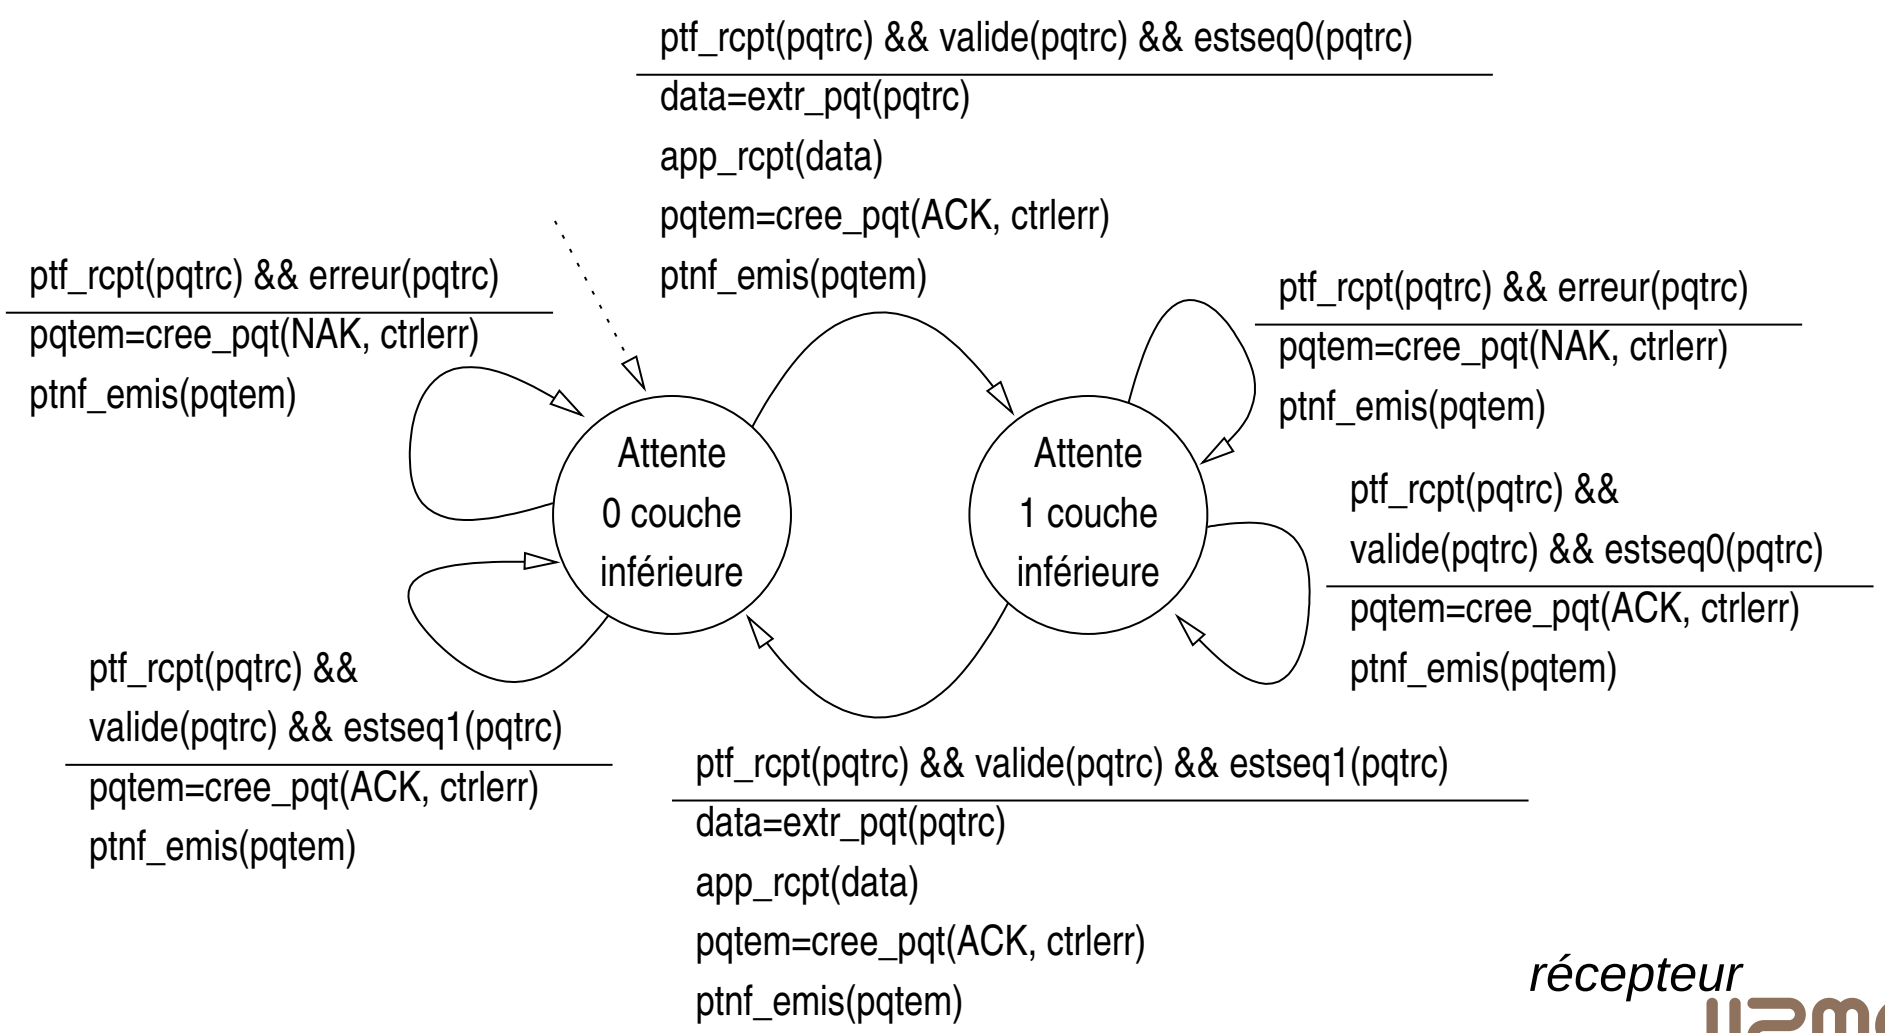


*récepteur*

# PTF v2.1 : discussion

Comportement des extrémités avec PFT v2.1

- **émetteur**
  - ajout de numéro de séquence à chaque paquet
    - 2 suffisent (0 et 1)
  - contrôle d'erreur sur les ACK et NAK
  - 2 fois plus d'états
- **récepteur**
  - vérification que le paquet n'est pas dupliqué
    - l'état où l'on se trouve indique le numéro de séquence attendu

*Peut-on éliminer les NAK ?*

- remplacement des NAK par **ACK du dernier paquet** valide reçu
  - récepteur inclue le numéro de séquence correspondant dans le ACK
  - ACK dupliqué au récepteur = NAK reçu au récepteur
    - intégré dans **PFT v2.2**

# PTF v2.2 : émetteur

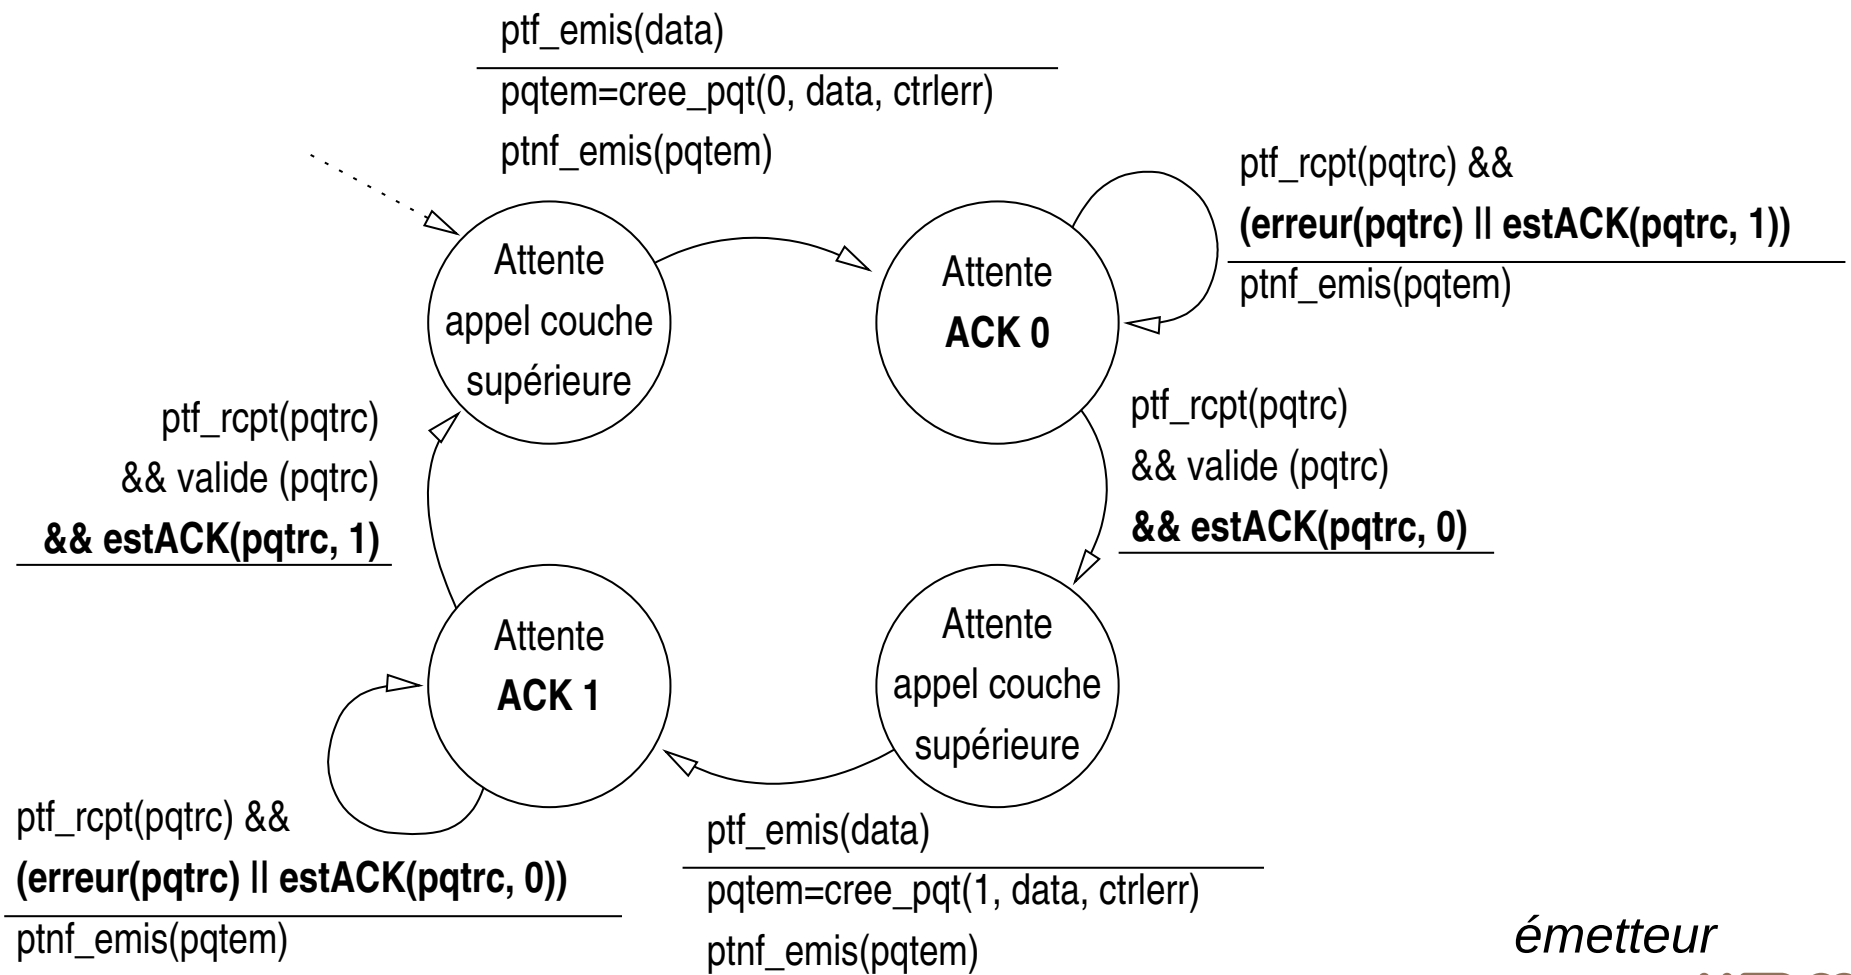


*émetteur*

# PTF v2.2 : récepteur

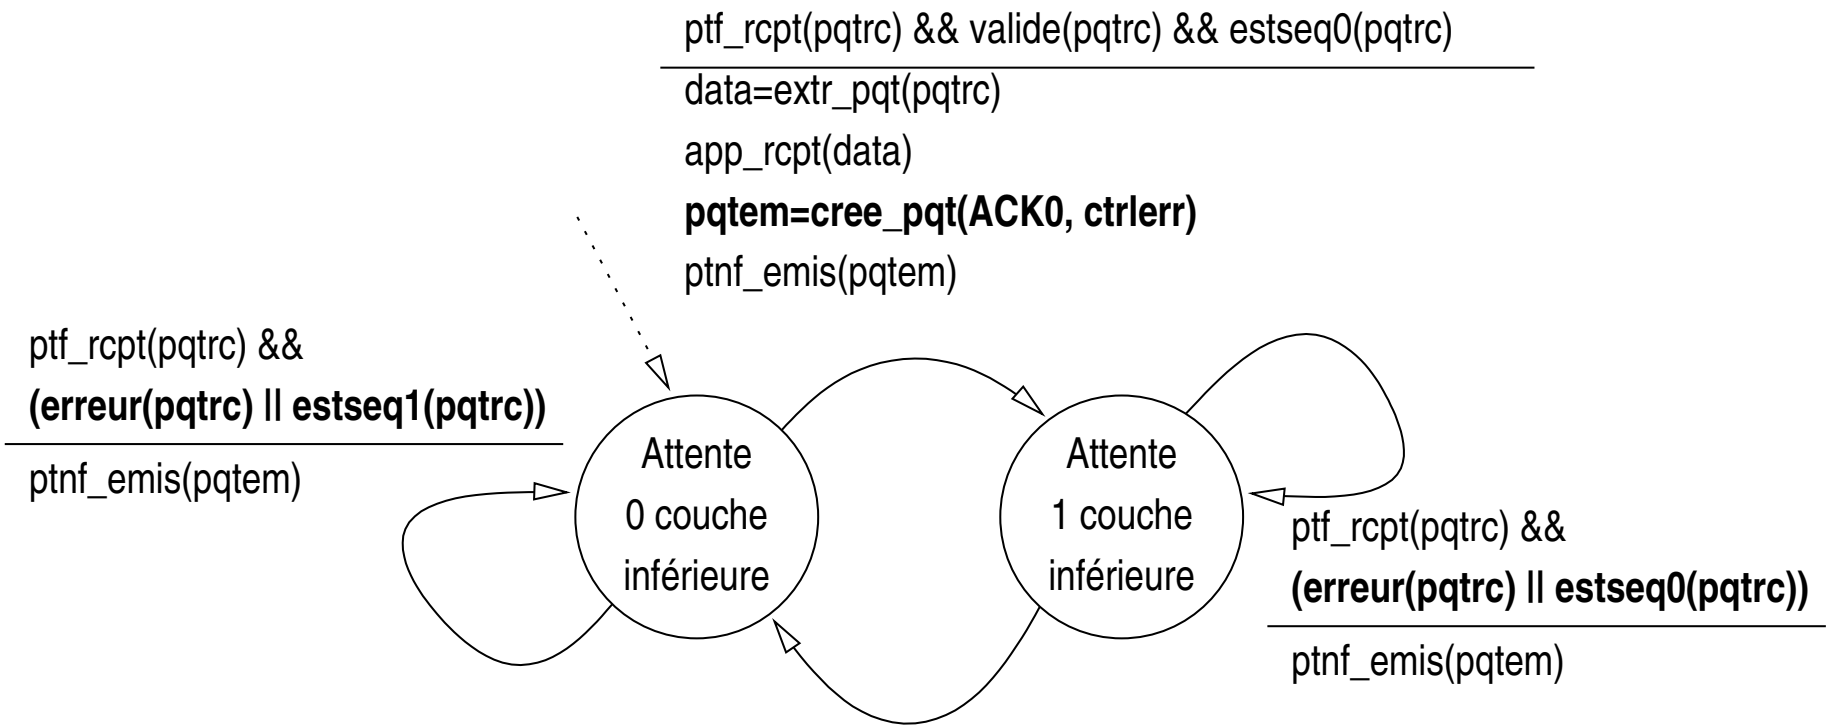


*récepteur*

# PTF v3.0

Transfert fiable sur un **canal avec erreurs et pertes**

- canal sous-jacent peut aussi perdre des paquets (data ou ACK)
  - `ctrlerr` + `numSeq` + ACK + retransmission
    - insuffisant : l'absence d'un paquet bloque l'automate !

**Temporisation des retransmission**

- estimation d'un temps de retour de ACK raisonable
  - déclenchement d'une temporisation à l'emission d'un paquet
    - `tempo_init`
  - ACK avant l'expiration de la temporisation ➠ rien
    - `tempo_stop`
  - pas de ACK à l'expiration de la temporisation ➠ retransmission
    - `tempo_expire`
- si le ACK est seulement en retard...
  - retransmission = duplication
    - détectée grâce au numéro de séquence

# PTF v3.0 : émetteur

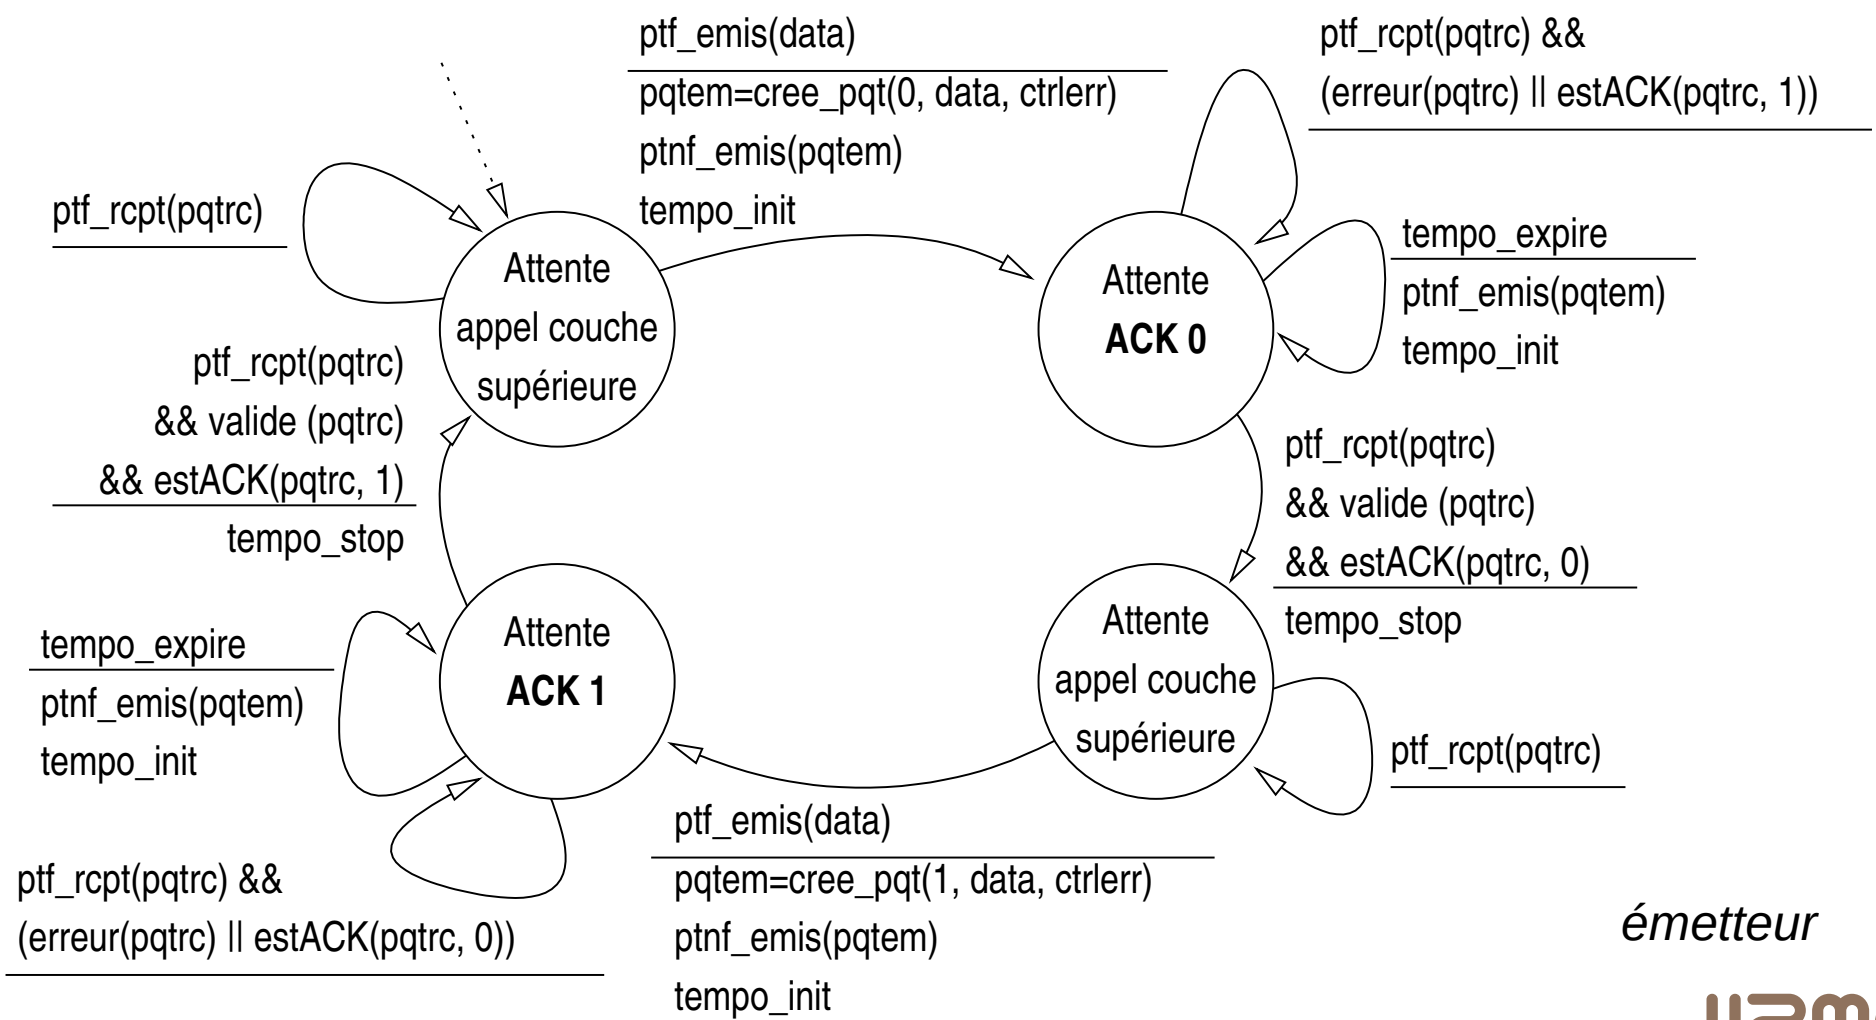


*émetteur*

# PTF v3.0 : sans perte

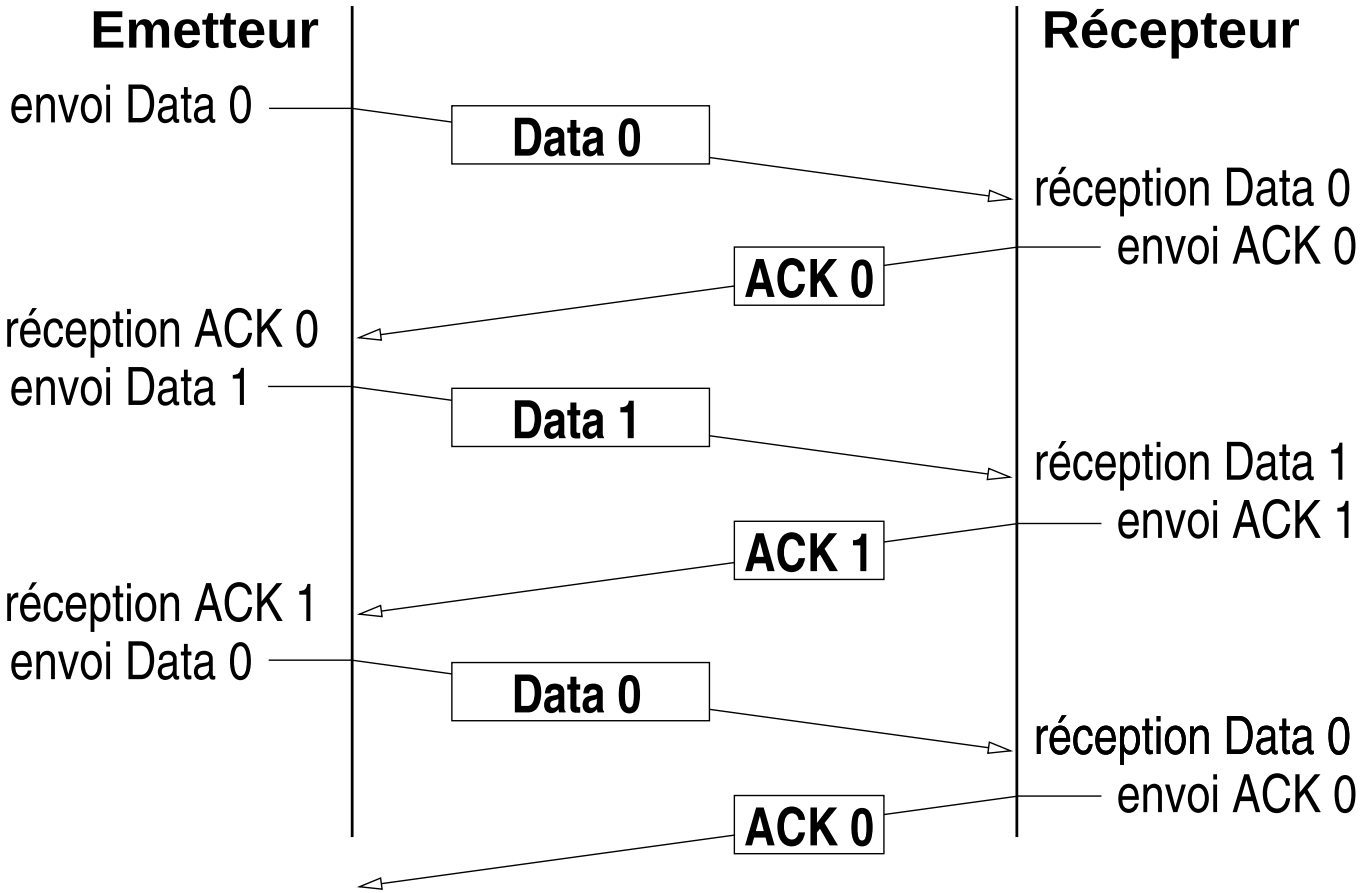

# PTF v3.0 : perte d'un paquet de données

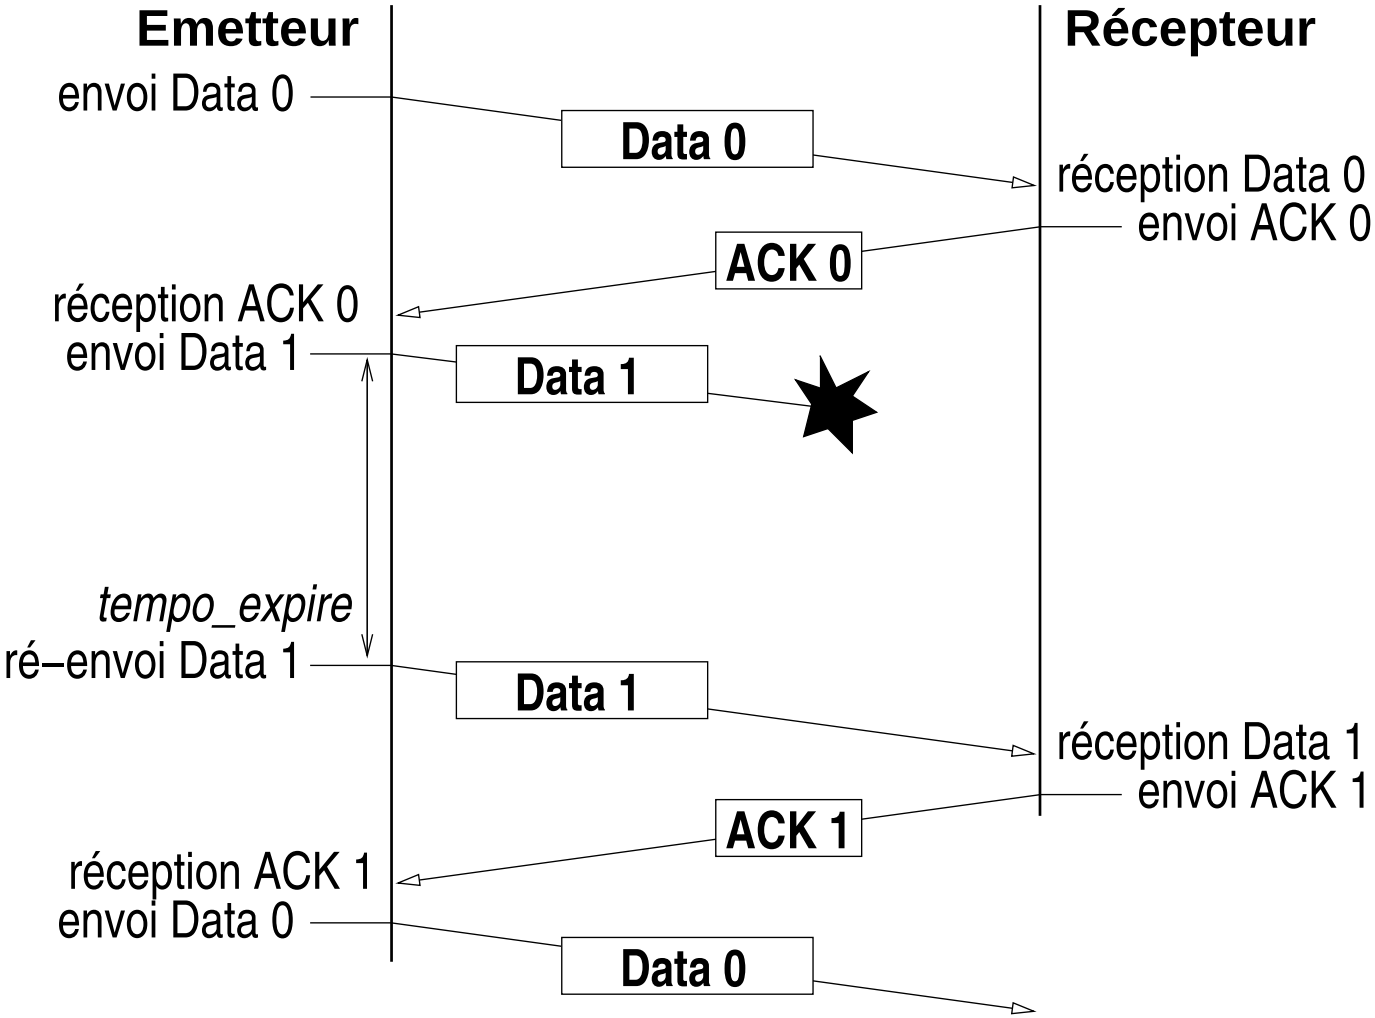

# PTF v3.0 : perte d'un ACK

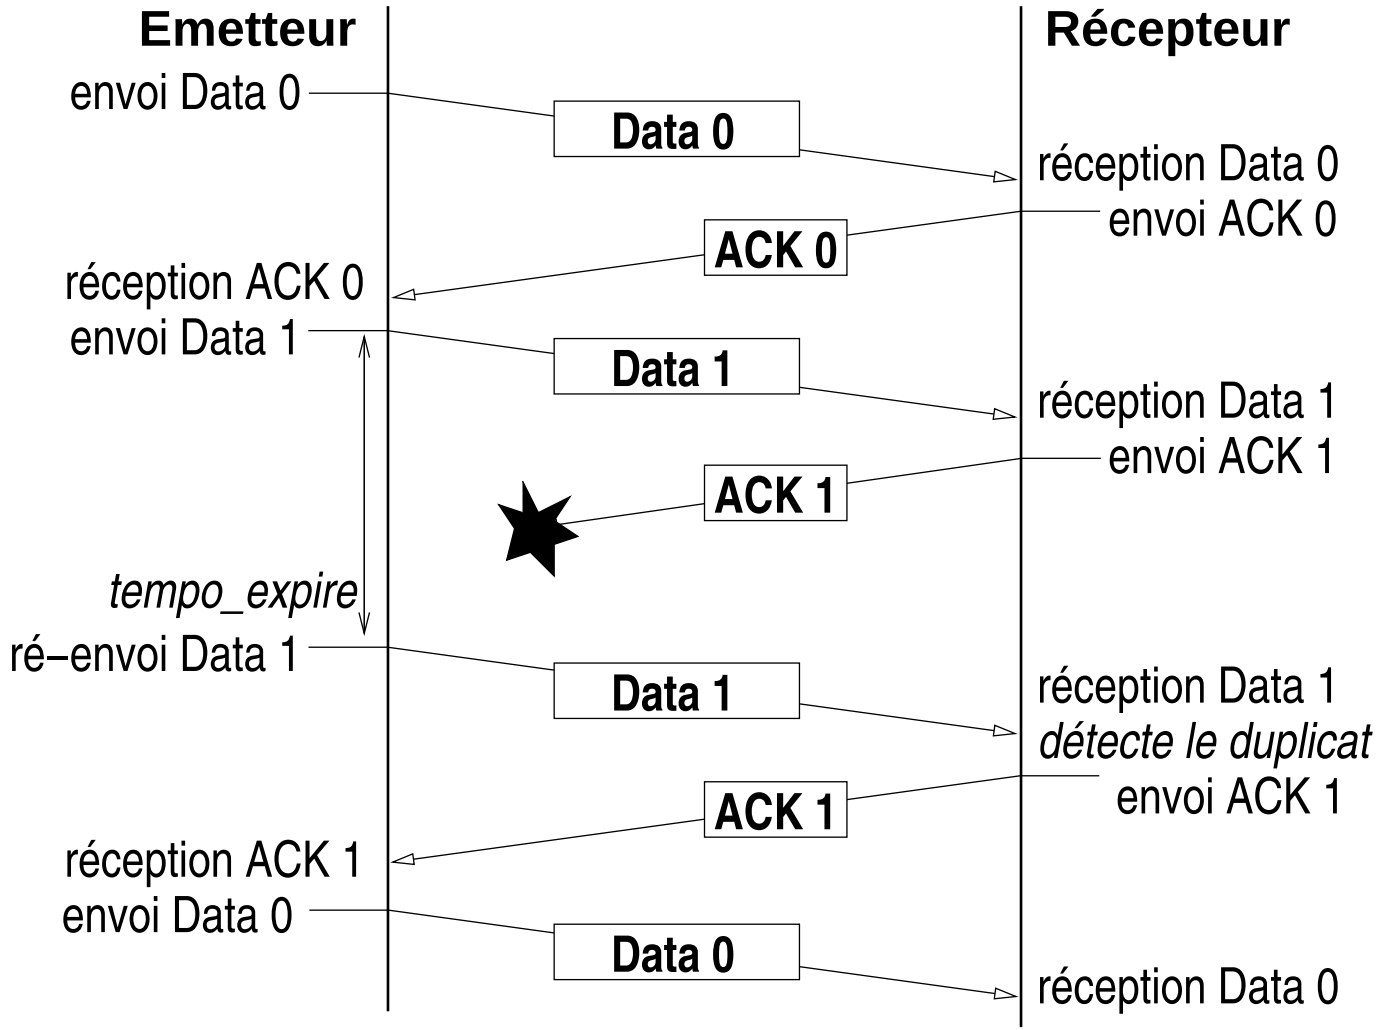

# PTF v3.0 : fin de temporisation prématurée

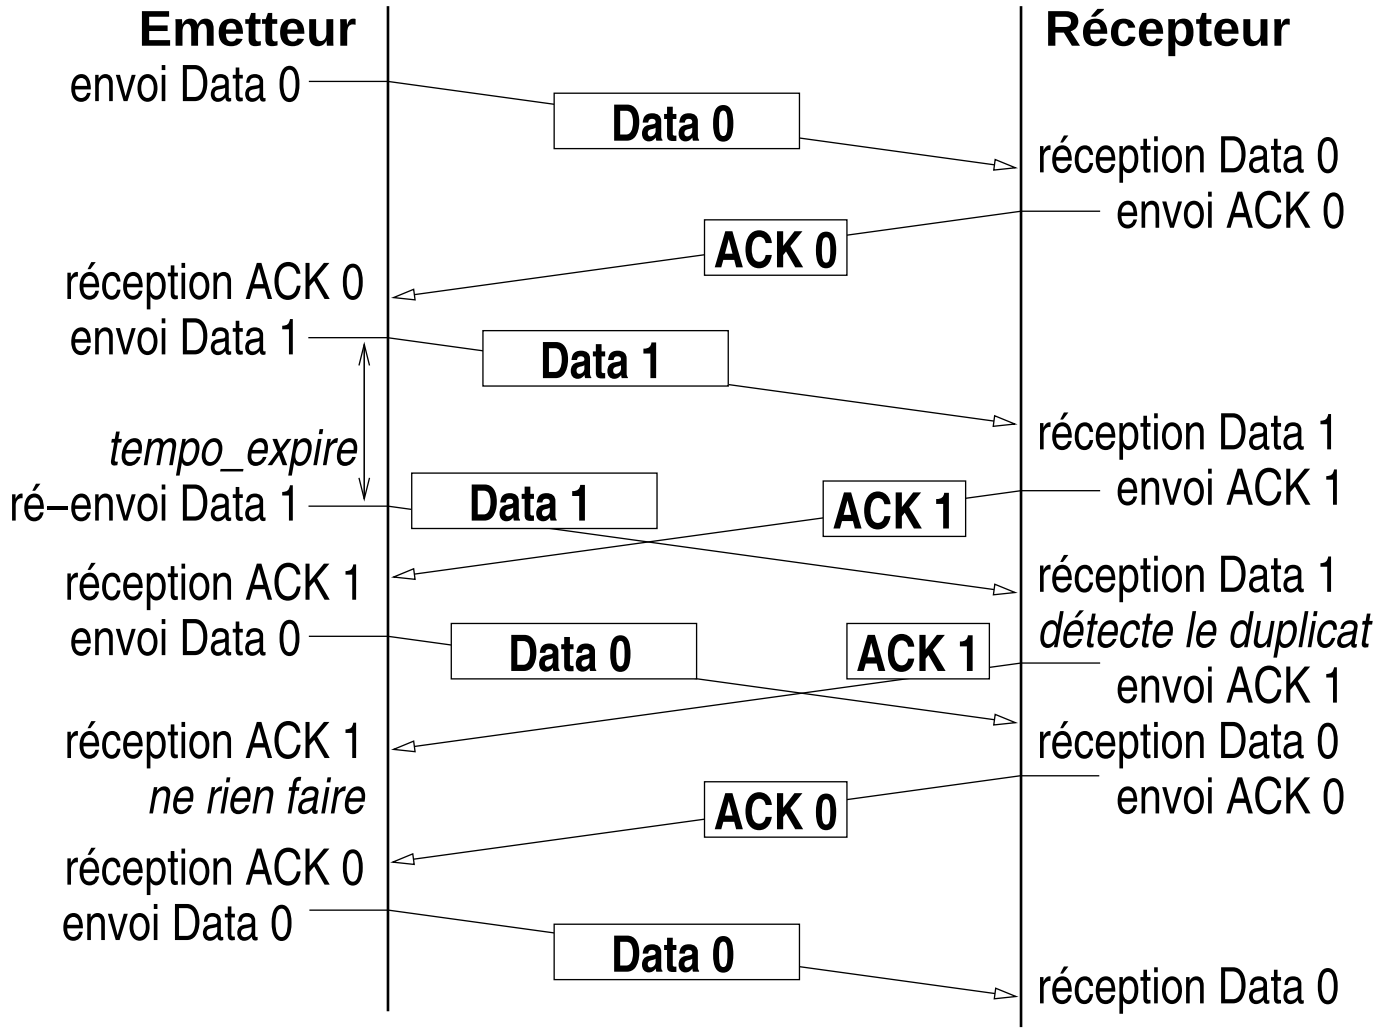

# PTF v3.0 : performance

PFT v3.0 fonctionne mais quelles sont ses performances ?

- exemple de communication :
  - débit du lien : $D_{reseau} = 1\ Gbps$,
  - délais de bout-en-bout : $d = 40\ ms$ ($d_{AR} = 80\ ms$)
  - paquets de longueur 1000 octets ($L_{paquet} = 8000\ b$)
- $T_{transmission} = L_{paquet}/D_{reseau} = 8.10^3/10^9 = 8\ \mu s$
- efficatité émetteur ($E_{emis}$) : fraction de temps en émission
  - $E_{emis} = \frac{L_{paquet}/D_{reseau}}{L_{paquet}/D_{reseau}+d_{AR}} = \frac{8.10^{-6}}{8.10^{-6}+8.10^{-2}} = \frac{1}{10000}$
  - $D_{transport} = L_{paquet}/d_{AR} = 8.10^3/8.10^{-2} = 100\ Kbps$
    - **le protocole limite l'utilisation des ressources disponibles !**

# PTF v3.0 : stop and wait

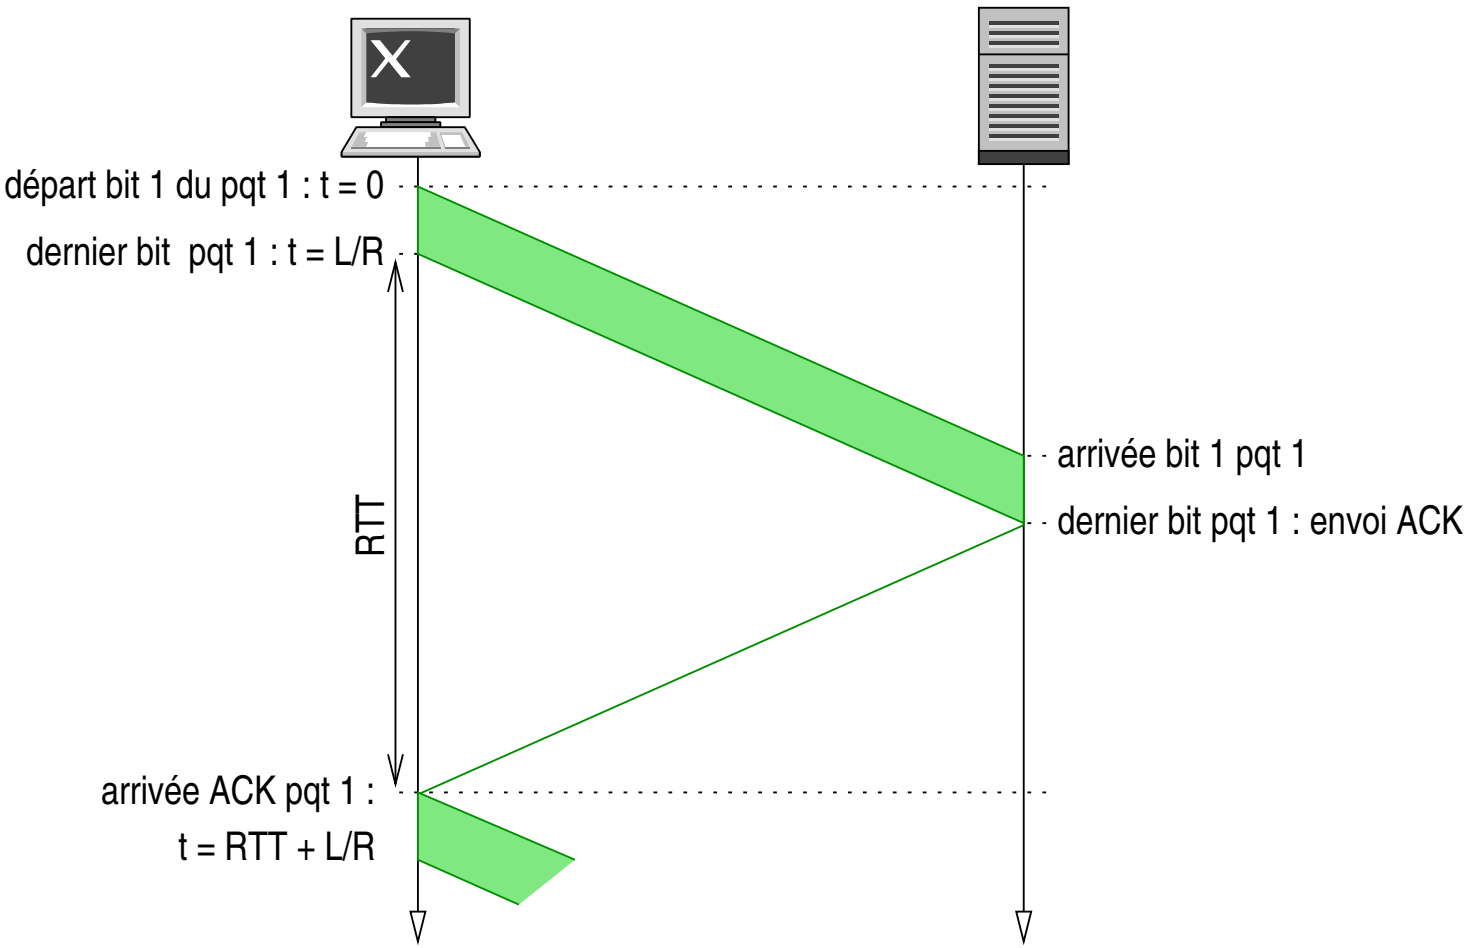

# Protocole pipeline

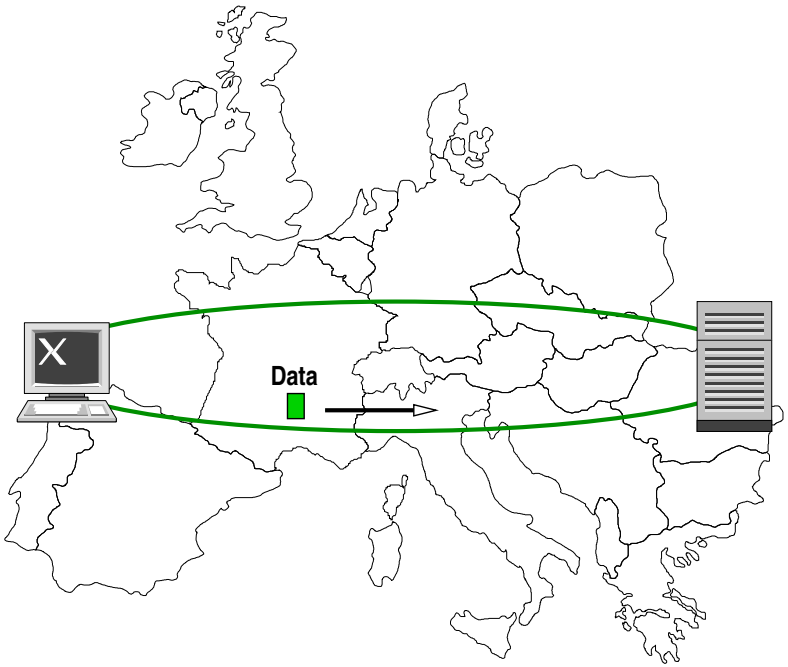


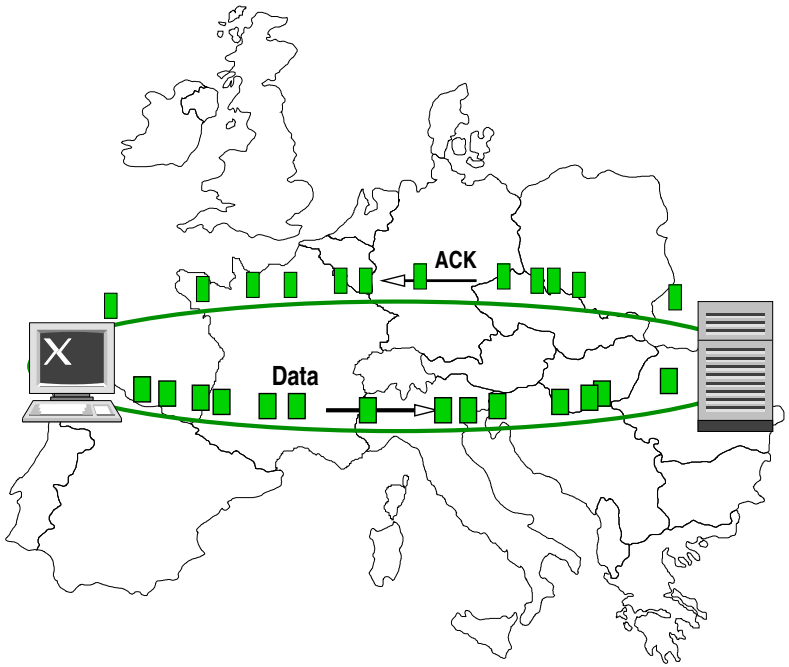


- l'émetteur autorise plusieurs paquets en attente d'acquittement
  - numéro de sequences étendus
  - tampons d'émission et/ou de réception
    - 2 types de protocole pipeliné : **Go-Back-N** et **Retransmissions sélectives**

# Performance pipeline

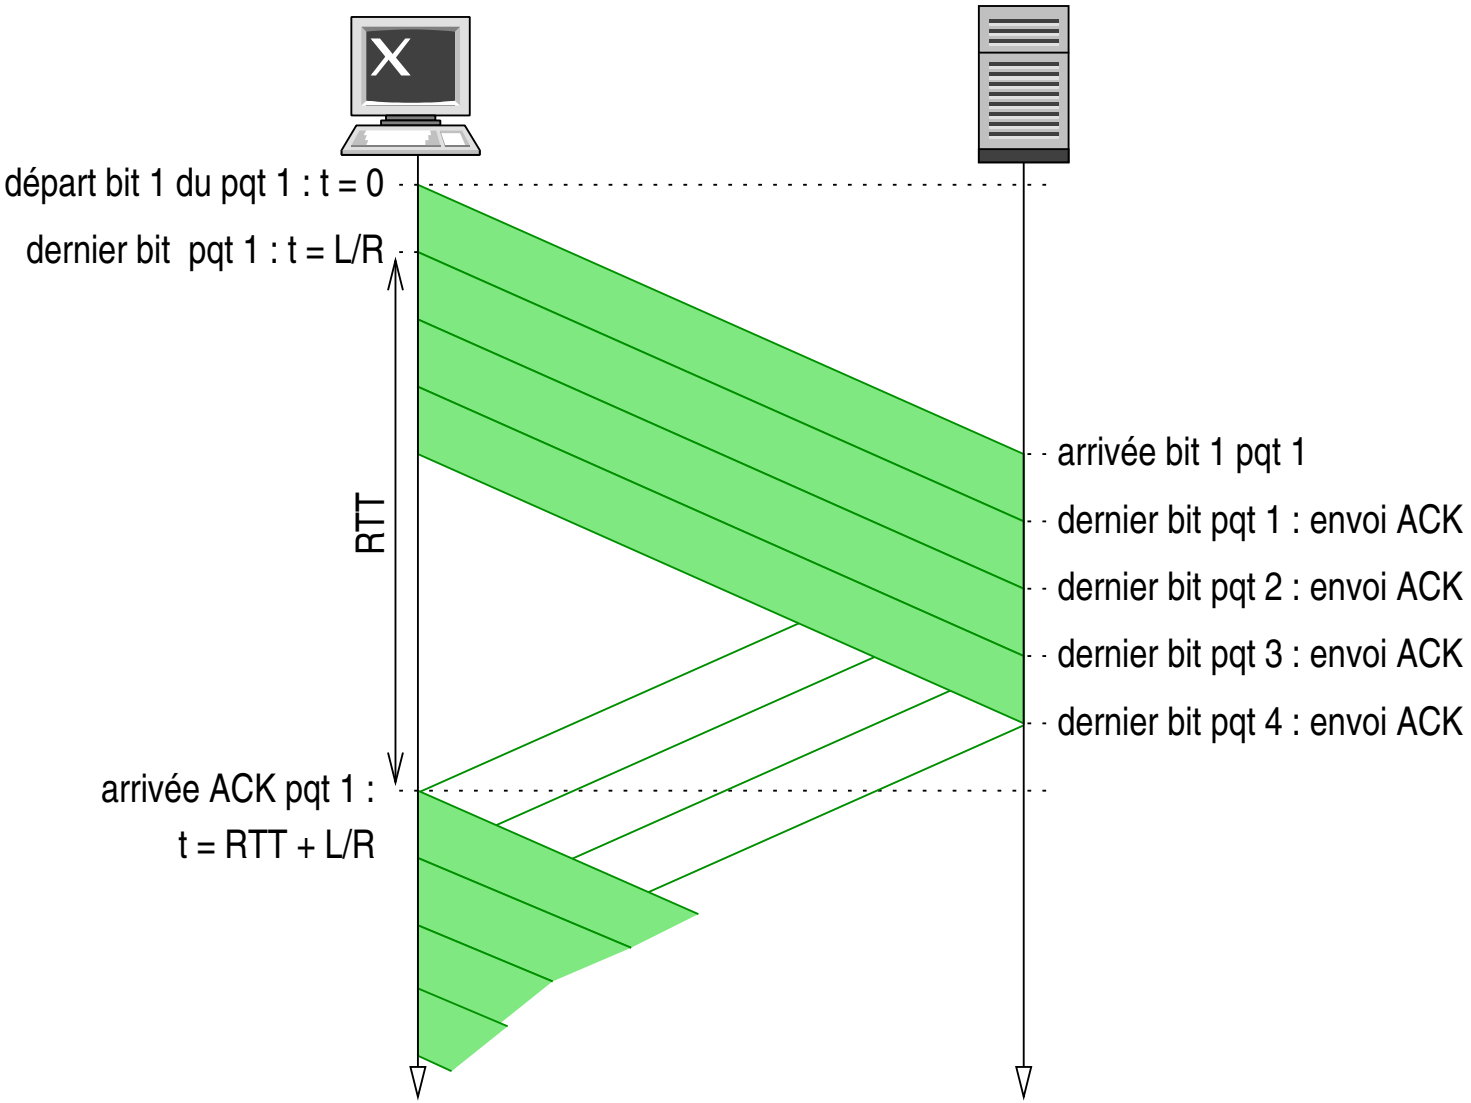

# Go-Back-N : émetteur

Emetteur avec gestion *Go-Back-N* (retour arrière).

- entête des paquets avec k bits de numéro de séquence
- acquittements **cumulatifs**
  - `ACK(n)` acquitte tous les paquets jusqu'au numéro de séquence `n`
- fenêtre d'au maximun *N* paquets non acquités :

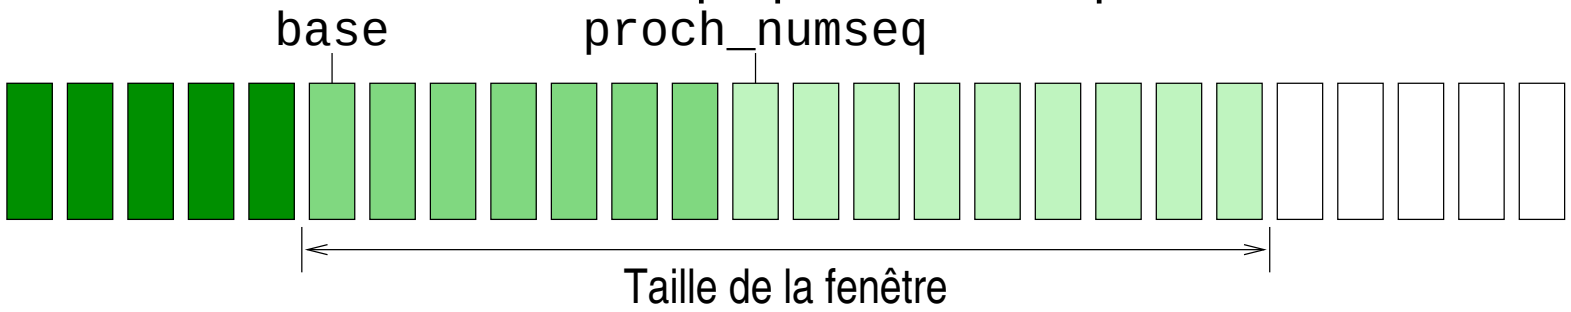


- une temporisation pour les paquets en attente *(in-flight)*
  - `tempo_expire(n)` : retransmission du paquet `n` et des suivants avec numéro de séquence supérieur

# PTF v4.0 : émetteur

ptf_emis(data)

si (proch_numseq < base+N) alors :
  pqtem[proch_numseq] = cree_pqt(proch_numseq, data, ctrlerr)
  ptnf_emis(pqtem[proch_numseq])
  si (base == proch_numseq) alors tempo_init
  proch_numseq ++
sinon refuse_data(data)

base=1
proch_numseq=1

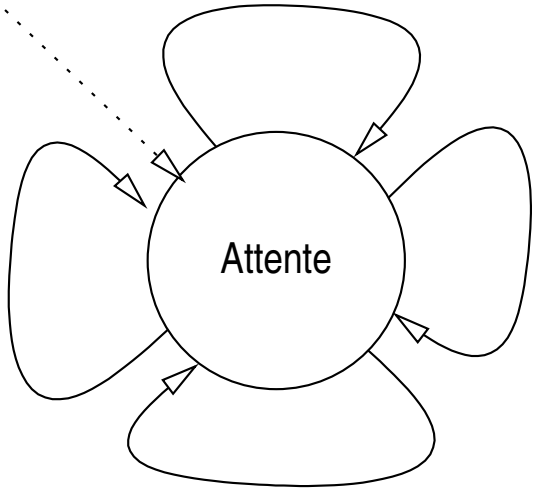


tempo_expire

tempo_init
ptnf_emis(pqtem[base])
ptnf_emis(pqtem[base+1])
.....
ptnf_emis(pqtem[proch_numseq−1])

ptf_rcpt(pqtrc) &&
erreur(pqtrc)

ptf_rcpt(pqtrc) && valide(pqtrc)

base = extr_numack(pqtrc)+1
si (base == proch_numseq) alors tempo_stop sinon tempo_init

*émetteur*

# Go-Back-N : récepteur

Récepteur avec gestion *Go-Back-N* (retour arrière).

- **seulement des ACK** :
  - envoie toujours des ACK avec le plus élevé des `seqnum` de paquets valides **ordonnés**
    - peut générer des ACK dupliqués
    - seul `seqnum_attendu` est mémorisé
- **déséquencement** :
  - élimine les paquets déséquencés
    - pas de tampon au niveau du récepteur
  - ré-émet le ACK avec le plus élevé des `seqnum` de paquets valides **ordonnés**

# PTF v4.0 : récepteur

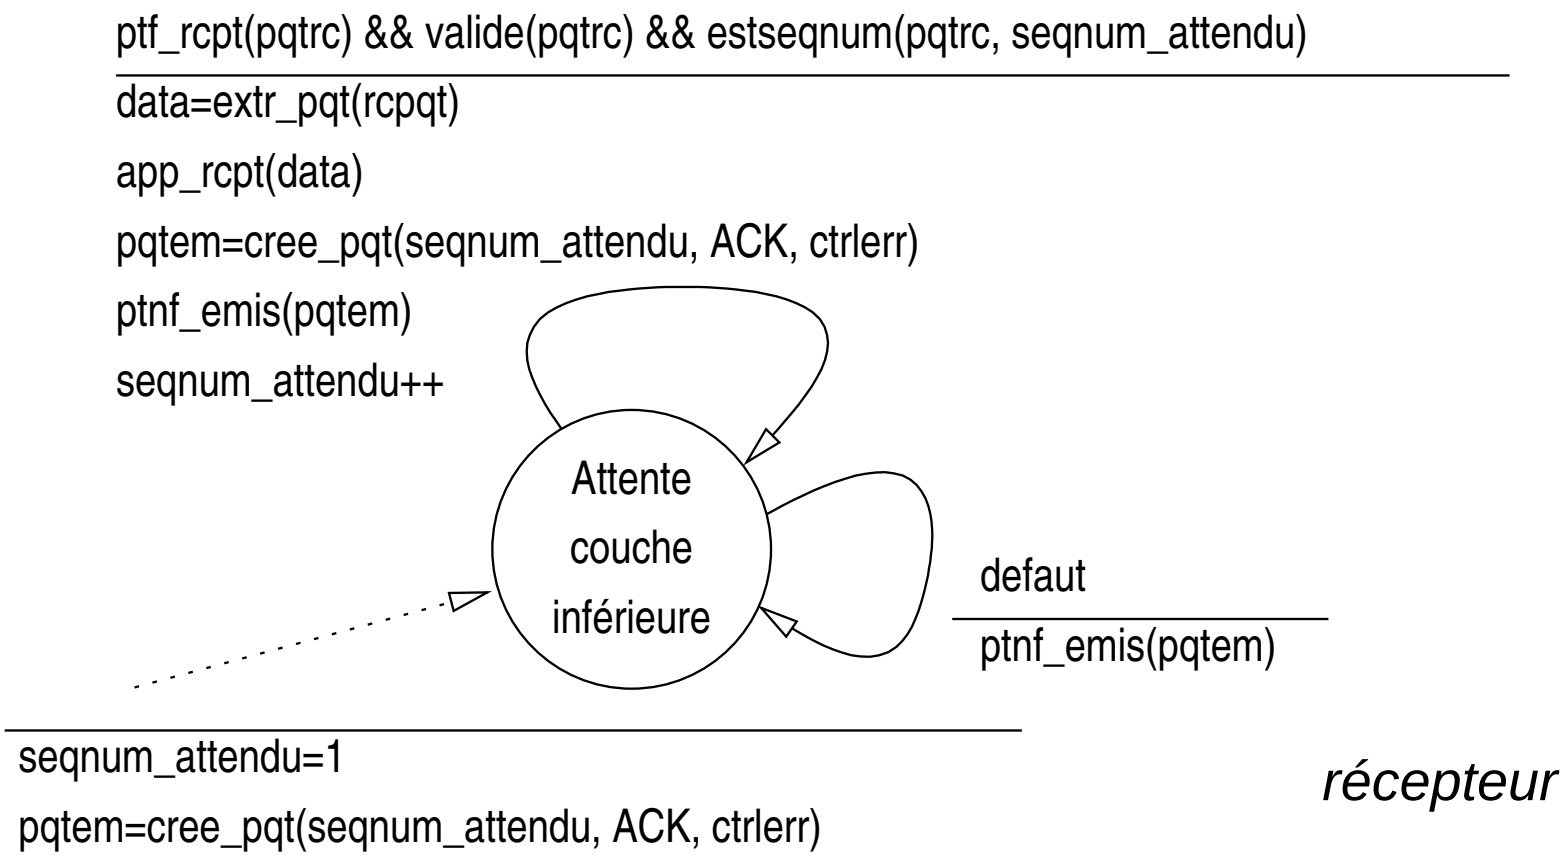


*récepteur*

# PTF v4.0 : exemple

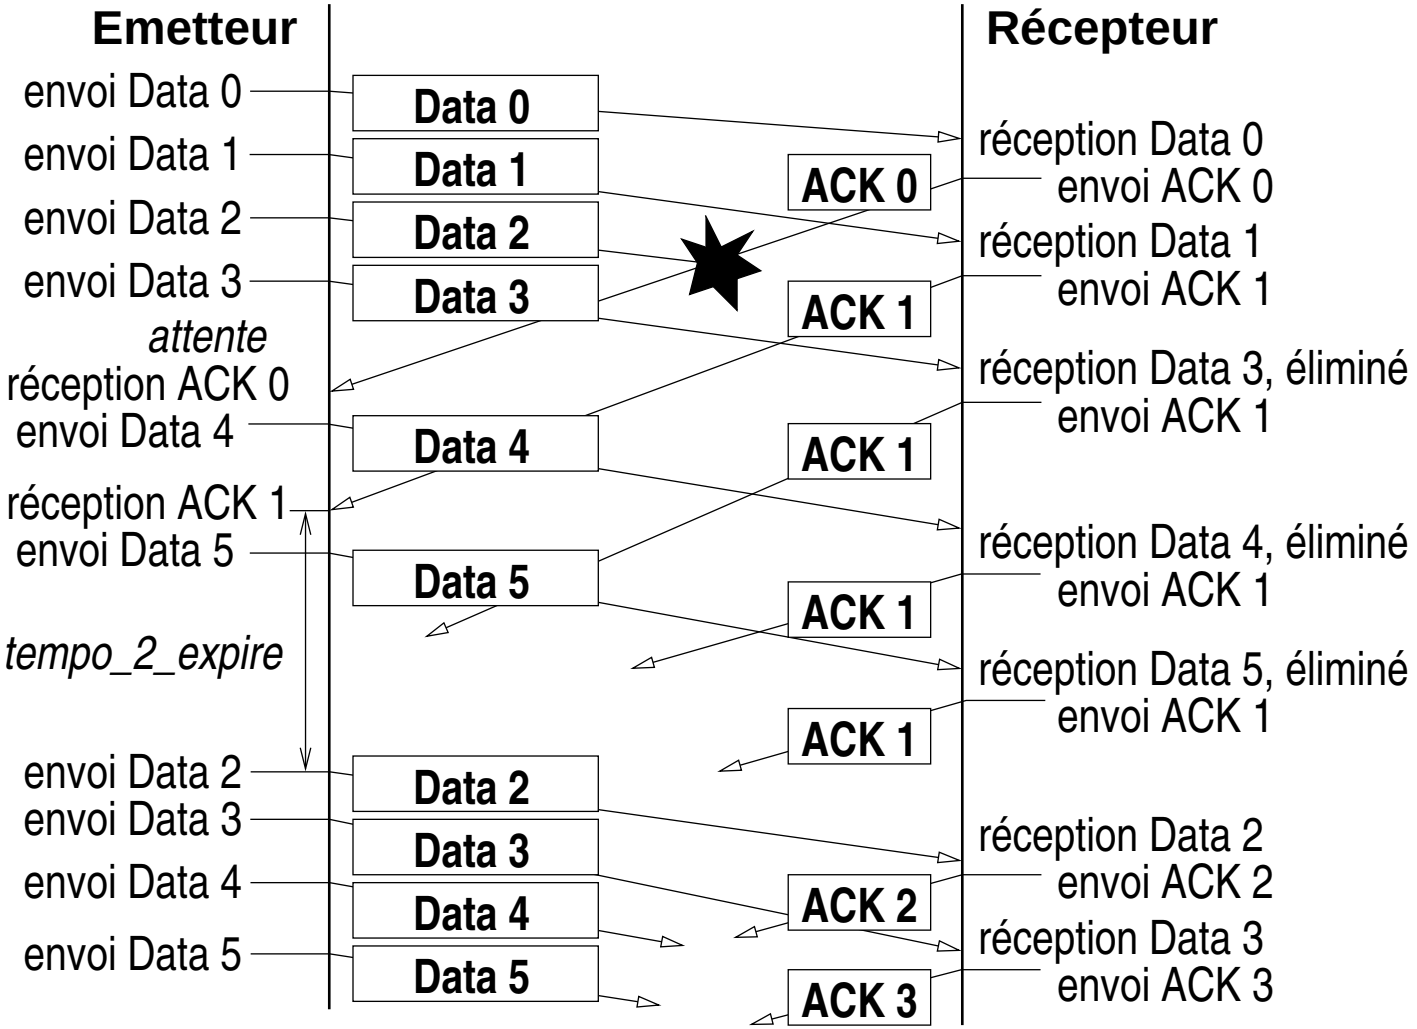

# Retransmissions sélectives : émetteur

Emetteur avec gestion des retransmissions sélectives :

- récepteur acquitte **individuellement** tous les paquets reçut correctement
- retransmet **seulement** les paquets non acquittés
- fenêtre d'émission limité à *N*seqnum consécutifs
- algo :
  - `pft_emis(data)`
    - envoi un paquet si `seqnum` dans la fenêtre
  - `tempo_expire(n)`
    - retransmet paquet `n`
      `tempo_init(n)`
  - `ACK(n)` dans [`base_rcpt`,`base_rcpt+N`]
    - marque le paquet `n` reçu
    - si `n` est le plus petit paquet non acquitté, décale la fenêtre

# Retransmissions sélectives : récepteur

Récepteur avec gestion des retransmissions sélectives :

- acquitte **explicitement** chaque paquet valide reçu
- tampon de réception pour re-séquencement
- algo :
  - `ptf_rcpt(n)` avec `n` dans [`base_rcpt`,`base_rcpt+N`]
    - `ACK(n)`
    - si déséquensé : tampon
    - si séquense : `app_emis(data)`, est le plus petit paquet non acquitté, décale la fenêtre
  - `ptf_rcpt(n)` avec `n` dans [`base_rcpt-N`,`base_rcpt-1`]
    - `ACK(n)`
  - autre
    - ignore

# Retransmissions sélectives : visualisation

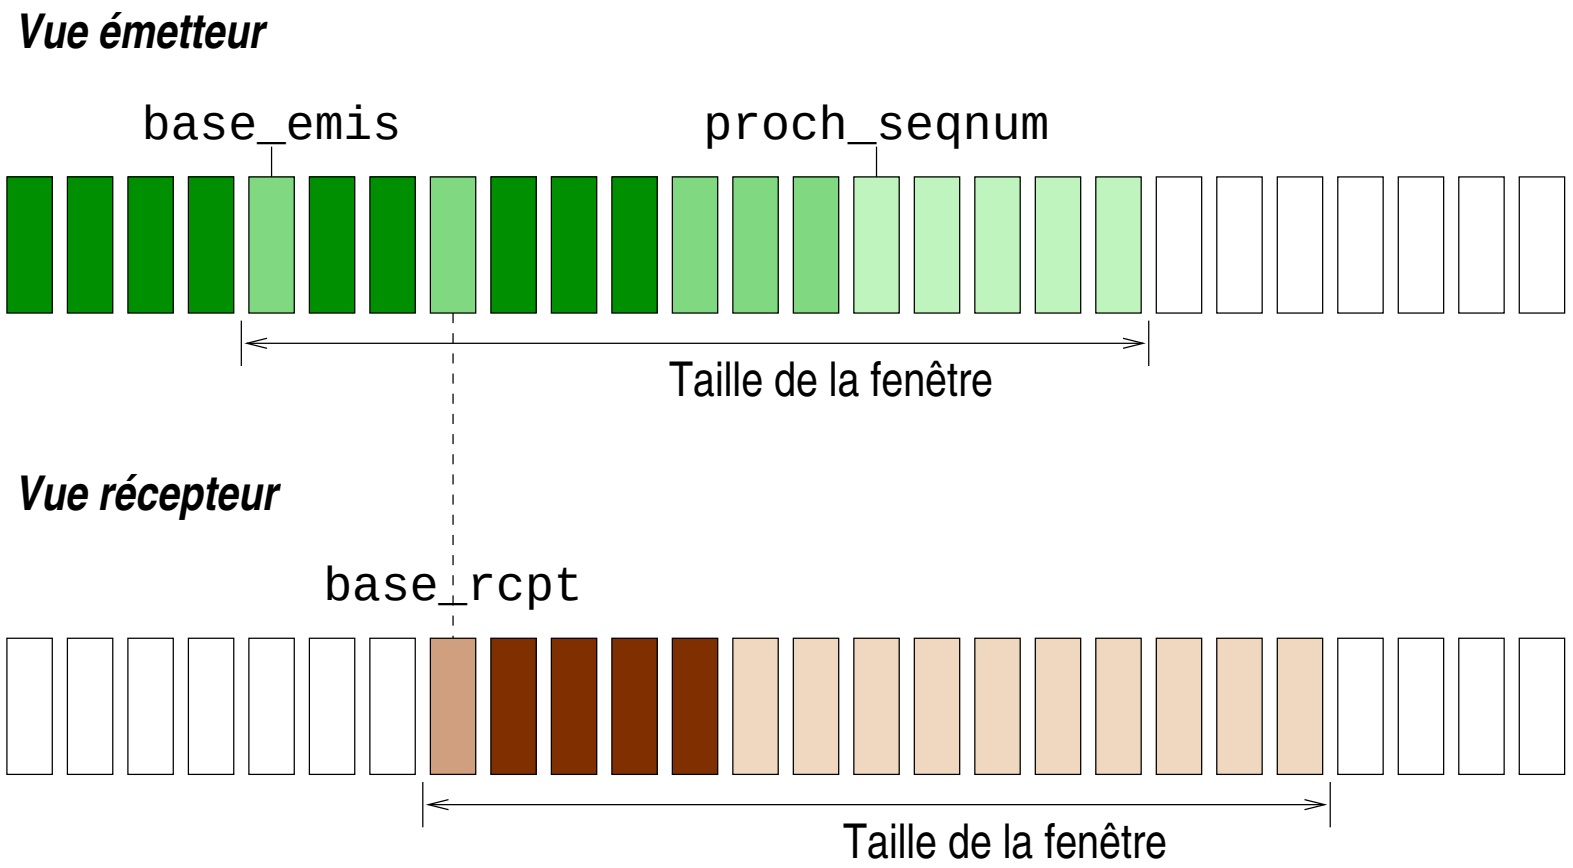

# Retransmissions sélectives : exemple

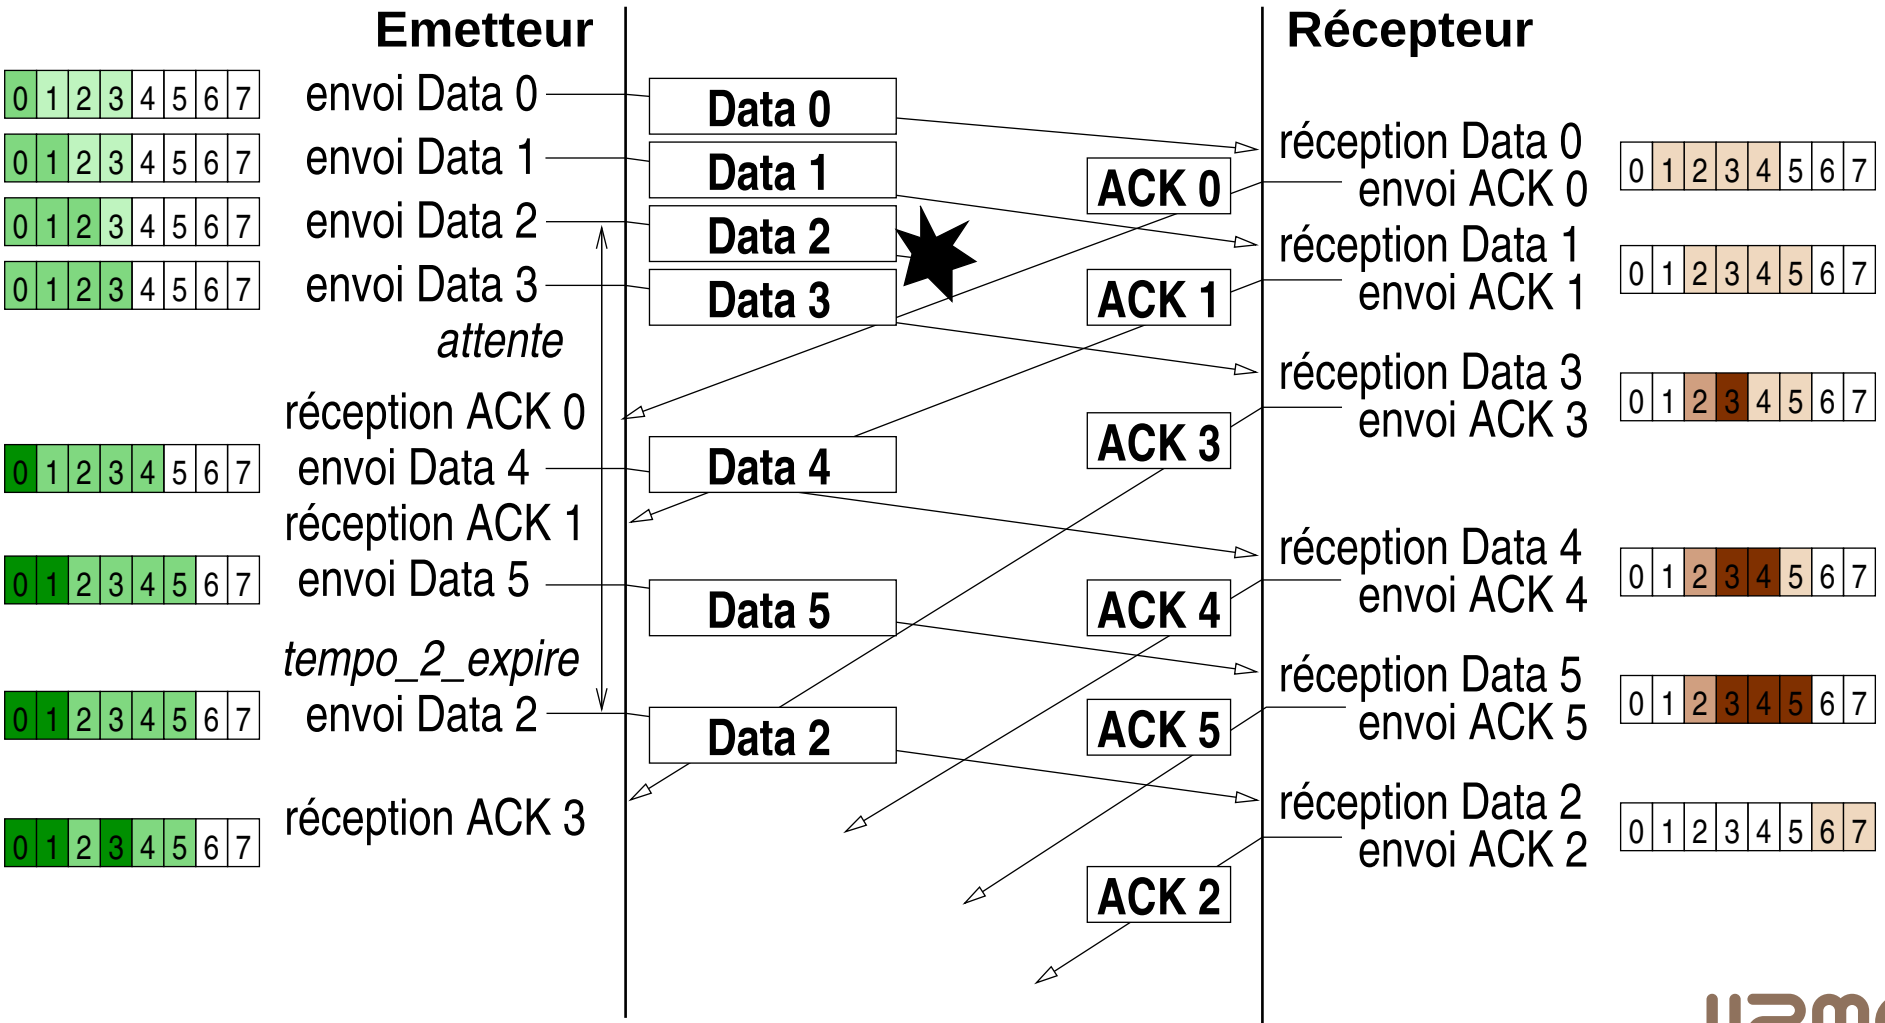

# ARES : plan du cours 3/5

# TCP

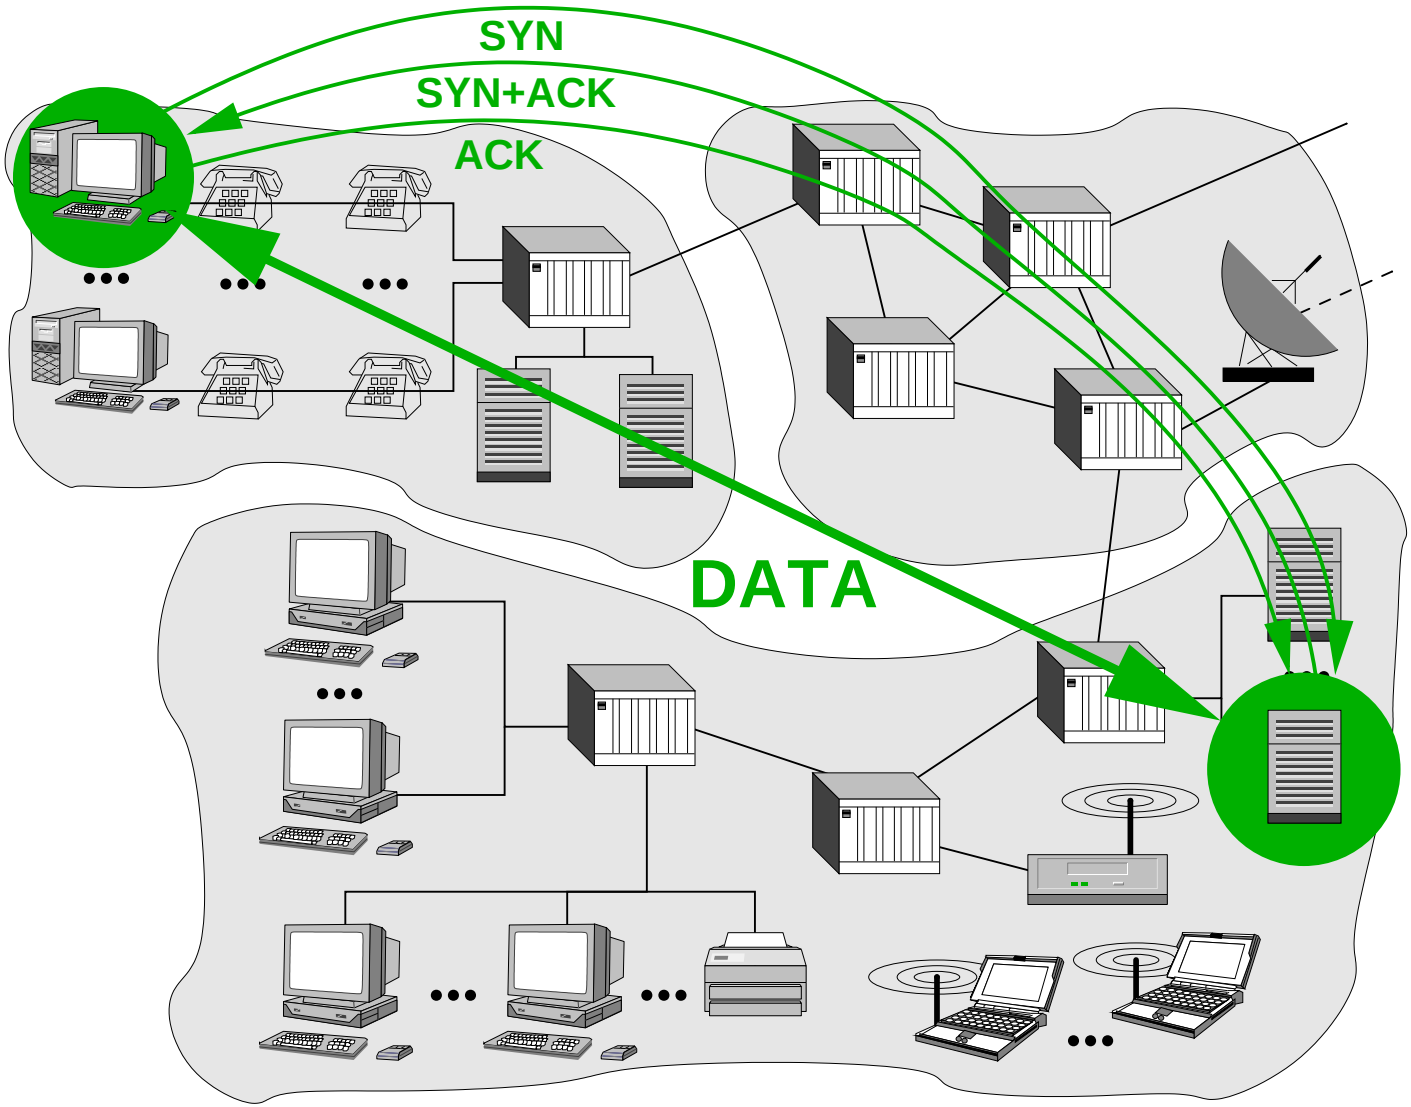

# TCP (*Transmission Control Protocol*)

[RFCs : 793, 1122-1123, 2474, 3168, 3260, 4379, 5462 et 5681]

- service **fiable**
  - mécanismes ARQ
- **point-à-point**
  - deux processus (généralement un client et un serveur)
- flot d'**octet** continu
  - pas de frontières de messages
- **orienté connexion**
  - ouverture en trois échanges (*three-way handshake*)
    - initiation des états aux extrémité avant l'échanges de données
  - fermetures courtoise ou brutale
- connexion **bidirectionnelle** (*full duplex*)
  - flux de données dans chaques sens
  - taille maximum du segment : MSS (*Maximun Segment Size*)
- **pipeline**
  - tampons d'émission et de réception
  - double fenêtre asservie aux contrôles de flux et de congestion

# Segment TCP

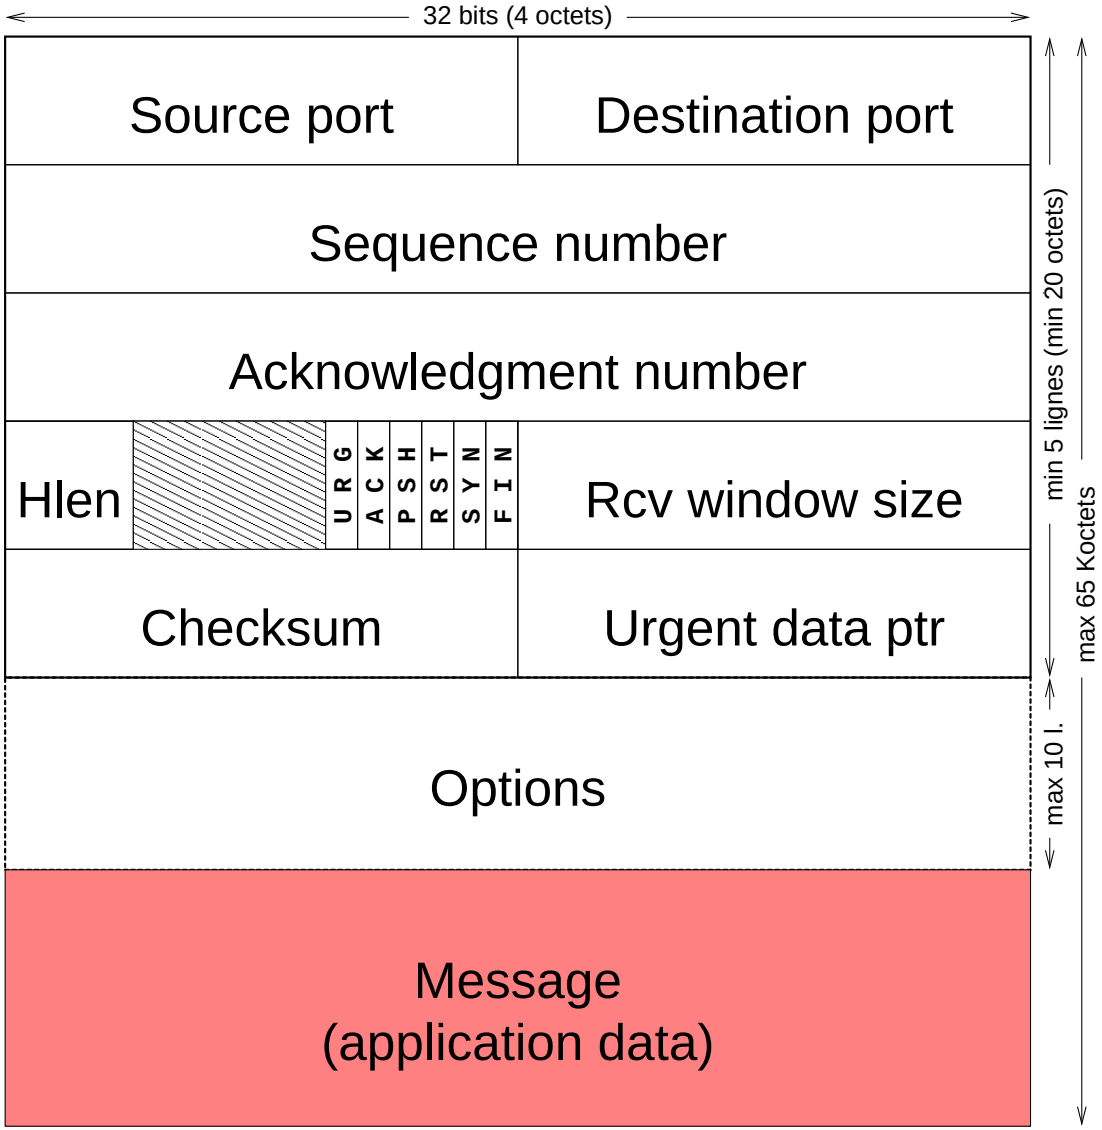
32 bits (4 octets)
Source port
Destination port
Sequence number
Acknowledgment number
Hlen
URG
ACK
PSH
RST
SYN
FIN
Rcv window size
Checksum
Urgent data ptr
Options
Message
(application data)
min 5 lignes (min 20 octets)
max 10 l.
max 65 Koctets

# TCP : port source

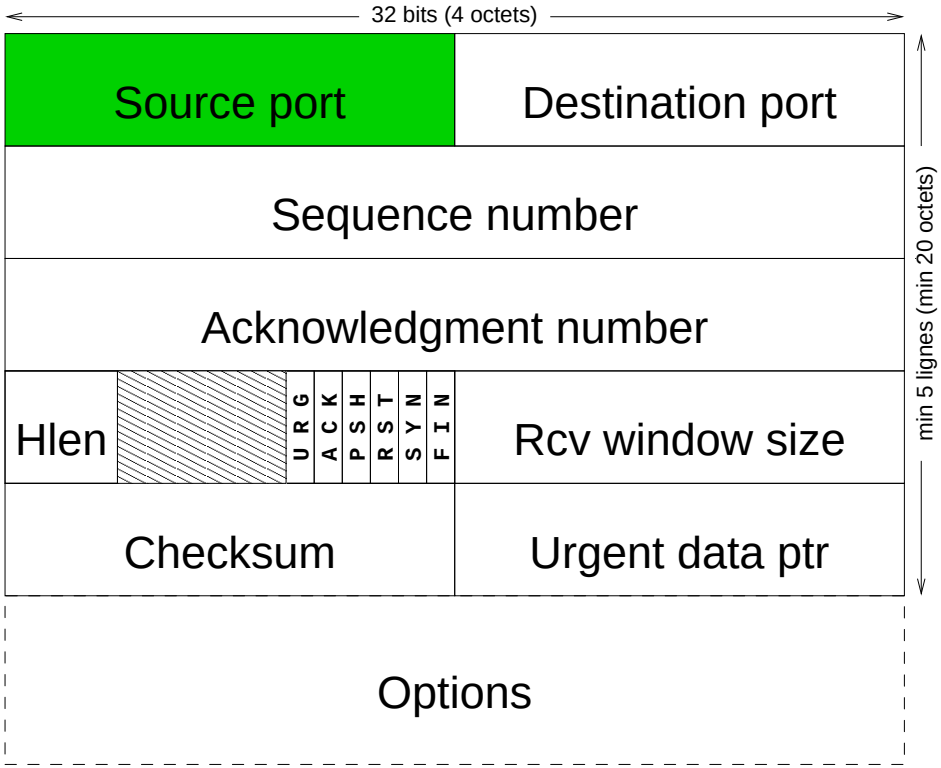


- 16 bits (65535 ports)
- **multiplexage** à la source
- identification partielle du socket (demi-association locale)
- allocation généralement dynamique (dans le cas d'un client)
- répartition espace des ports :
  - $0 \leq$ `numPort` $\leq 1023$ : accessible à l'administrateur
    - socket usuel des serveurs
  - $1024 \leq$ `numPort` : accessible aux utilisateurs
    - socket usuel des clients

# TCP : port destination

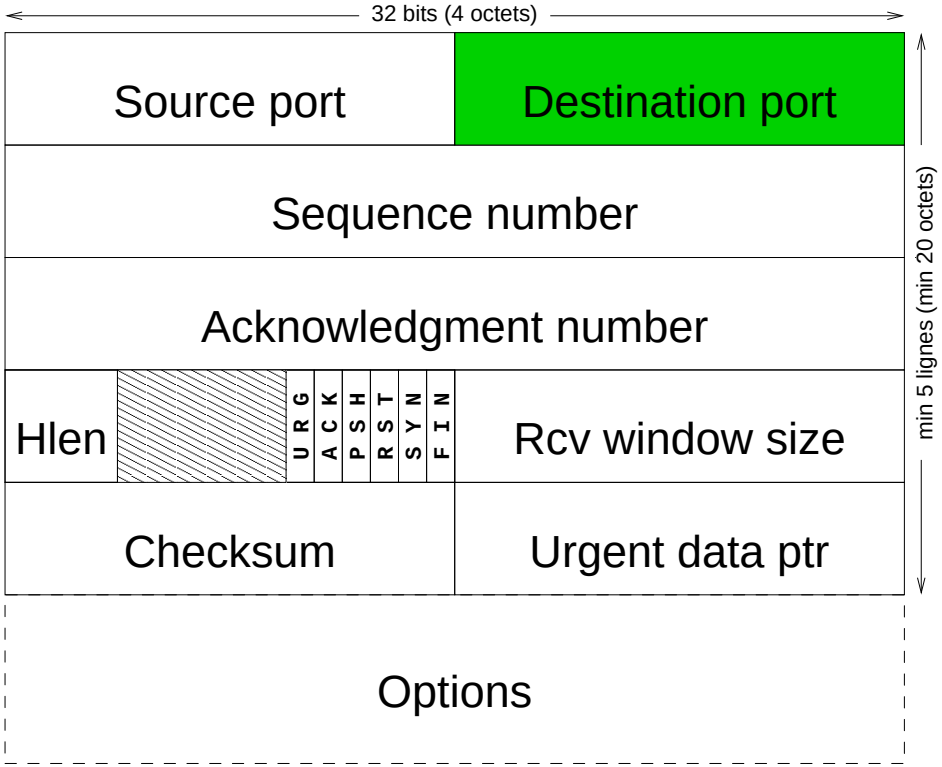


- 16 bits (65535 ports)
- **démultiplexage** au niveau de la destination
- identification partielle du socket (demi-association distante)
- destinataire à l'écoute sur ce port lors de la création
- négociation du port ou *well-known ports* (réservés) :

```
Unix> cat \etc\services|grep tcp
tcpmux          1/tcp
chargen         19/tcp
ftp-data        20/tcp
ftp             21/tcp
ssh             22/tcp ..
telnet          23/tcp
smtp            25/tcp
gopher          70/tcp
finger          79/tcp
www             80/tcp
kerberos        88/tcp ....
```

# TCP : numéro de séquence (1)

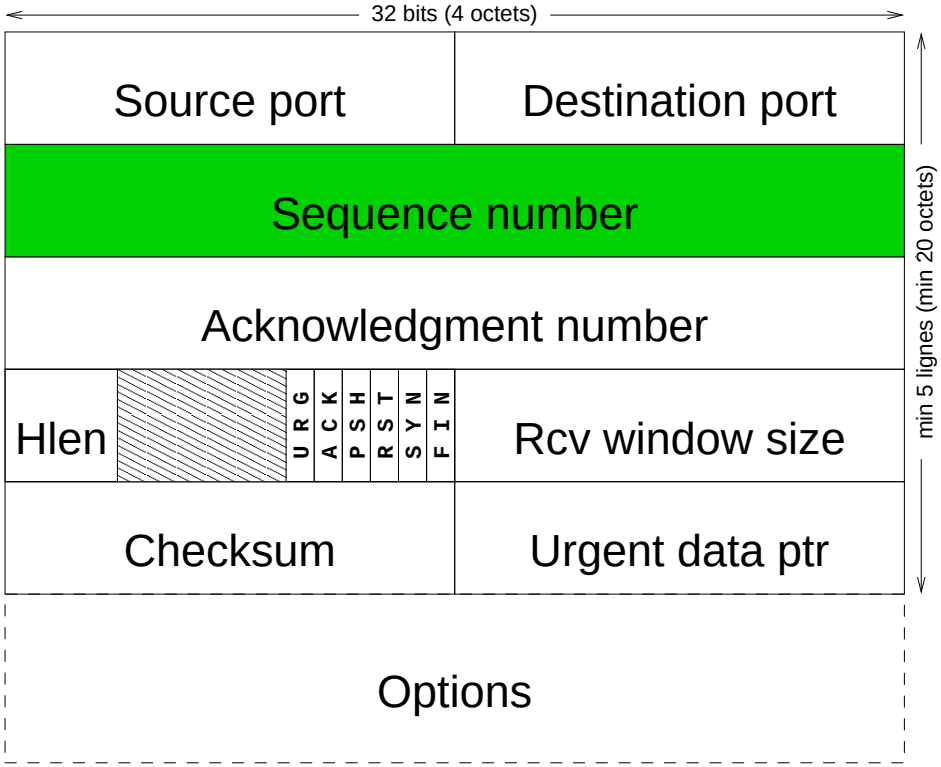


- 32 bits
- associé à chaque **octet** (et non pas à un segment)
  - numérote le **premier** octet des *data*
  - numérotation implicite des octets suivants
  - boucle au bout de 4 Goctets
- détection des **pertes**
- **ordonnancement**

# TCP : Numéro de séquence (2)

Numérotation de chaque **octet** du flot de données

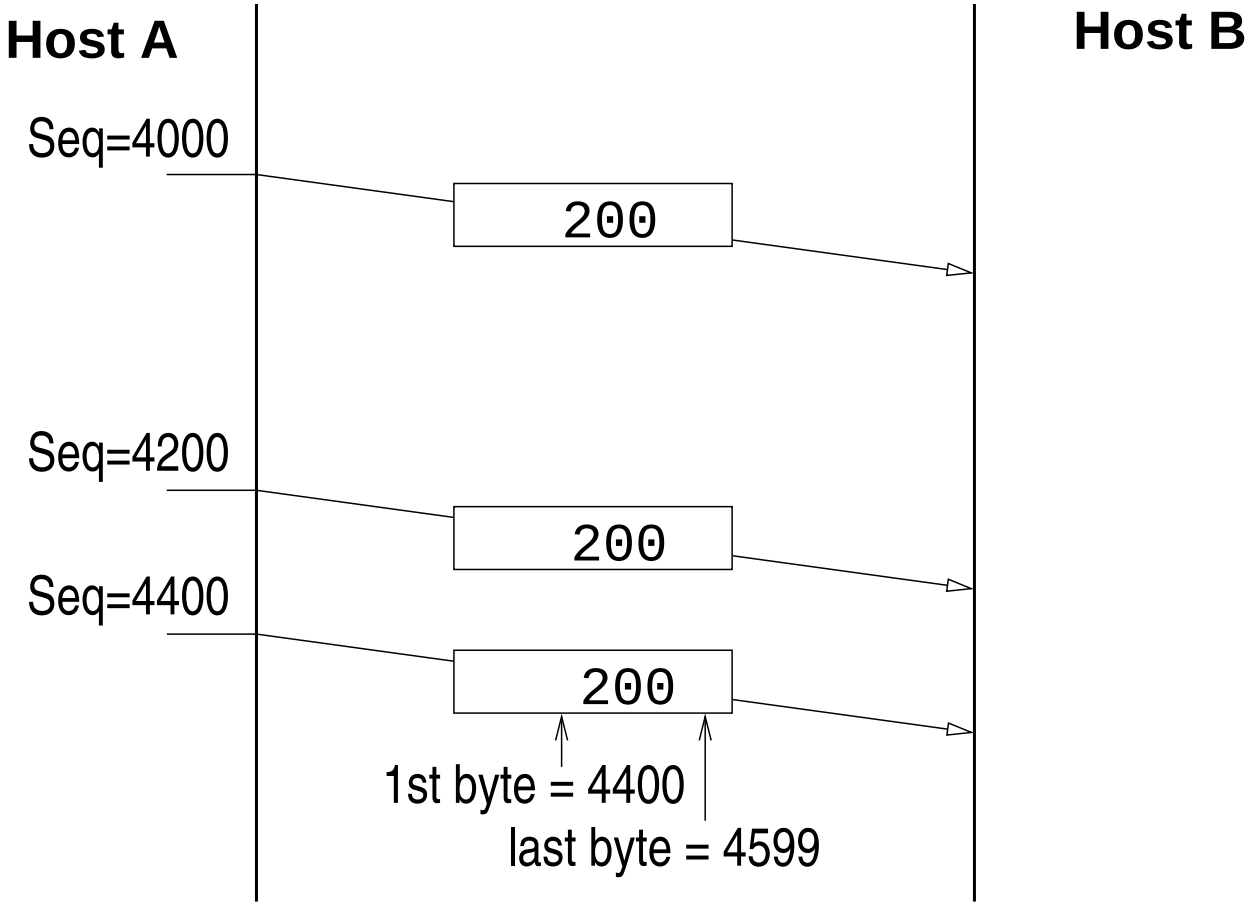

# TCP : numéro d'acquittement (1)

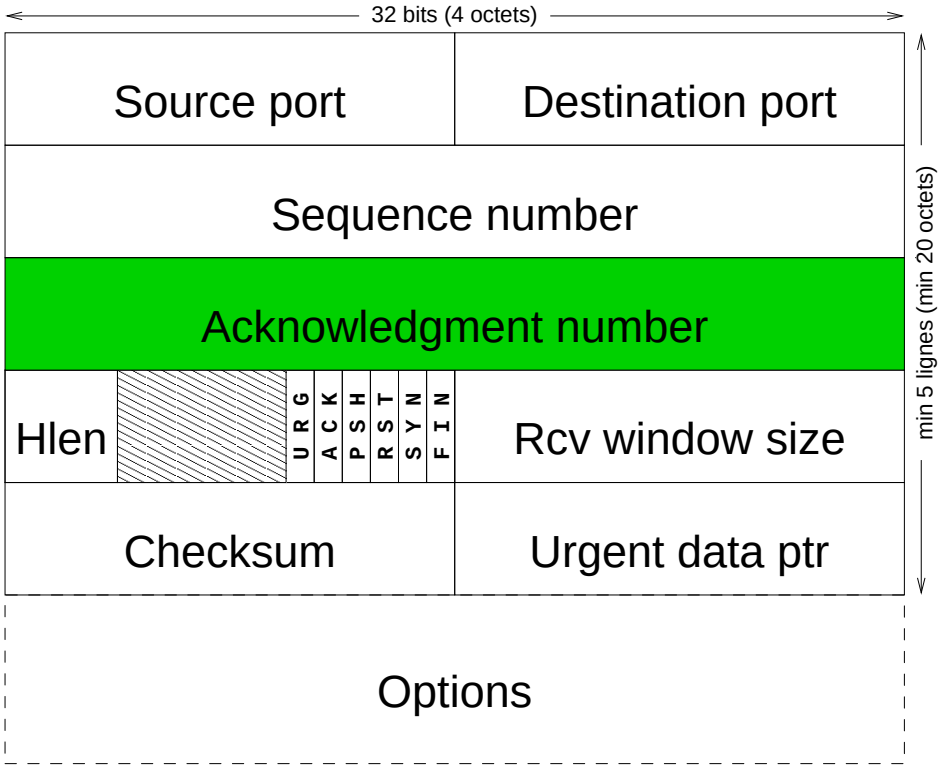


- 32 bits
- *piggybacking*
- indique le numéro du **prochain** octet attendu
- **cumulatif**, indique le premier octet non reçu (d'autres peuvent avoir été reçus avec des numéros de séquence supérieurs)

# TCP : numéro d'acquittement (2)

Acquittement de chaque **octet** du flot de données

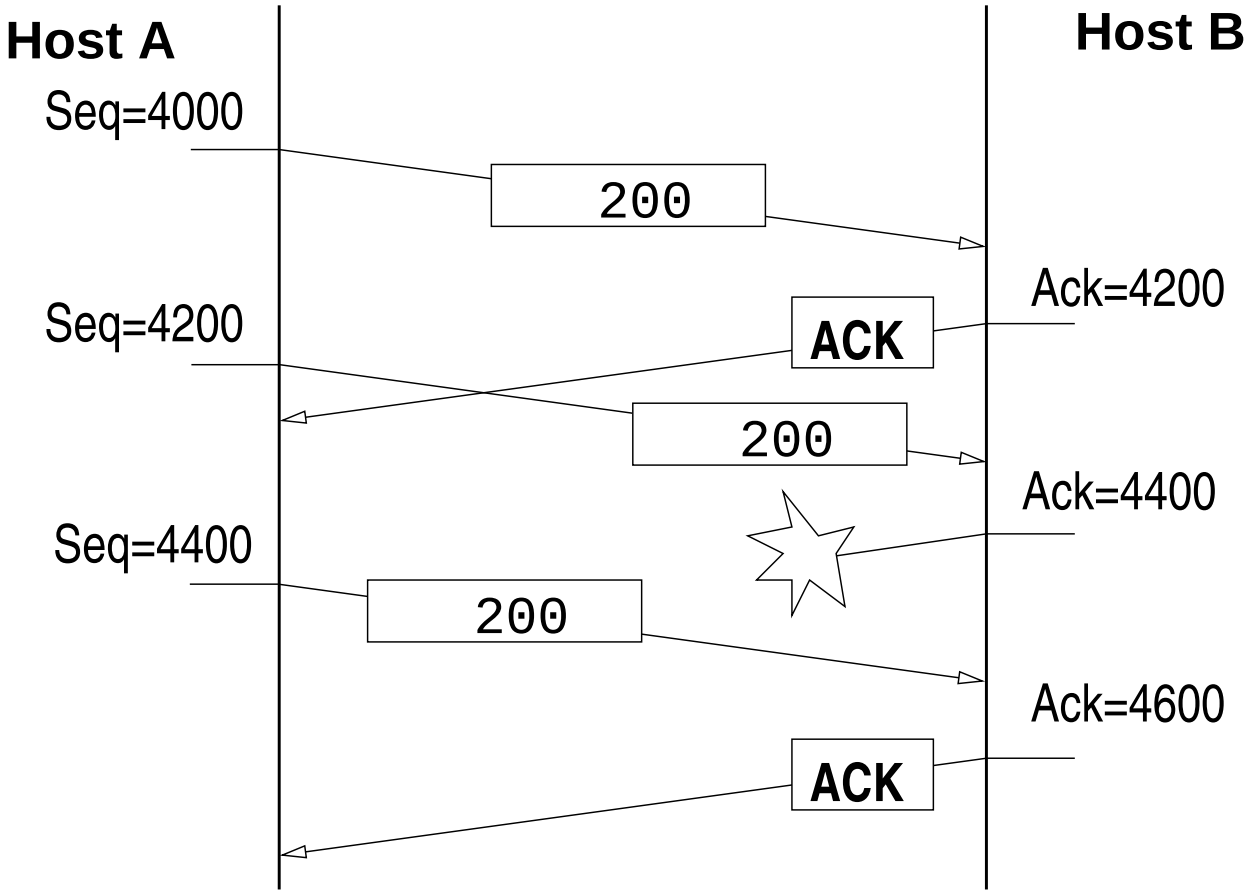

# TCP : numéro d'acquittement (3)

*Piggybacking*

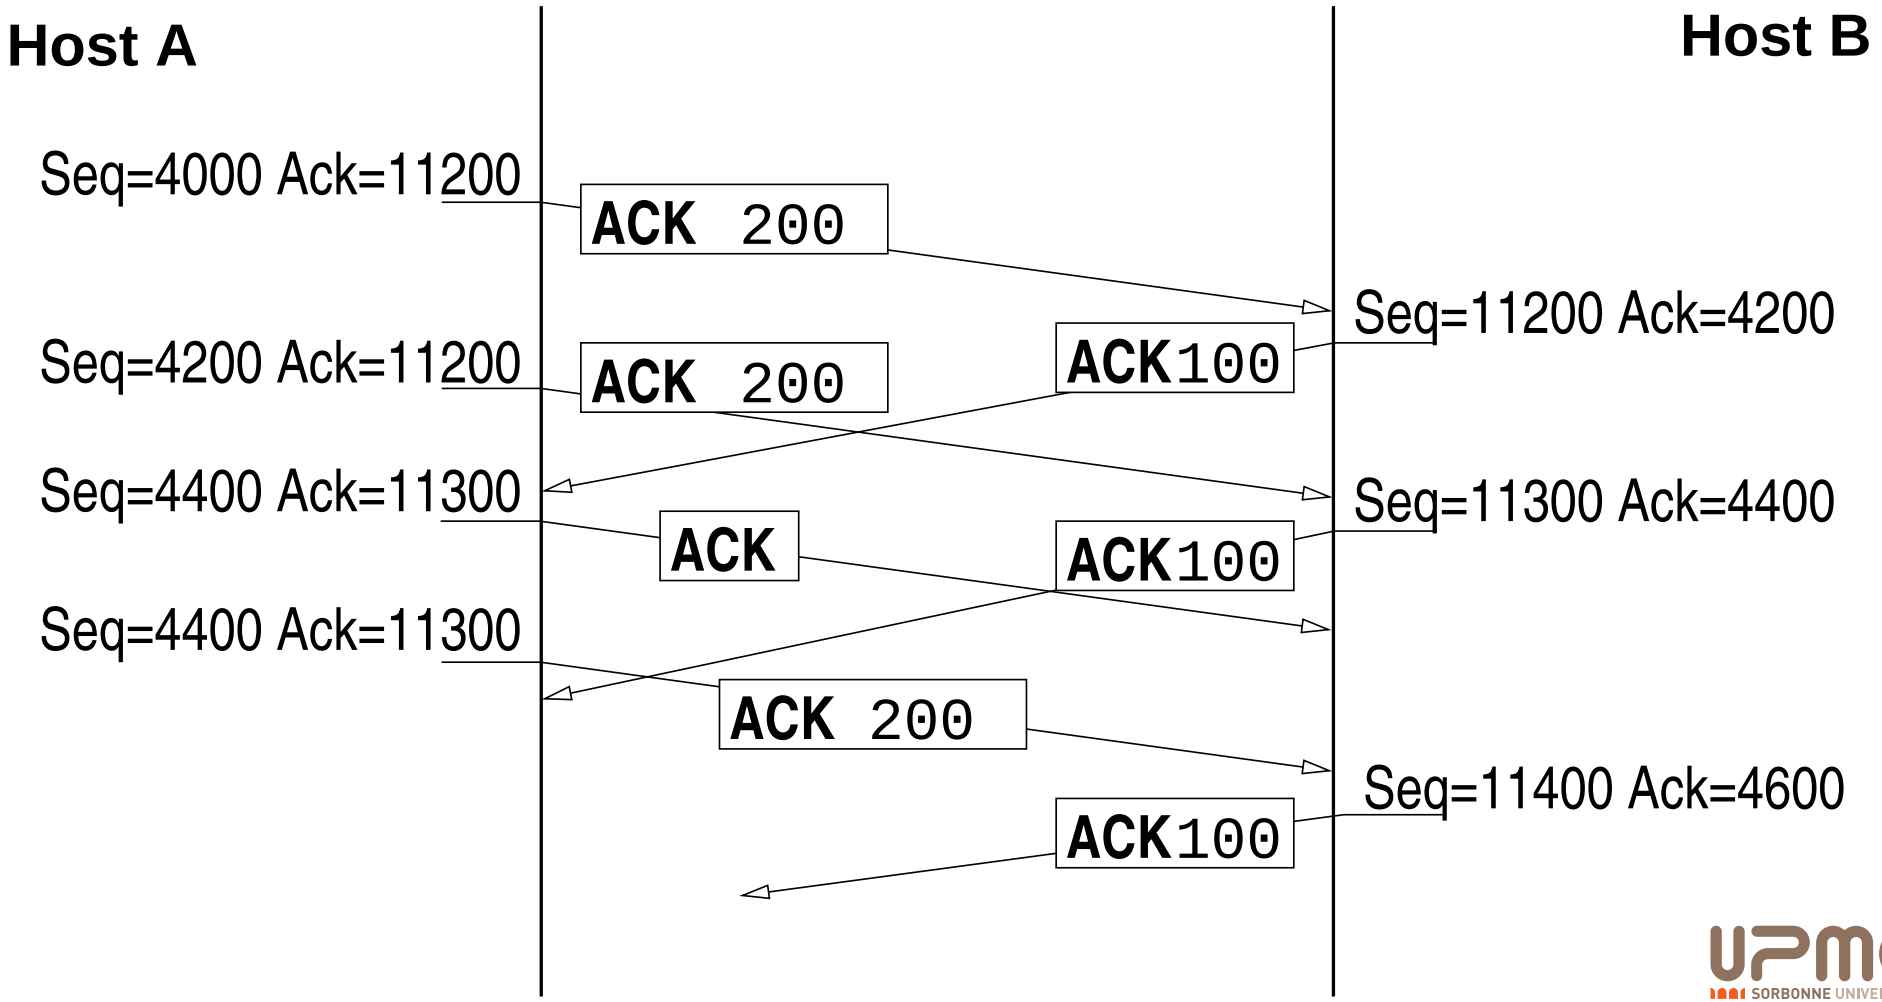

# TCP : exemple TELNET (1)

Emission d'un caractère frappé et renvoi par le serveur pour l'affichage

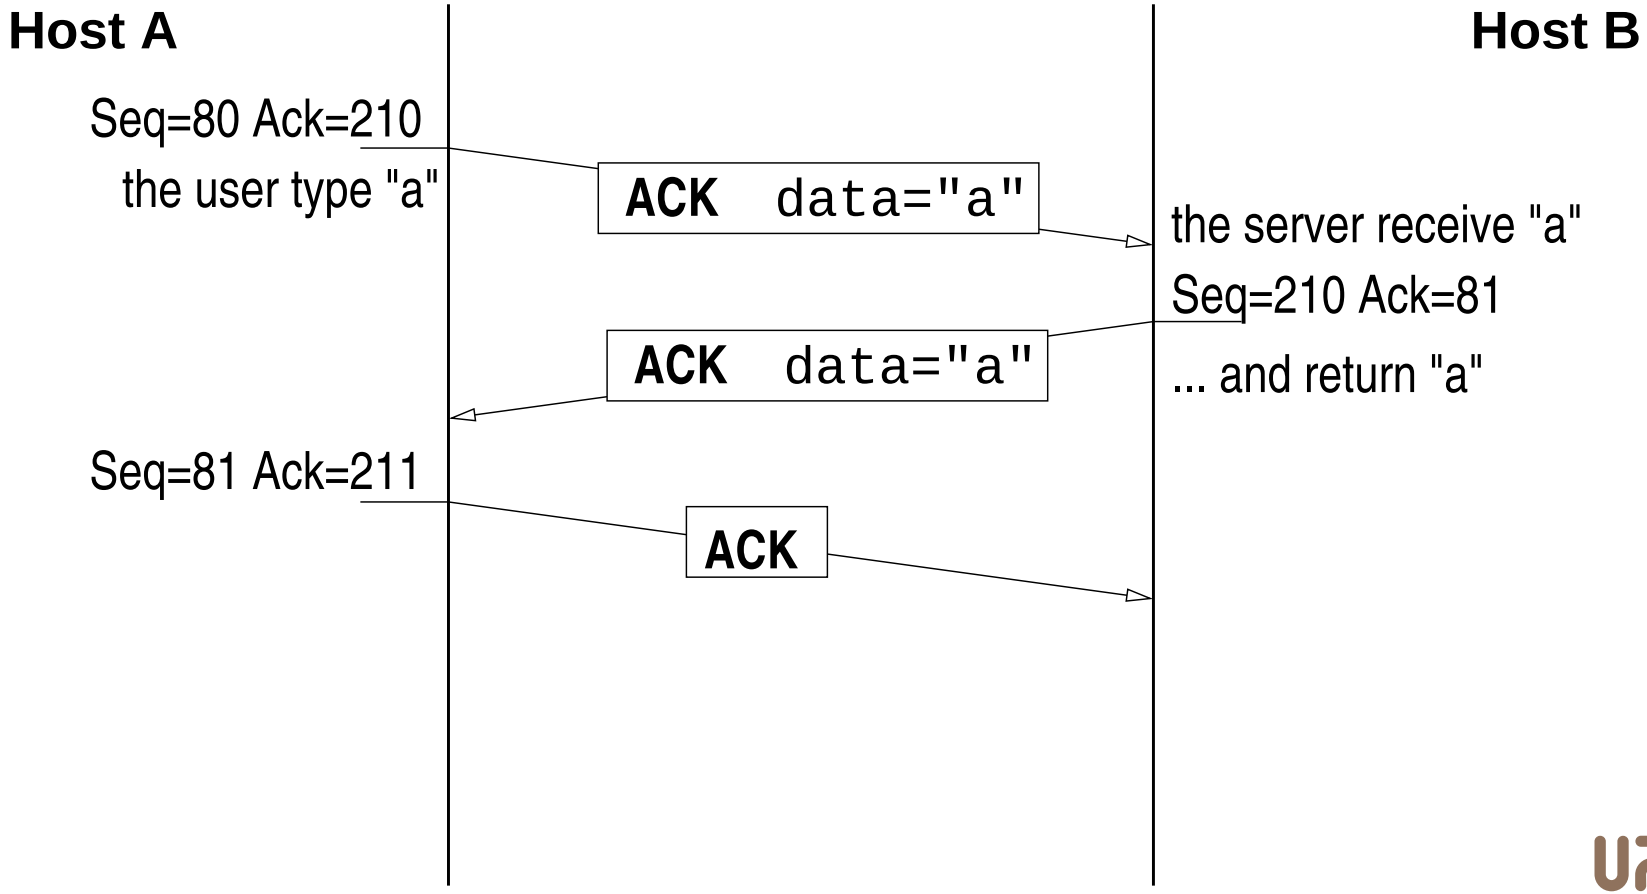

# TCP : exemple TELNET (2)

Les acquittements peuvent être plus rapide que l'application

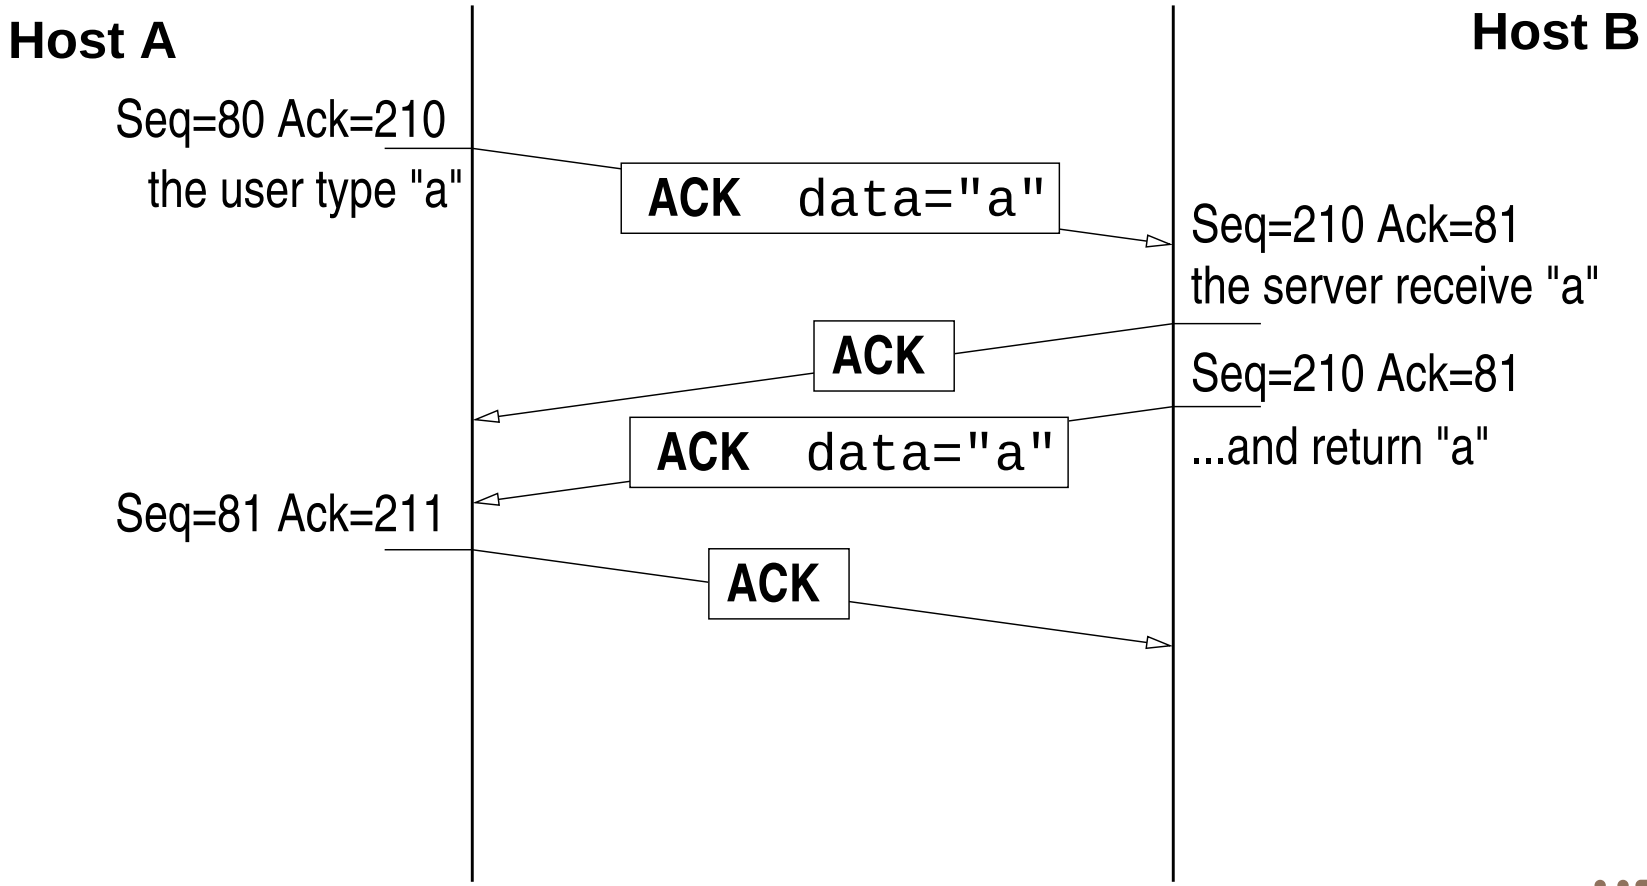

# TCP : acquittements temporisés

*Delayed ACK* (attente de deux segments ou 500 ms max.)

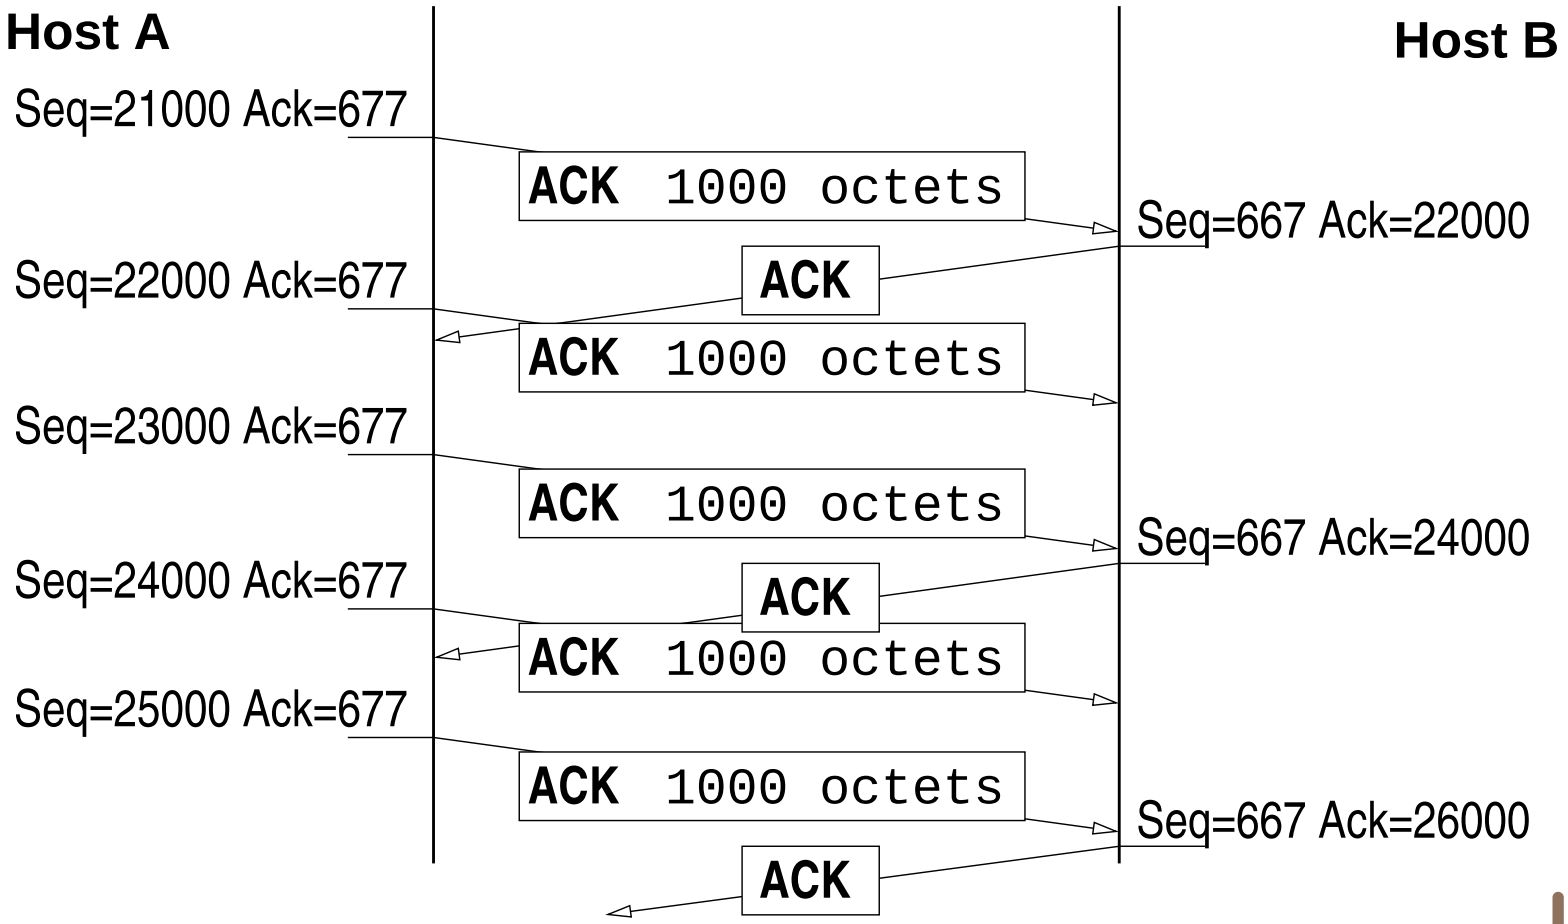

# TCP : longueur de l'entête

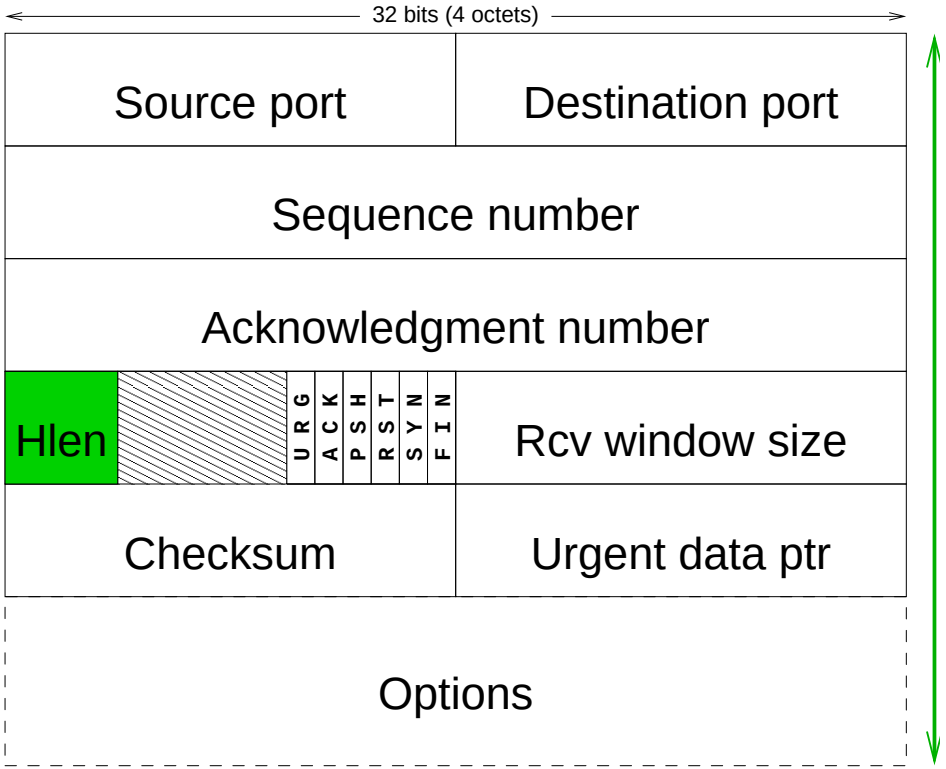


- 4 bits (valeur 15 max)
- nombre de lignes de 32 bits dans l'entête TCP
- nécessaire car le champ option est de longueur variable
  - valeur 5...
    - pas d'options
    - entête TCP de 20 octets minimum
  - ... à 15
    - 10 lignes d'options
    - 40 octets d'options max
    - entête TCP de 60 octets maximum

# TCP : indicateurs (*flags*)

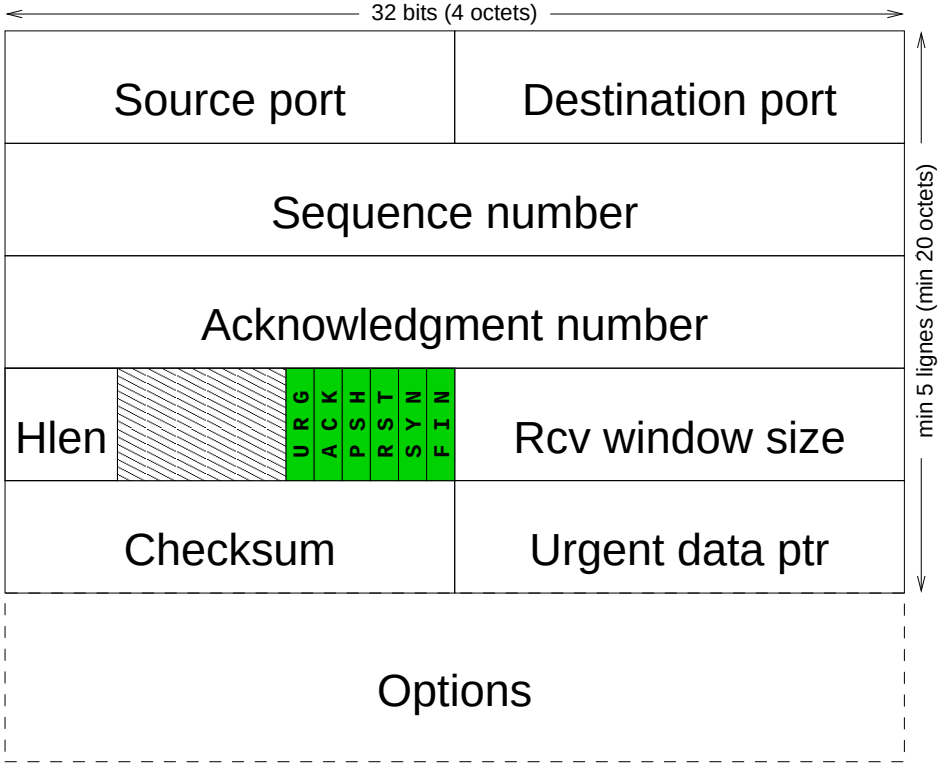


Chacun sur 1 bit indique :

- `URG` : données **urgentes**
- `ACK` : le champ **acquittement** est valide
- `PSH` : envoi **immédiat** avec vidage des tampons
- `RST` : **terminaison** brutale de la connexion
- `SYN` : synchronisation lors de l'**ouverture**
- `FIN` : echanges terminaux lors d'une **fermeture** courtoise

U.E. **ING**

UPMC SORBONNE UNIVERSITÉS

# TCP : taille de la fenêtre de réception

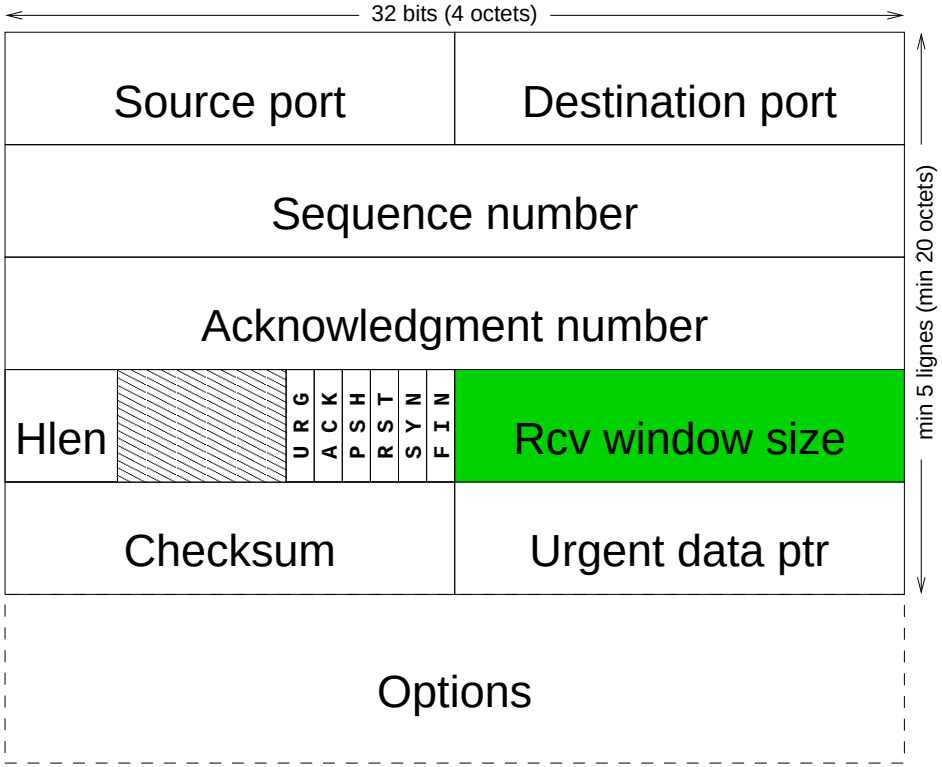


- 16 bits
  - le récepteur peut annoncer jusqu'à 64 Koctets
- *piggybacking*
- **contrôle de flux**
  - indique le nombre d'octets disponibles du coté du récepteur
  - dimentionne la taille de la fenêtre d'anticipation de l'émetteur

# TCP : somme de contrôle du segment

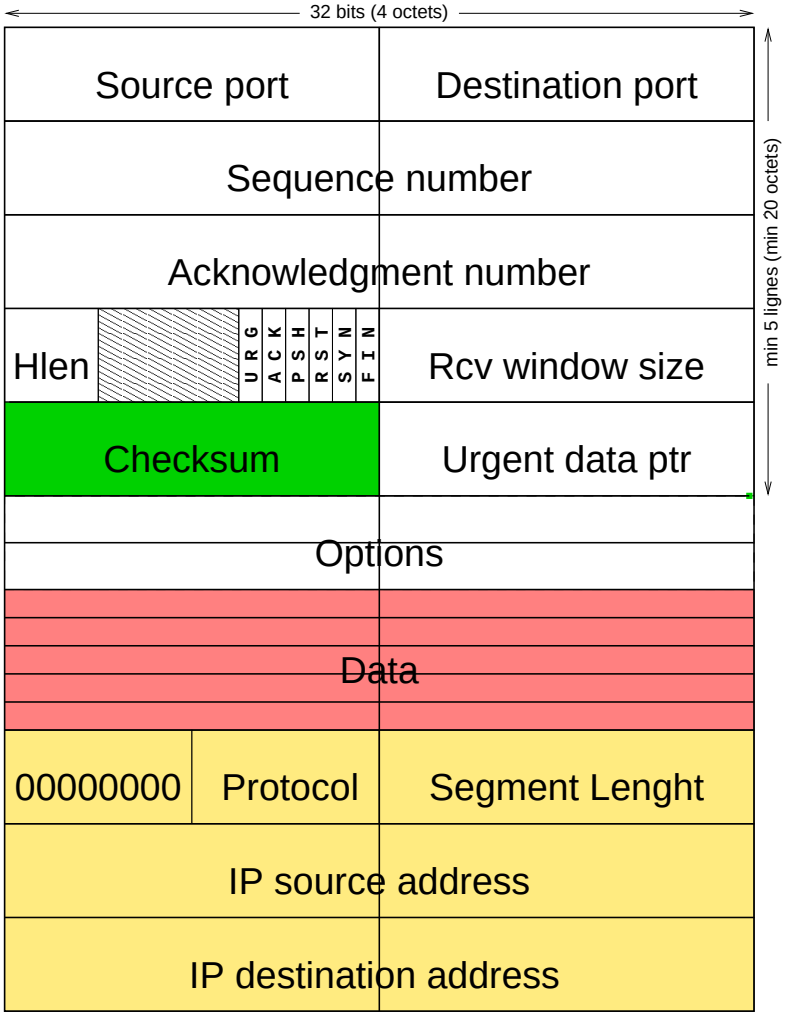


- 16 bits
- idem UDP
- émetteur :
  - ajout *pseudo-header*
  - $checksum = \overline{\sum mot_{16\text{bits}}}$
- récepteur :
  - ajout *pseudo-header*
  - recalcul de $\sum mot_{16\text{bits}}$
    - $= 0$ : Ok
    - $\neq 0$ : destruction

# TCP : pointeur sur les données urgentes

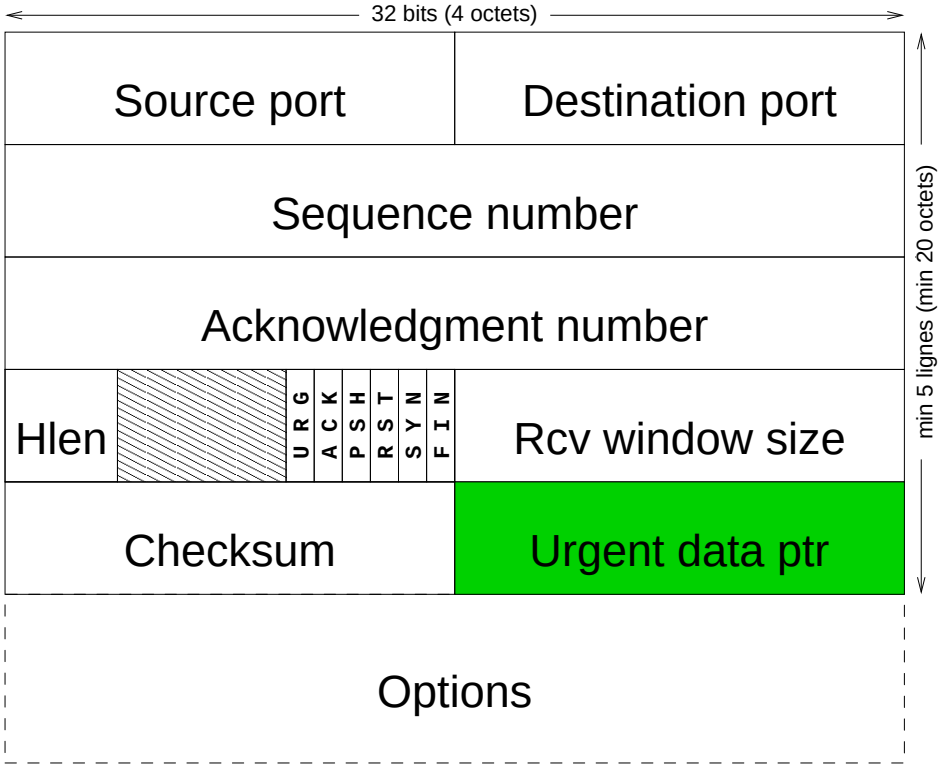


- 16 bits
- permet l'envoi de données spéciales (et non **hors bande**)
- délimite des données traitées en priorité
- indique la fin des données urgentes
  - interprétation de la quantité de données et de leur rôle par l'application

# TCP : options

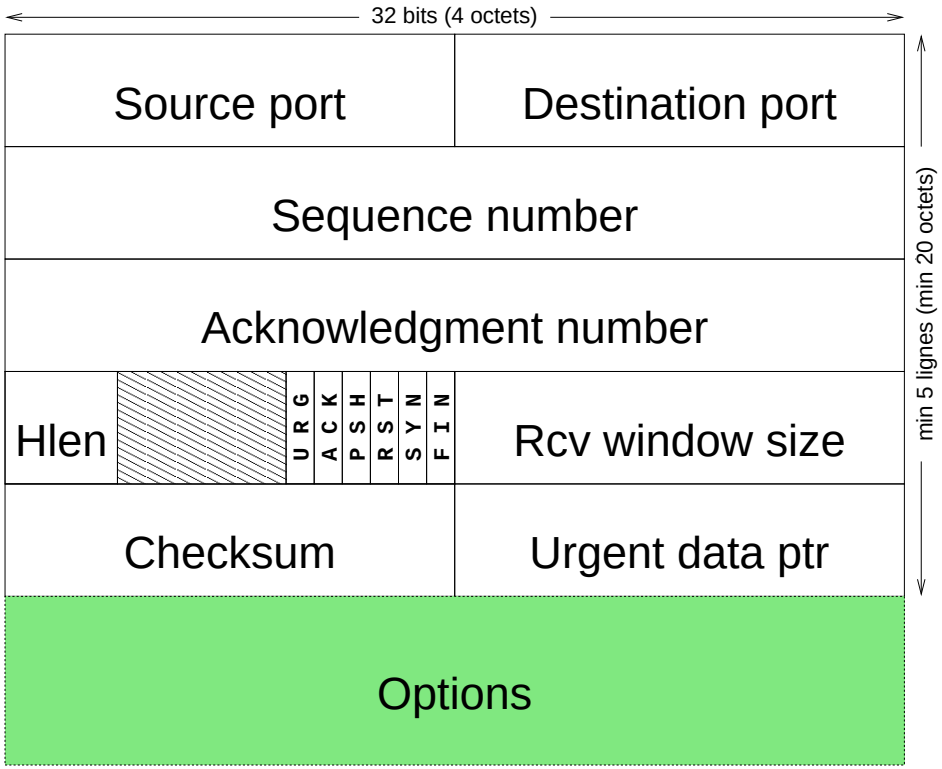


Les options sont de la forme TLV ou *Type, Length (octets), Value* :

- `END` : fin de liste d'options (T=0, non obligatoire)
- `NOOP` : pas d'opération (T=1, bourrage)
- `MSS` : négociation du MSS (T=2, L=4, V=MSS)
- `WSIZE` : mise à l'échelle de la fenêtre par le facteur $2^N$ (T=3, L=3, V=$N$)
- `SACK` : demande d'acquit. sélectif (T=4,L=2, à l'ouverture)
- `SACK` : acquittement sélectif de $n$ blocs (T=5, L=$2+8n$, $2n$ numéros de séquences) ...

# TCP : gestion de la connexion

## Ourverture de la **connexion** préalable à l'échange des données :

- initialisation des variables TCP
  - synchronisation des numéros de séquence
  - création des tampons
  - initiation du controle de flot
- **client** : initiateur de la connexion
- **serveur** : en attente de la demande de connexion

## Fermeture de la connexion après l'échange des données :

- attente ou non de l'émission des données restantes
- libération des tampons

# TCP : three-way handshake (1)

Echange initial en 3 segments *(three-way handshake)*

- **1** client ➠ serveur : segment TCP avec le bit `SYN`
  - indique le numéro de séquence initial (ISN) choisi par le client
  - l'emission du `SYN` incrémentera le futur numéro de séquence
  - pas de données
- **2** serveur ➠ client : segment TCP avec les bits `SYN` + `ACK`
  - la réception du `SYN` à incrémenté le numéro de d'aquittement
  - indique le numéro de séquence initial (ISN) choisi par le serveur
  - l'emission du `SYN` incrémentera le futur numéro de séquence
  - allocation des tampons du serveur
- **3** client ➠ serveur : segment TCP avec le bit `ACK`
  - la réception du `SYN` à incrémenté le numéro de d'aquittement
  - peut contenir des données

# TCP : three-way handshake (2)

Echange initial en 3 segments

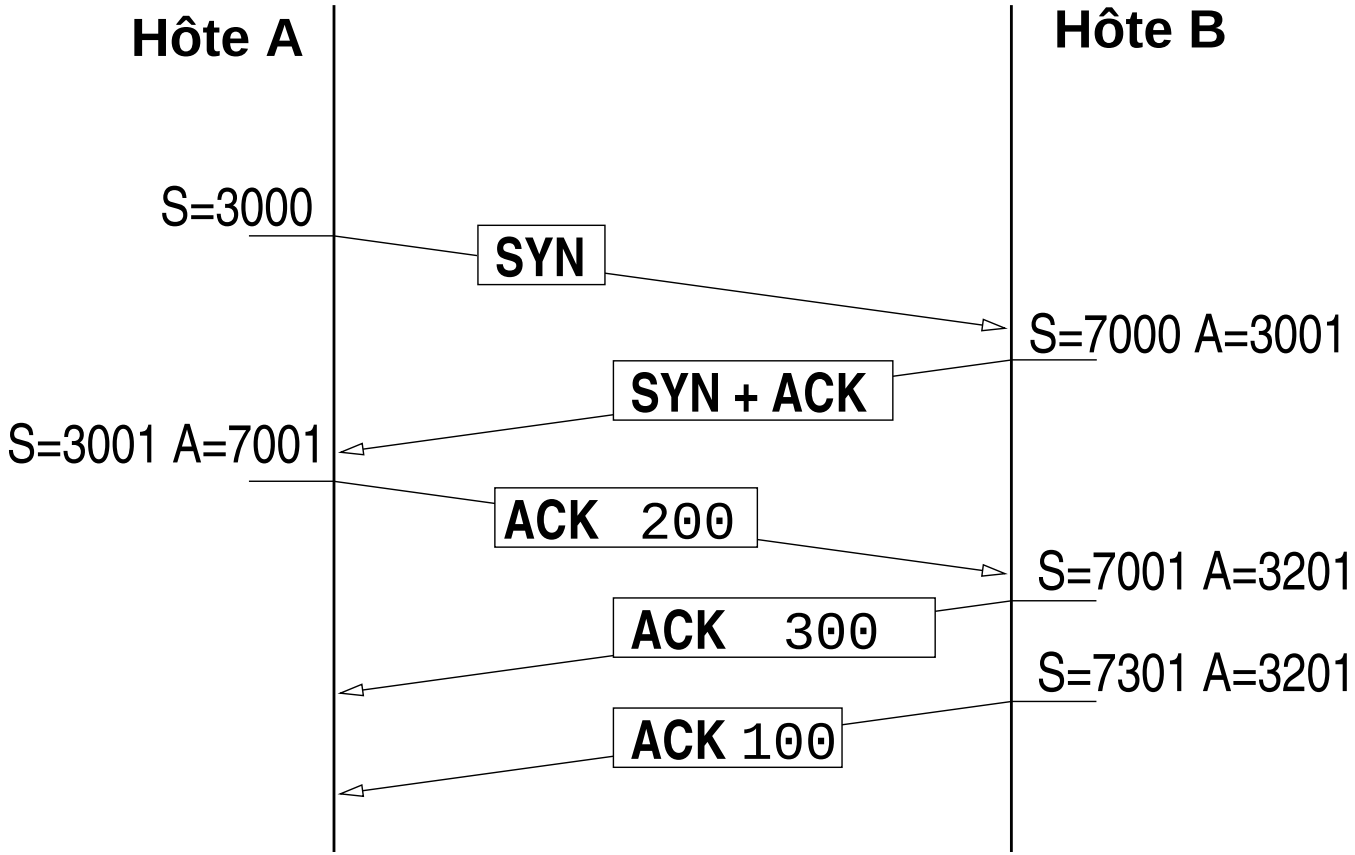

# TCP : three-way handshake (3)

## Gestion des ouvertures simultanées

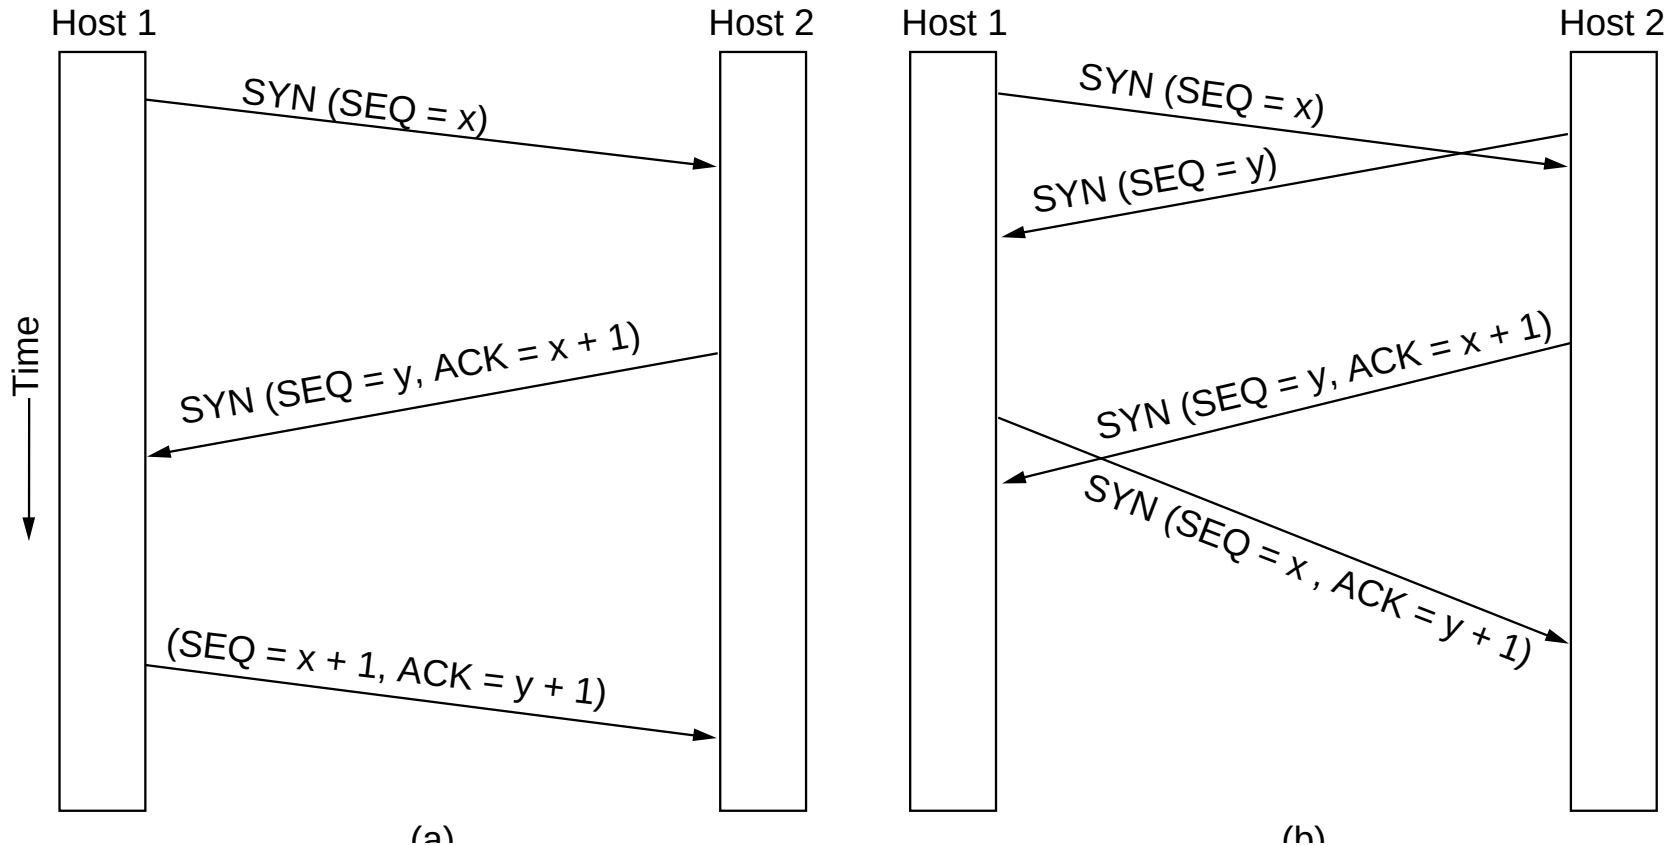

# TCP : graceful release (1)

- 1 le **client** émet un segment TCP avec `FIN`
  - l'émission du `FIN` incrémentera le futur numéro de séquence
  - peut contenir des données
- 2 le **serveur** recoit le segment avec `FIN`
  - la réception du `FIN` incrémente le numéro d'aquittement
  - émet un segment TCP avec `ACK`
  - termine la connexion **(envoie les données restantes)**
  - émet un segment TCP avec `FIN`
  - l'émission du `FIN` incrémentera le futur numéro de séquence
- 3 le **client** recoit le segment avec `FIN`
  - la réception du `FIN` incrémente le numéro d'aquittement
  - emet un segment TCP avec `ACK`
  - termine la connexion
    - déclanche une temporisation d'attente (`FIN` dupliquées)
- 4 le **serveur** recoit le segment avec `FIN`

# TCP : graceful release (2)

Déconnexion : terminaison courtoise

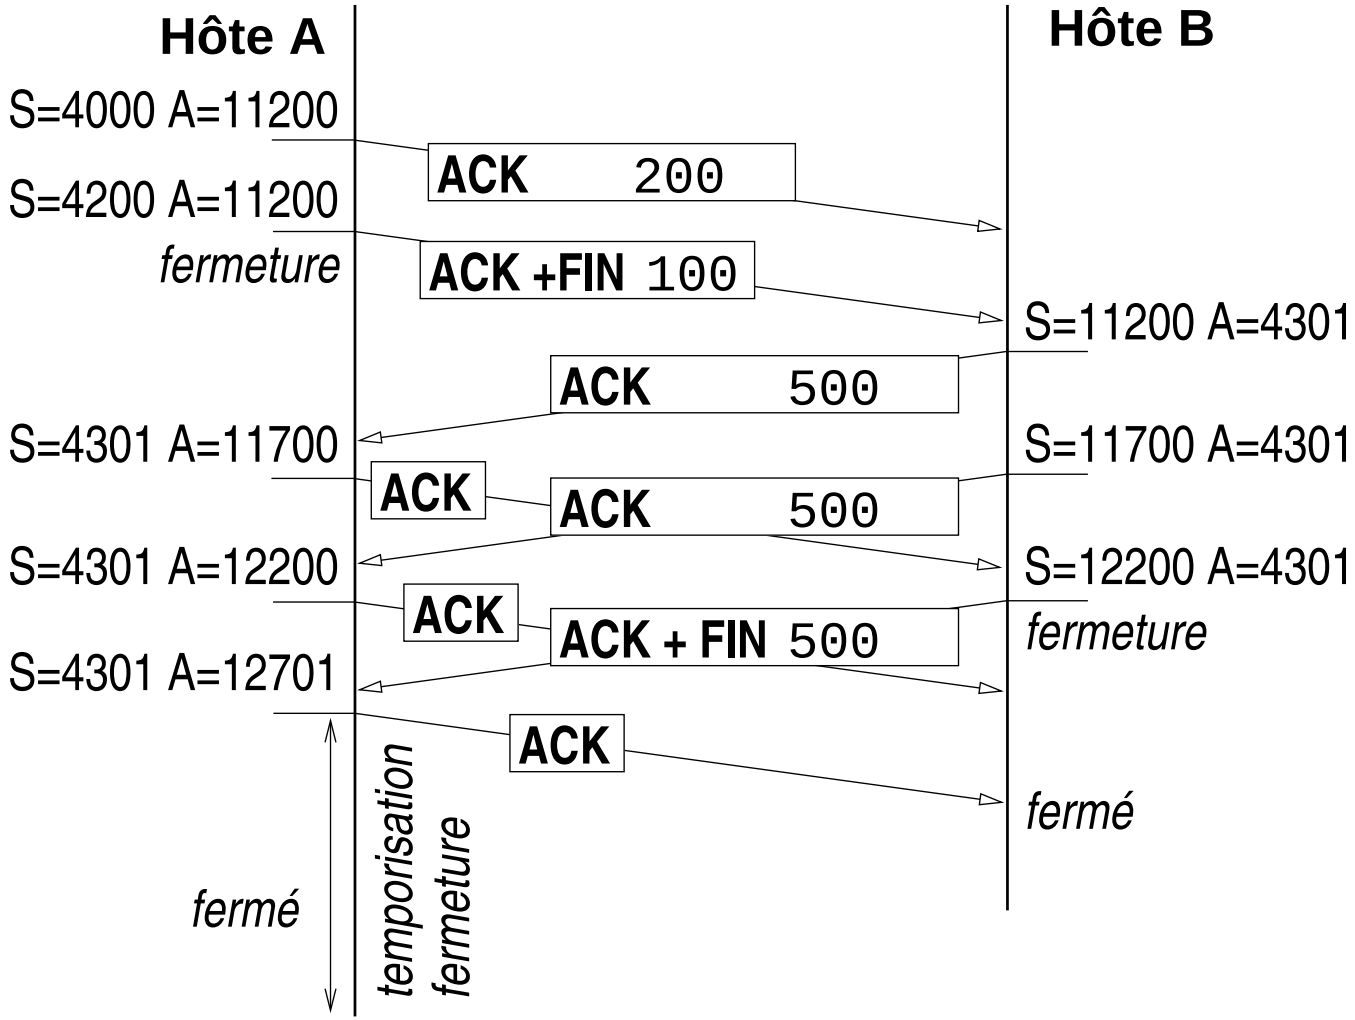

# TCP : shutdown

Déconnexion : terminaison unilatérale
(pour tout comportement anormal ou indésiré)

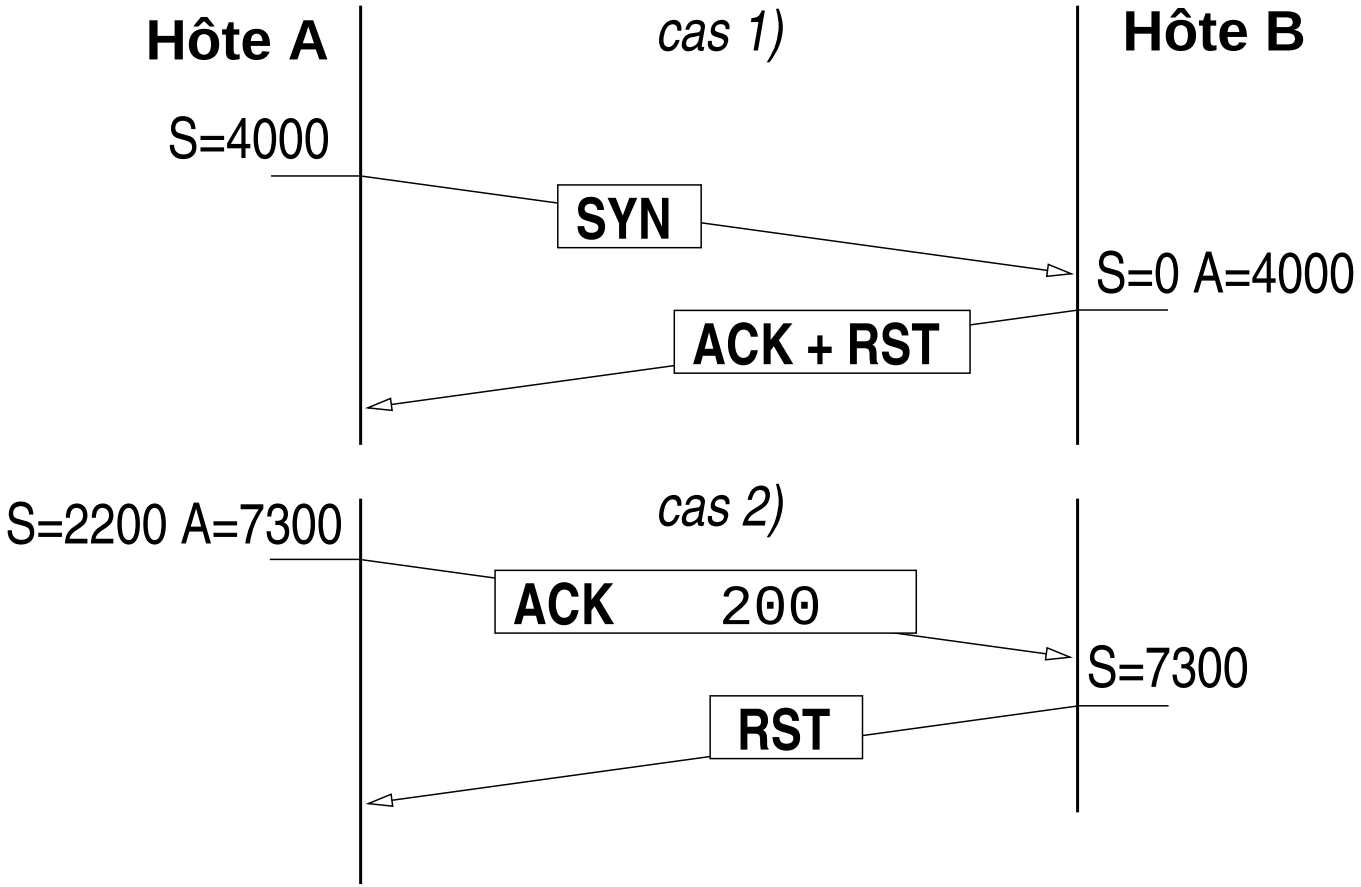

# TCP : Automate d'états finis

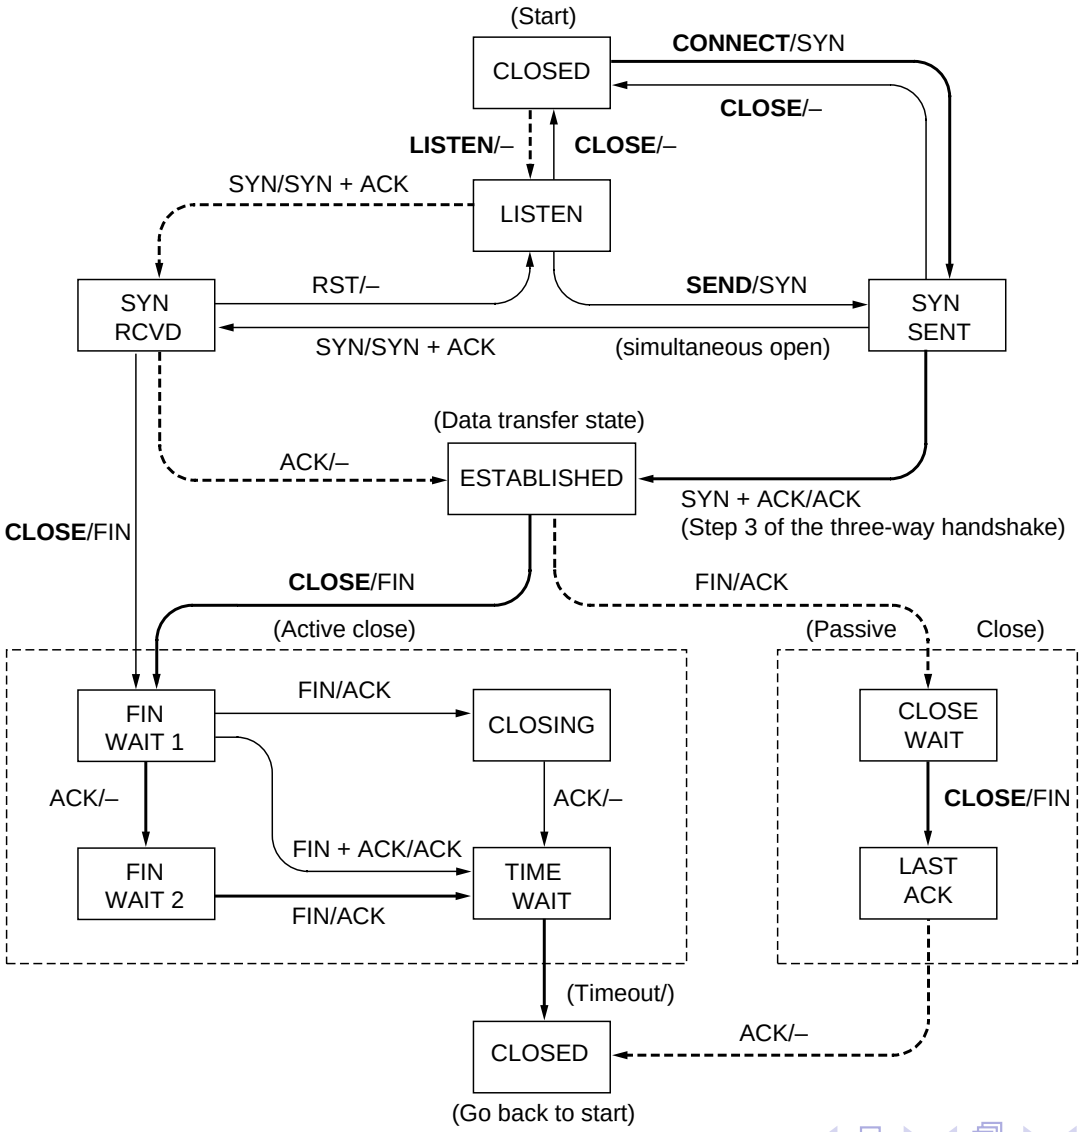

# ARES : plan du cours 3/5

# Transmission fiable de TCP

TCP est un protocole fiable de transfert sur le service IP non fiable

- mécanismes de base :
  - **pipeline**
  - ACK **cumulatifs**
  - temporisateur de retransmission **unique**
  - retransmissions déclanchées par :
    - expiration de temporisation *(timeout)*
    - duplication d'ACK
- dans la suite...
  - émetteur TCP simplifié :
    - pas d'ACK dupliqué
    - pas de contrôle de flux
    - pas de contrôle de congestion

# TCP : Calcul du RTT

RTT = Round Trip Time

- Estimation de la temporisation de retransmission :
  - supérieure au RTT... mais le RTT varie !
    - trop petit : retransmissions inutiles
    - trop grand : réaction lente aux pertes
- Estimation du RTT :
  - $RTT_{mesure} = \Delta$ (envoi segment, reception ACK correspondant)
  - $RTT_{mesure}$ peut varier rapidement ➠ lissage
    - $RTT = \alpha RTT_{mesure} + (1 - \alpha) RTT_{ancien}$
      avec $\alpha$ usuel $= 1/8$
  - moyenne glissante à décroissance exponentielle

# TCP : Exemple de calcul de RTT

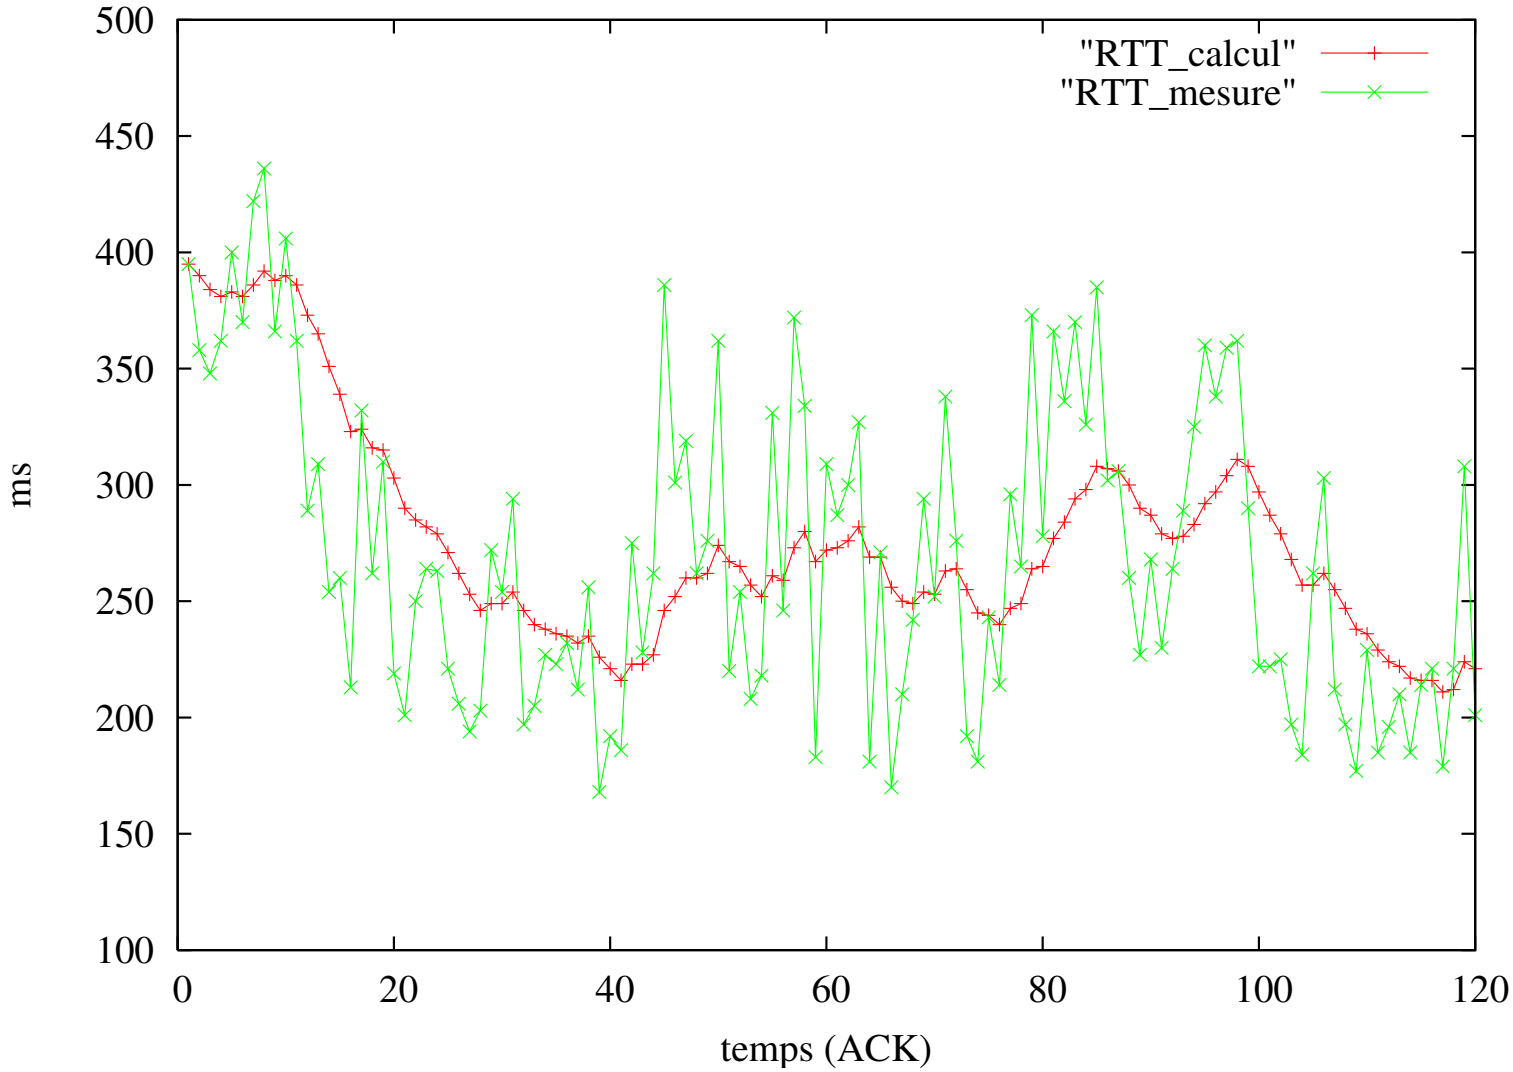

# TCP : Temporisations

Gestion de multiples temporisations (*timers*) :

- *retransmission timer* (détecte les pertes)
  - $RTO = RTT + \delta D$
    - avec $\delta = 4$ et une valeur initiale du $RTT$ élevée (3 secondes)
  - $D = \beta(|RTT_{mesure} - RTT_{ancien}|) + (1 - \beta)D_{ancien}$
    - calcul de l'écart moyen avec $\beta$ usuel $= 1/4$
  - **algorithme de Karn**
    - ne pas tenir compte des paquets retransmis et doubler le $RTO$ à chaque échec (*exponential backoff*)
- *persistence timer* (évite les blocages)
  - envoi d'un acquittement avec une fenêtre à 0
- *keep alive timer* (vérifie s'il y a toujours un destinataire)
- *closing timer* (terminaison)

# TCP : évènements à l'émetteur

- **data received from the layer above**
  - **creation** of a segment with `numSeq`
    - `numSeq` is the number, in the data stream, of the segment's first byte
  - start the **timer** if it is not already set
    - the timer is for the oldest non-acknowledged segment
- **timeout**
  - **retransmit** the segment associated with the timer
  - restart the **timer**
- **acknowledgement received** (ACK)
  - if it acknowledges as-yet anacknowledged segments :
    - update the base of the transmission window (`base_emis`)
    - restart the **timer** if waiting on other ACKs

# TCP : retransmission (1)

Scénario avec ACK perdu

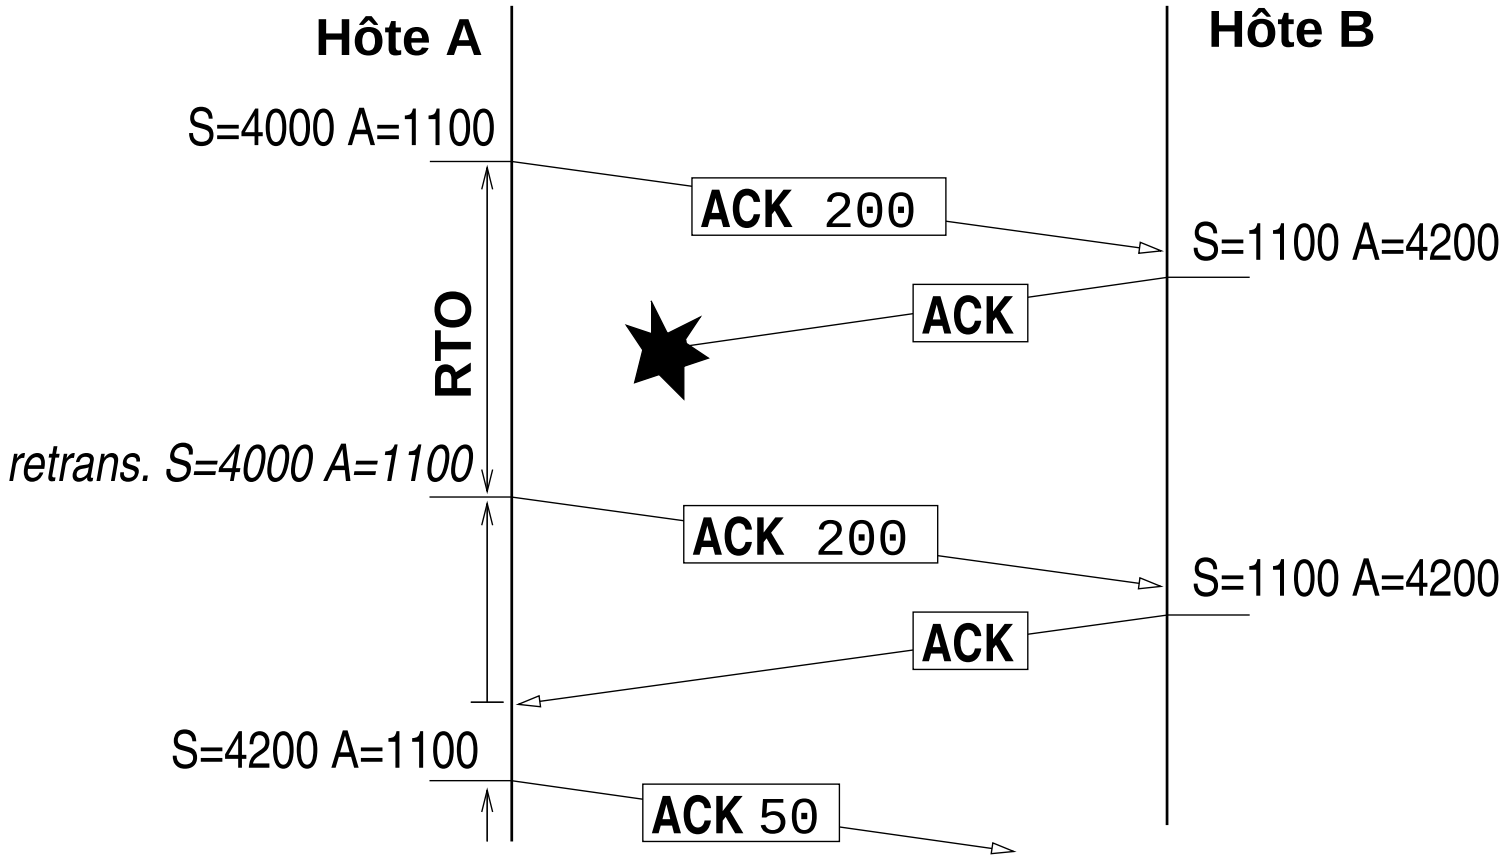

# TCP : retransmission (2)

Scénario avec temporisation sous-estimée

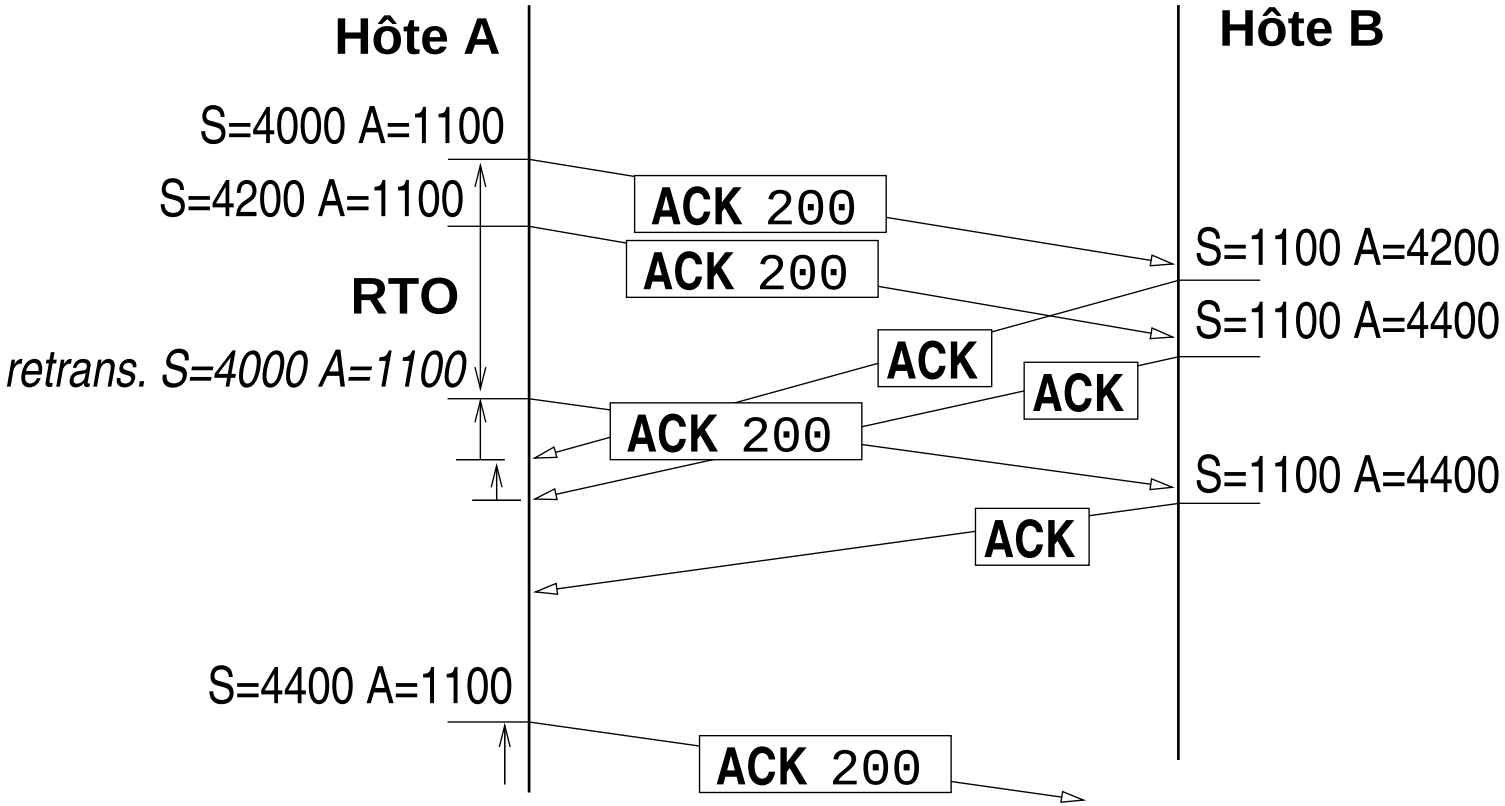

# TCP : retransmission (3)

Scénario avec ACK cumulatifs

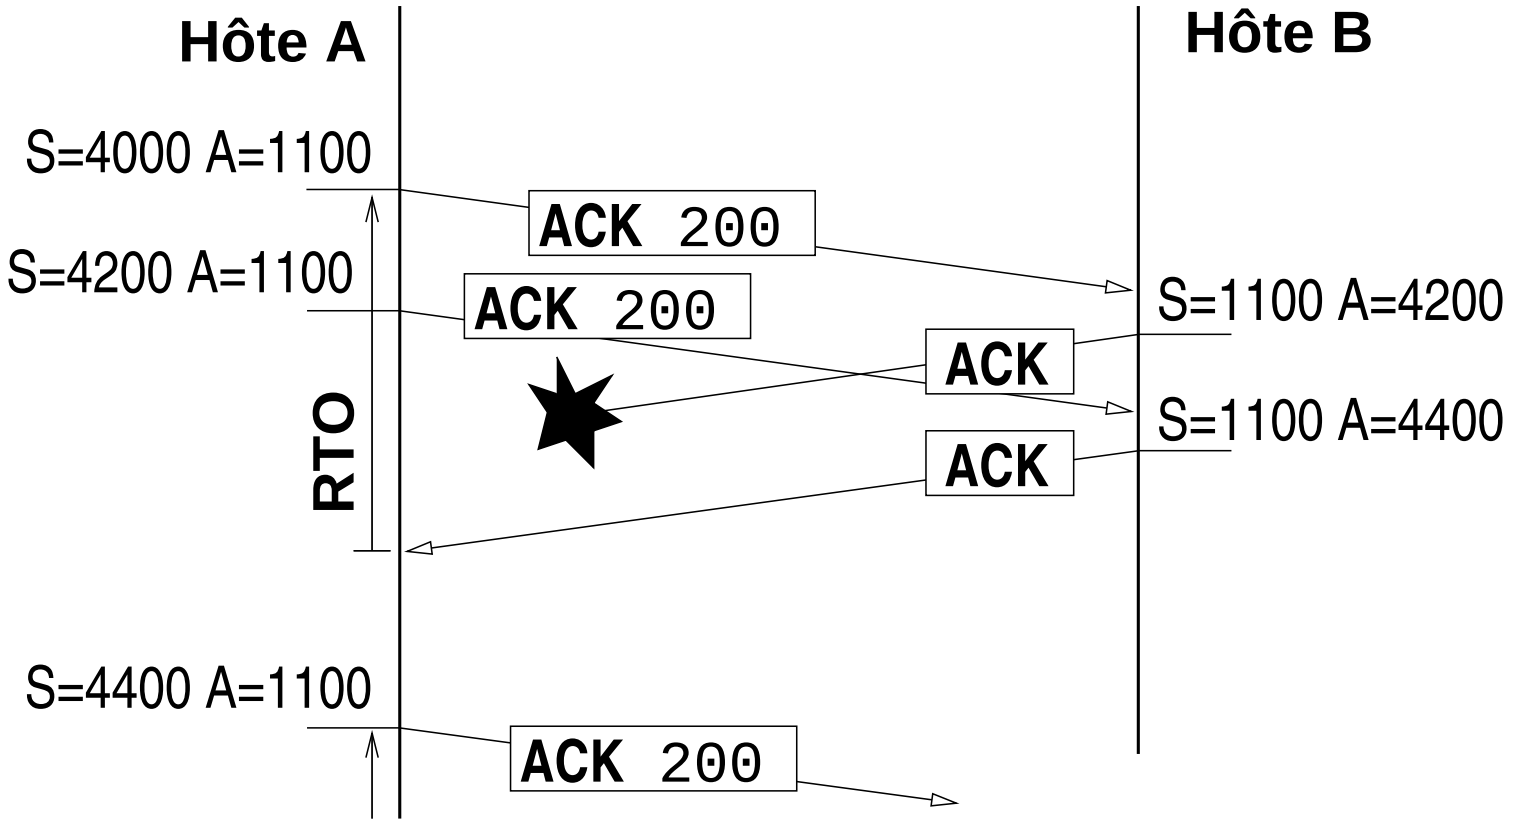

# TCP : évènement au récepteur

Génération d'**ACKs** (actions du récepteur)

- arrivée d'un segment **dans l'ordre** avec le `numSeq` attendu :
  - les segments précédents sont déjà acquittés
    - ACK **retardé** *(delayed ACK)*, attente jusqu'à 500 ms
    - si pas d'autre segments, envoi d'un ACK
  - un autre segment est en attente d'acquittement
    - envoi immédiat d'un ACK **cumulatif** pour ces deux segments dans l'ordre
- arrivée d'un segment **dans le désordre** :
  - `numSeq` supérieur à celui attendu (intervalle détecté)
    - envoi immédiat d'un ACK **dupliqué**
    - rappel du prochain `numSeq` attendu
  - rempli partiellement ou totalement un intervalle
    - envoi immédiat d'un ACK
    - nouveau `numSeq` attendu suite au remplissage de l'intervalle

# TCP : fast retransmit (1)

Optimisation du mécanisme de retransmission

- temporisation souvent relativement élevée
  - délai important avant une retransmission
- détection des segments perdus grâce aux ACKs **dupliqués**
  - ensemble de segments souvent envoyés cote-à-cote
  - si un segment est perdu ➠ nombreux ACKs dupliqués
- si l'émetteur reçoit 3 ACK dupliqués (4 ACKs identiques)
  - TCP suppose que le segment suivant celui acquitter est perdu
    - **fast retransmit** : retransmission du segment avant l'expiration de la temporisation

# TCP : fast retransmit (2)

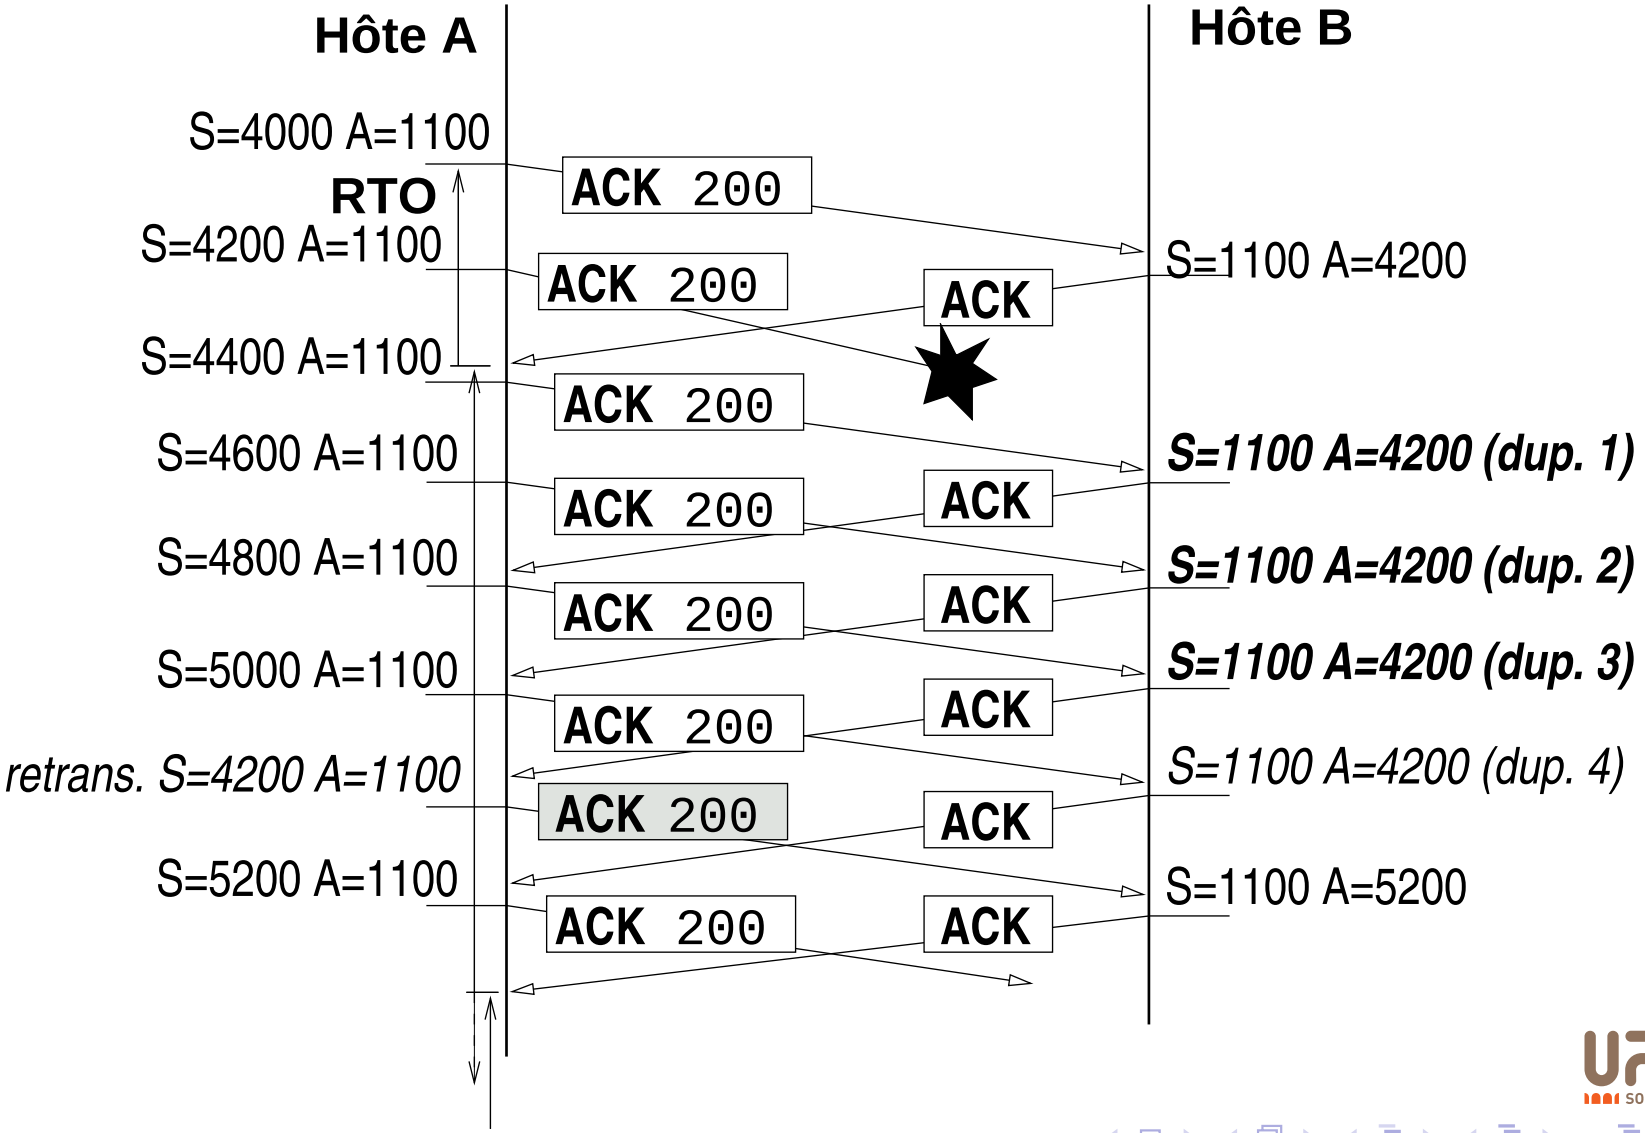

# TCP : asservissement au récepteur

- **contrôle de flux**
  - l'émetteur ne doit pas dépasser les capacités du récepteur
  - récupération de la taille de la place disponible du tampon de réception du récepteur :

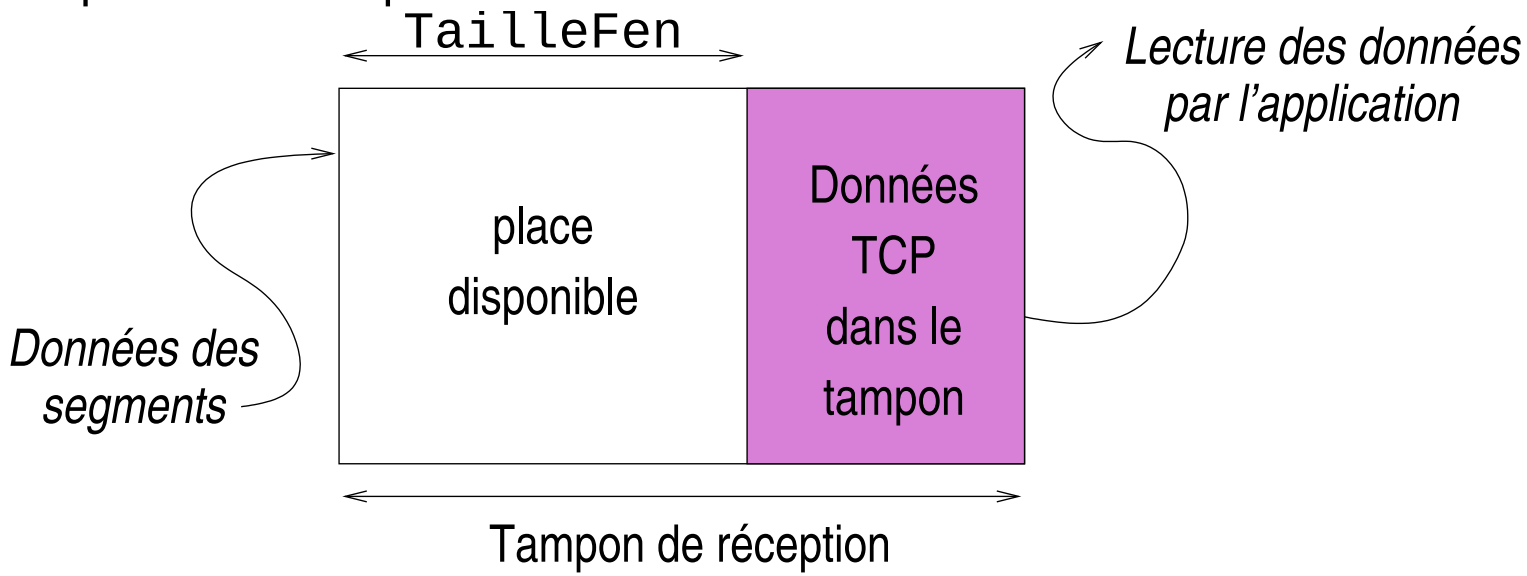


  - `TailleFen = TailleTampon - DernierOctetRecu + DernierOctetLu`

# TCP : Limitation de l'émetteur

*Sliding window* : l'emetteur limite la transmission de ses données non acquittées

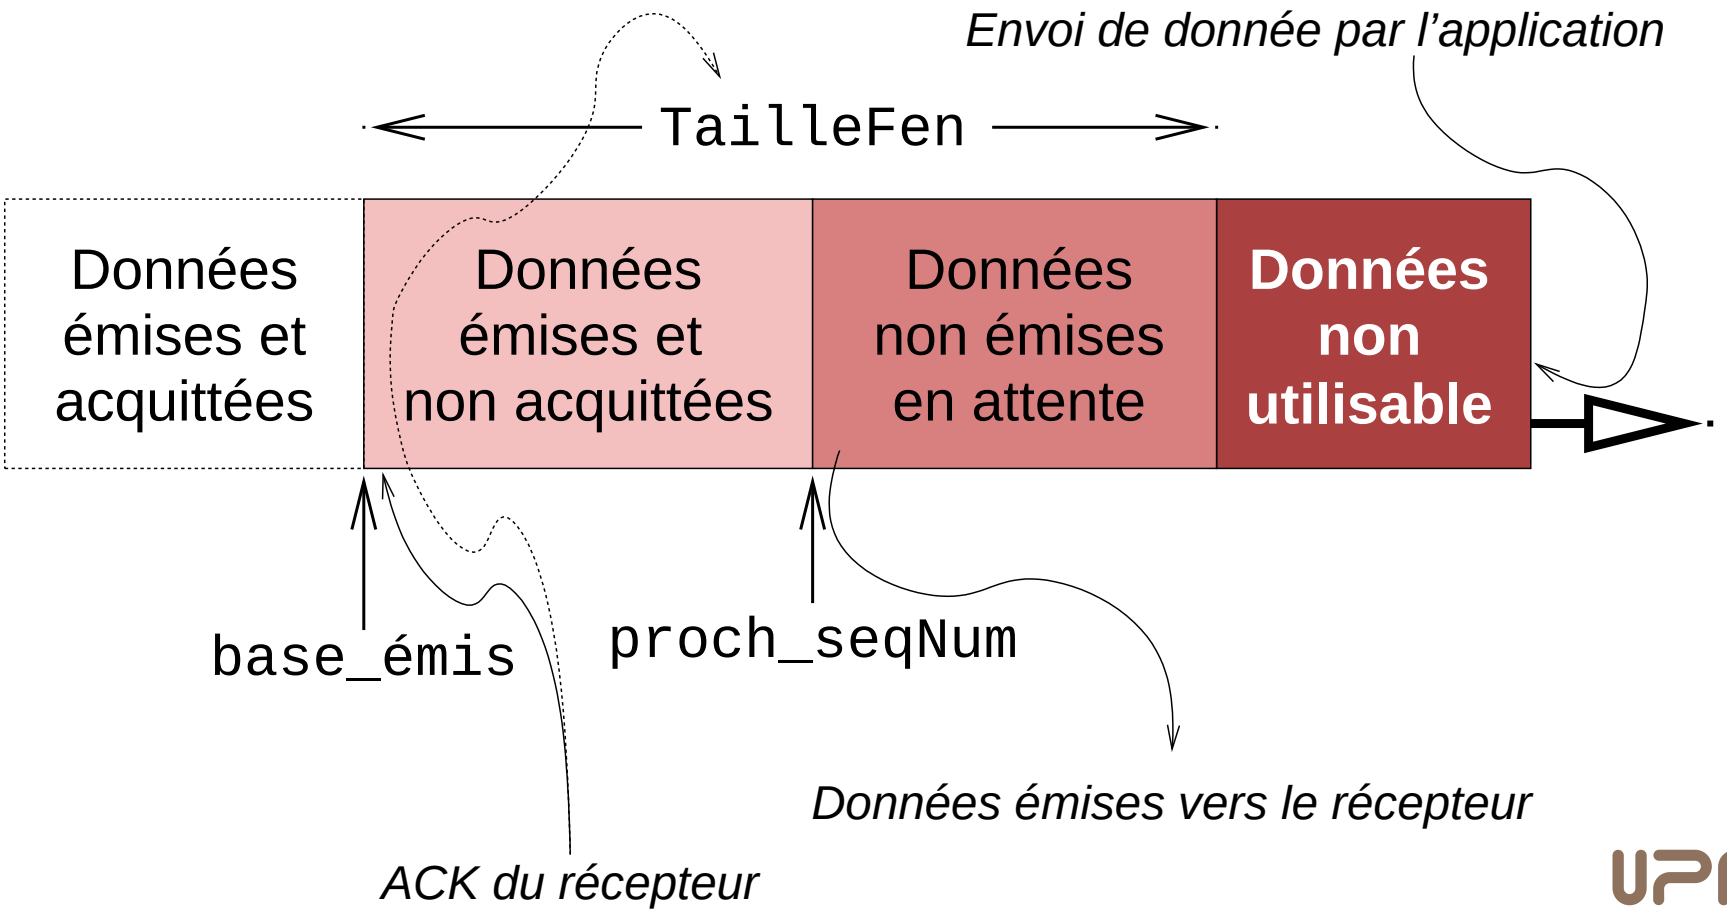

# TCP : Contrôle de flux

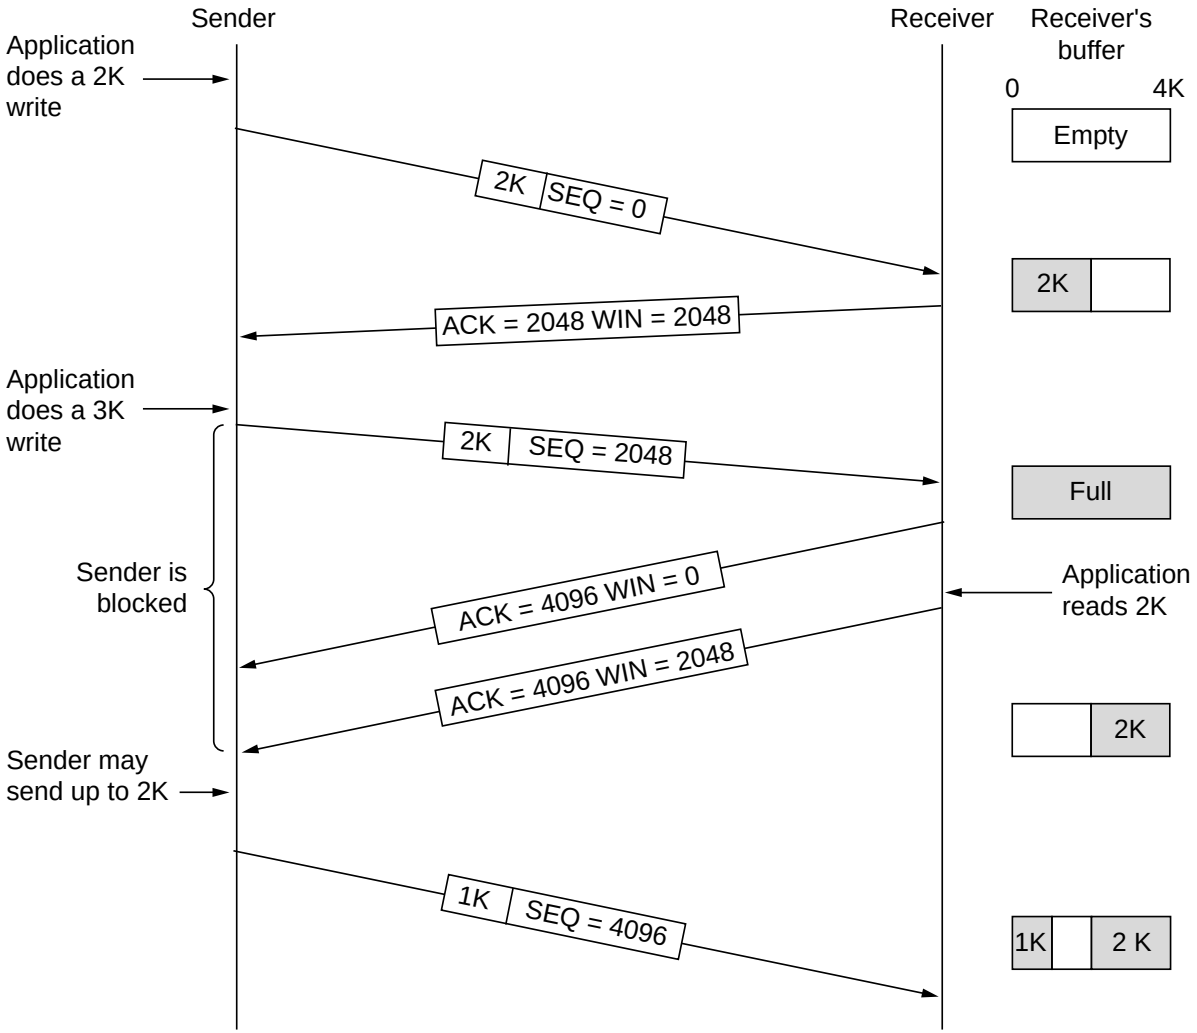


pictures from TANENBAUM A. S. *Computer Networks 3rd edition*

# TCP : temporisation de ré-ouverture de la fenêtre

*Persistence timer*

- évite que la taille de la fenêtre reste à 0
  - possible si perte du ACK annonçant une fenêtre non nulle
  - évité grâce à l'envoi d'un paquet sonde après une temporisation
    - tempo. initiée à RTT puis double à chaque expiration jusqu'à 60s (puis reste à 60s)
    - le paquet sonde est un segment avec 1 octet de données

# TCP : optimisation du contrôle de flux

*Send-side silly window syndrome*

- Algorithme de Nagle (RFC 896)
  - agrégation de petits paquets *(nagling)*
  - attente d'un acquittement ou d'un MSS avant d'envoyer un segment
    - TELNET : évite d'envoyer un paquet par caractère tapé
    - désactivable avec l'option TCP_NODELAY des sockets

*Receiver silly window syndrome*

- Algorithme de Clark
- limiter les annonces de fenêtre trop petites
  - fermeture de la fenêtre en attendant d'avoir suffisamment de place pour un segment complet

# TCP : exemples d'applications

Les applications suivantes reposent typiquement sur TCP :

- connexion à distance (TELNET, rlogin et ssh)
- transfert de fichiers (FTP, rcp, scp et sftp)
- protocole de routage externe (BGP)
- messageries instantanées (IRC, ICQ, AIM...)
- web (HTTP)
  - nouvelles applications utilisent HTTP comme service d'accès au réseau
    - permet de passer les *firewalls*

# TCP : utilisations particulieres

TCP doit s'adapter à des flots de qqs **bps** à plusieurs **Gbps** :

- LFN (*Long Fat Network*)
  - capacité du réseau = **bande passante * délai de propagation**
    - limitation de taille de la fenêtre (option `WSIZE`, jusqu'à un facteur $2^{14}$)
    - rebouclage des numéros de séquence (PAWS, *Protect Against Wrapped Sequence*, utilise l'option `TIMESTAMP`)
    - acquittements sélectifs pour éviter des retransmissions importantes inutiles (option `SACK`)
  - satellites
  - fibres transatlantiques
- réseaux asymétriques (ADSL, Cable)
  - sous-utilisation du lien rapide

# TCP : interface socket

```
#include <sys/types.h>
#include <sys/socket.h>

# create a descriptor and bind local IP and port
int socket(int domain, int type, int protocol);
#   domain : PF_INET for IPv4 Internet Protocols
#     type : SOCK_STREAM Provides sequenced, reliable, 2-way, connection-based byte streams.
#             An out-of-band data transmission mechanism may be supported.
# protocol : TCP (/etc/protocols)
int bind(int s, struct sockaddr *my_addr, socklen_t addrlen);

# Server : passive queuing mode and connection acceptance
int listen(int s, int backlog);
int accept(int s, struct sockaddr *addr, socklen_t *addrlen);

# Client : active connection
int  connect(int sockfd, const struct sockaddr *serv_addr, socklen_t addrlen);

# Send and receive data
int send(int s, const void *msg, size_t len, int flags);
int recv(int s, void *buf, size_t len, int flags);

# End : dealocate
int close(int s);
```

# ARES : plan du cours 3/5

# Contrôle de congestion

## Congestion

- trop de flots de données saturent un ou plusieurs éléments du réseau
- différent du contrôle de flux
  - TCP n'a pas accès à l'intérieur du réseau
- manifestation :
  - longs délais
    - attente dans les tampons des routeurs
  - pertes de paquets
    - saturation des tampons des routeurs

# Congestion : scénario 1a

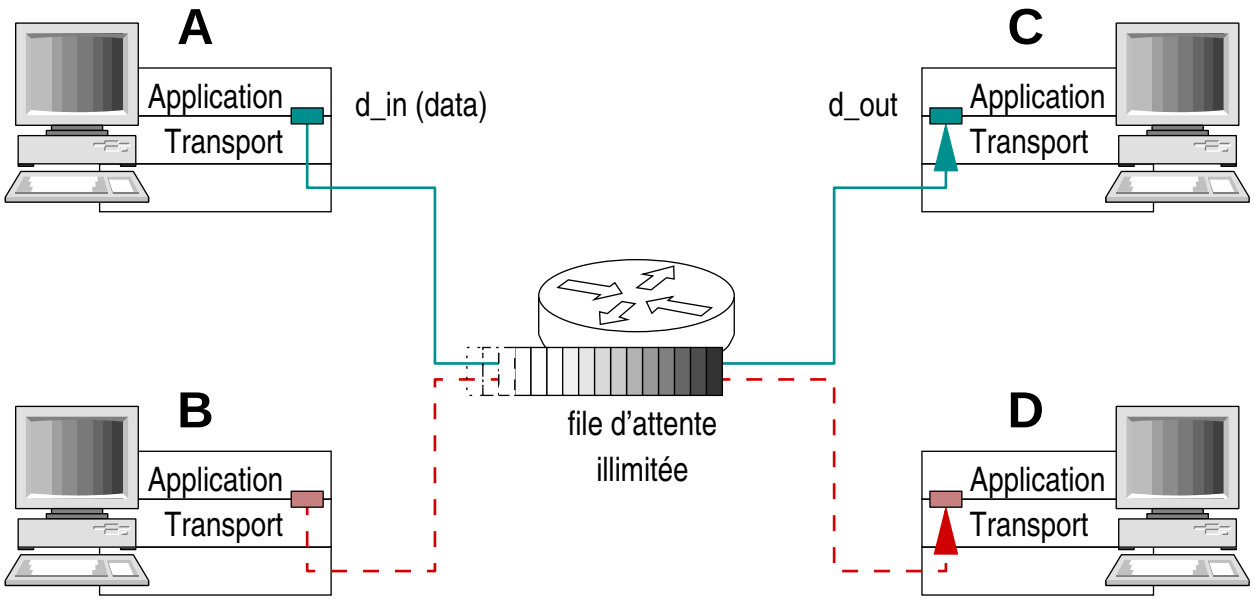


- 2 émetteurs, 2 récepteurs
- 1 routeur
  - tampons infinis
- pas de retransmission

➠ *Que ce passe-t-il quand d_in augmente ?*

# Congestion : scénario 1b

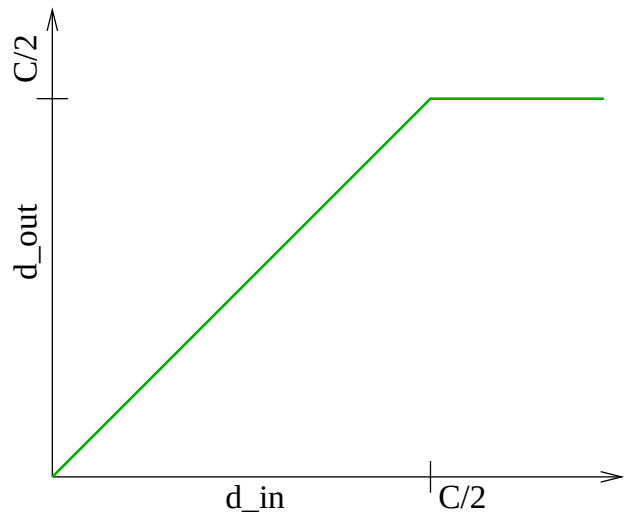


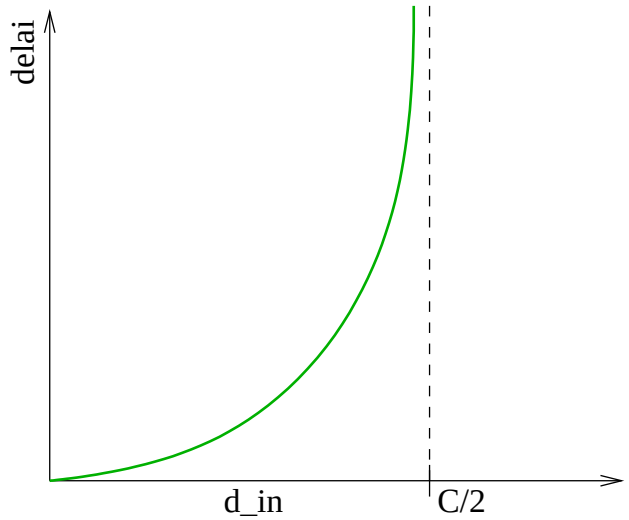


- **the cost of congestion :**
  - maximum possible bandwidth
    - d_in = C/2
  - high delay, close to the maximum
    - infinite buffer growth

# Congestion : scénario 2a

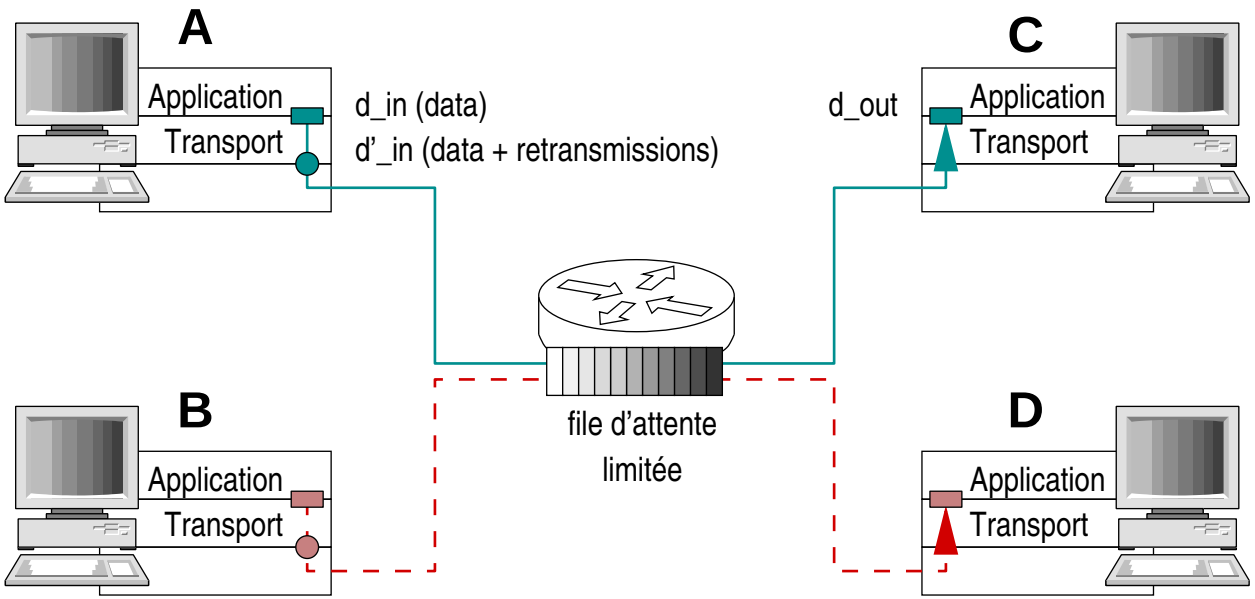


- 2 émetteurs, 2 récepteurs
- 1 routeur
  - **tampons finis**
- **retransmission** des segments perdus

➠ *Que ce passe-t-il quand d'_in augmente ?*

# Congestion : scénario 2b

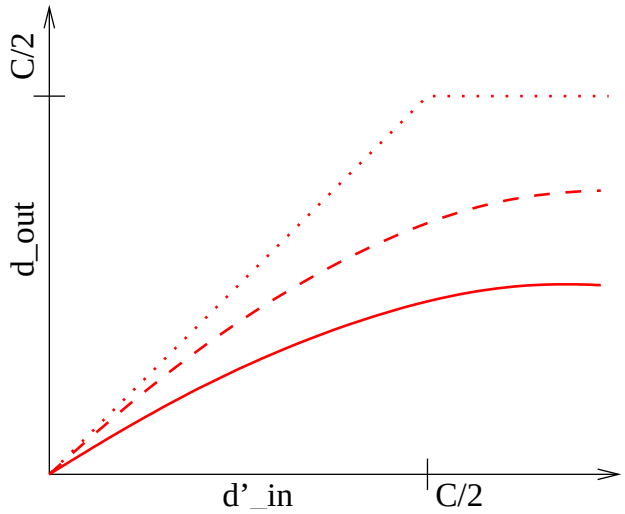


- toujours d_in = d_out *(goodput)*
- coût des retransmissions
  - **retransmissions utiles** : seulement pour des pertes
    - d'_in supérieur à d_out
  - **retransmissions inutiles** : segments en retard
    - d'_in encore plus supérieur à d_out
- **coût de la congestion** :
  - beaucoup plus de trafic pour un d_out donné
  - dupplications de segment inutile

# Congestion : scénario 3a

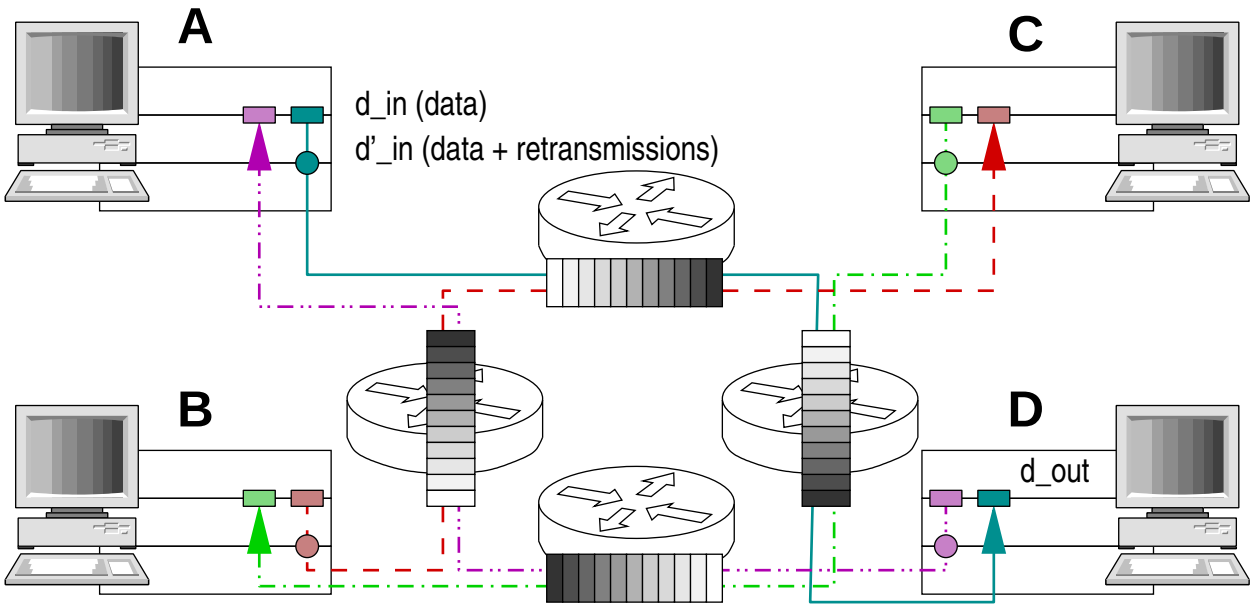


- 4 émetteurs, 4 récepteurs
- 4 routeurs
  - chemins multi-saut
  - tampons finis
- retransmission

➠ *Que ce passe-t-il quand d'_in augmente ?*

# Congestion : scénario 3b

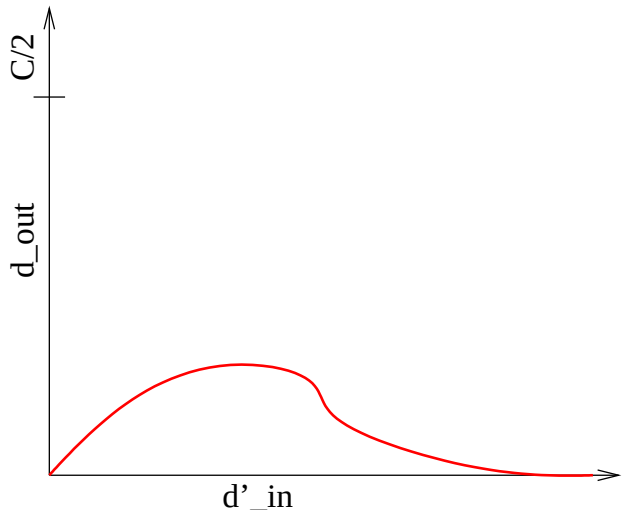


- **coût supplémentaire de la congestion** :
  - lors de la perte d'un paquet, toute la capacité amont est gachée

# Solutions pour le contrôle de congestion

Deux approches :

- contrôle de congestion géré par le **réseau**
  - les routeurs informent les extrémités
    - bit d'indication de la congestion (SNA, DECbit, ATM, TCP/IP ECN...)
    - indication explicte du débit disponible (ATM ABR, TCP/IP RSVP + IntServ...)
- contrôle de congestion aux **extrémités** *(end-to-end)*
  - aucune indication explicite du réseau
  - **inférence** à partir des observations faites aux extrémités
    - pertes
    - délais
  - **approche choisie dans TCP**

# ARES : plan du cours 3/5

# TCP : Algorithme AIMD

AIMD = *Additive Increase, Multiplicative Decrease*

- augmentation progressive du débit de transmission (`cwnd`) tant qu'il n'y a pas de perte
  - *Additive Increase*
    - augmenter `cwnd` de 1 MSS à chaque RTT tant qu'il n'y a pas de perte détectée
  - *Multiplicative Decrease*
    - diviser `cwnd` par 2 après une perte
  - comportement en dent de scie :

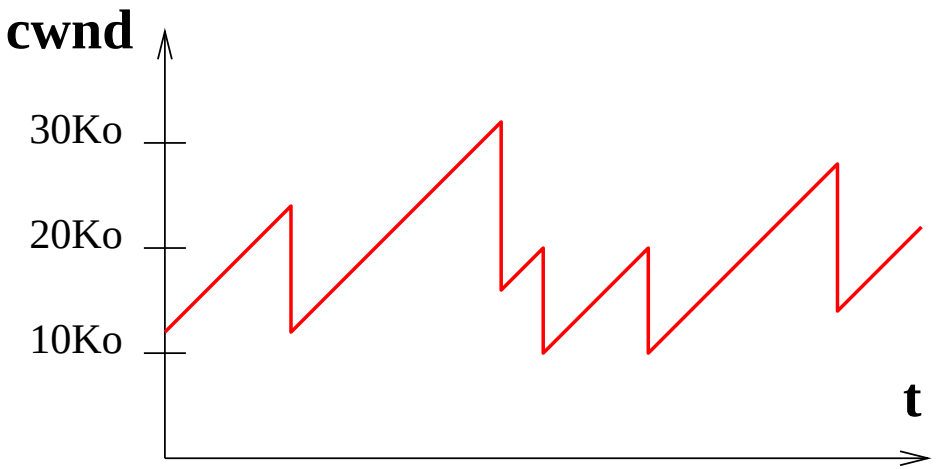

# TCP : contrôle de congestion

- basé sur la limitation de l'émission de l'émetteur
  - `dernierOctetEmis - dernierOctetAcq` $\leq$ `cwnd`
  - approximation du débit :
    - $d_{TCP} = \frac{\texttt{cwnd}}{RTT}$
- `cwnd` = fonction dynamique de la congestion perçue
  - perception de la congestion par le récepteur :
    - expiration de temporisation (RTO)
    - triple ACK dupliqués
  - 3 mécanismes :
    - AIMD
    - *Slow Start*
    - prudence après l'expiration d'une temporisation

# TCP : slow start

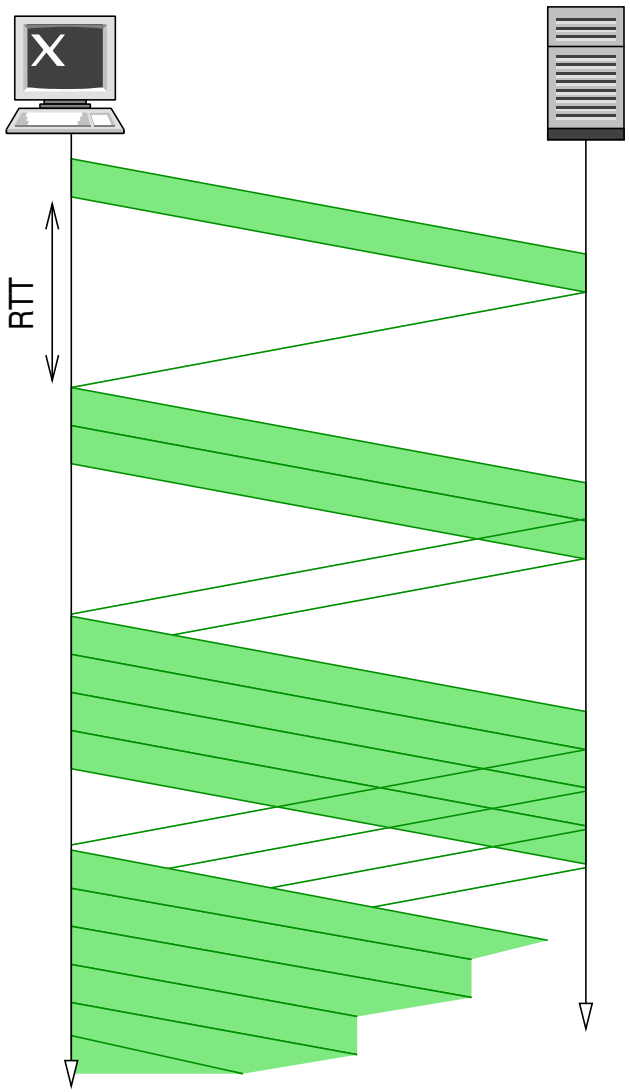


Démarre lentement *(slow start)*

➠ mais croit très vite ! !

- au démarrage de la connexion
  - `cwnd`= 2 à 4 MSS
- au redémarrage (après perte ou inactivité)
  - `cwnd` = 1 MSS ($d_{init} = \frac{MSS}{RTT}$)
- puis croissance exponentielle jusqu'à la première perte
  - `cwnd` double / RTT
  - implémenté par : `cwnd` ++ / ACK
  - $d_{potentiel} \gg \frac{MSS}{RTT}$

# TCP : optimisation

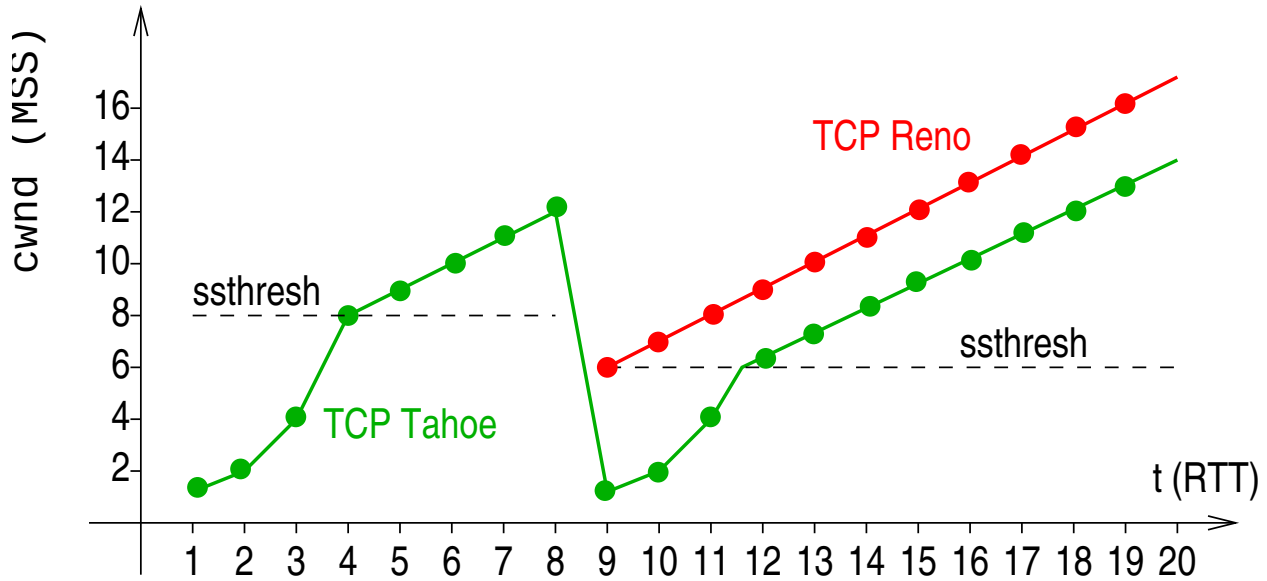


Passage de la croissance exponentielle à lineaire

- cwnd $\geq$ ancienne valeur de cwnd juste avant la perte
  - implémenté par une limite variable :
    ssthresh $=$ cwnd$_{\textit{avant la derniere perte}}/2$
  - plus précisément calculé avec les segments non acquittés :
    ssthresh $=$ qtt_données_non_acquit $/2$ (ou *flightsize*$/2$)

# TCP : inférence des pertes

Les ACK dupliqués sont moins graves que les expirations de temporisation

- suite **3 ACK dupliqués** :
  - indique que le réseau continue à transmettre des segments
    - `cwnd` divisé par 2
    - `cwnd` croit ensuite linéairement
- suite **expiration temporisation** :
  - indique que le réseau se bloque
    - `cwnd` = 1 MSS
    - *Slow Start* (croissance exponentielle)
    - à `ssthresh` = `cwnd`/2 (croissance linéaire)

# Contrôle de congestion TCP : synthèse

## RFC 5681

- when `cwnd` $<$ `ssthresh` :
  - sender in the *Slow Start* phase
  - `cwnd` grows exponentially
- when `cwnd` $\geqslant$ `ssthresh` :
  - sender is in the *Congestion Avoidance* phase
  - `cwnd` grows linearly
- when there are 3 duplicate ACKs :
  - `ssthresh` = last `cwnd` / 2
  - `cwnd` = `ssthresh`
- when there is a timeout :
  - `ssthresh` = last `cwnd` / 2
  - `cwnd` = 1 MSS

# TCP : équité entre flots ?

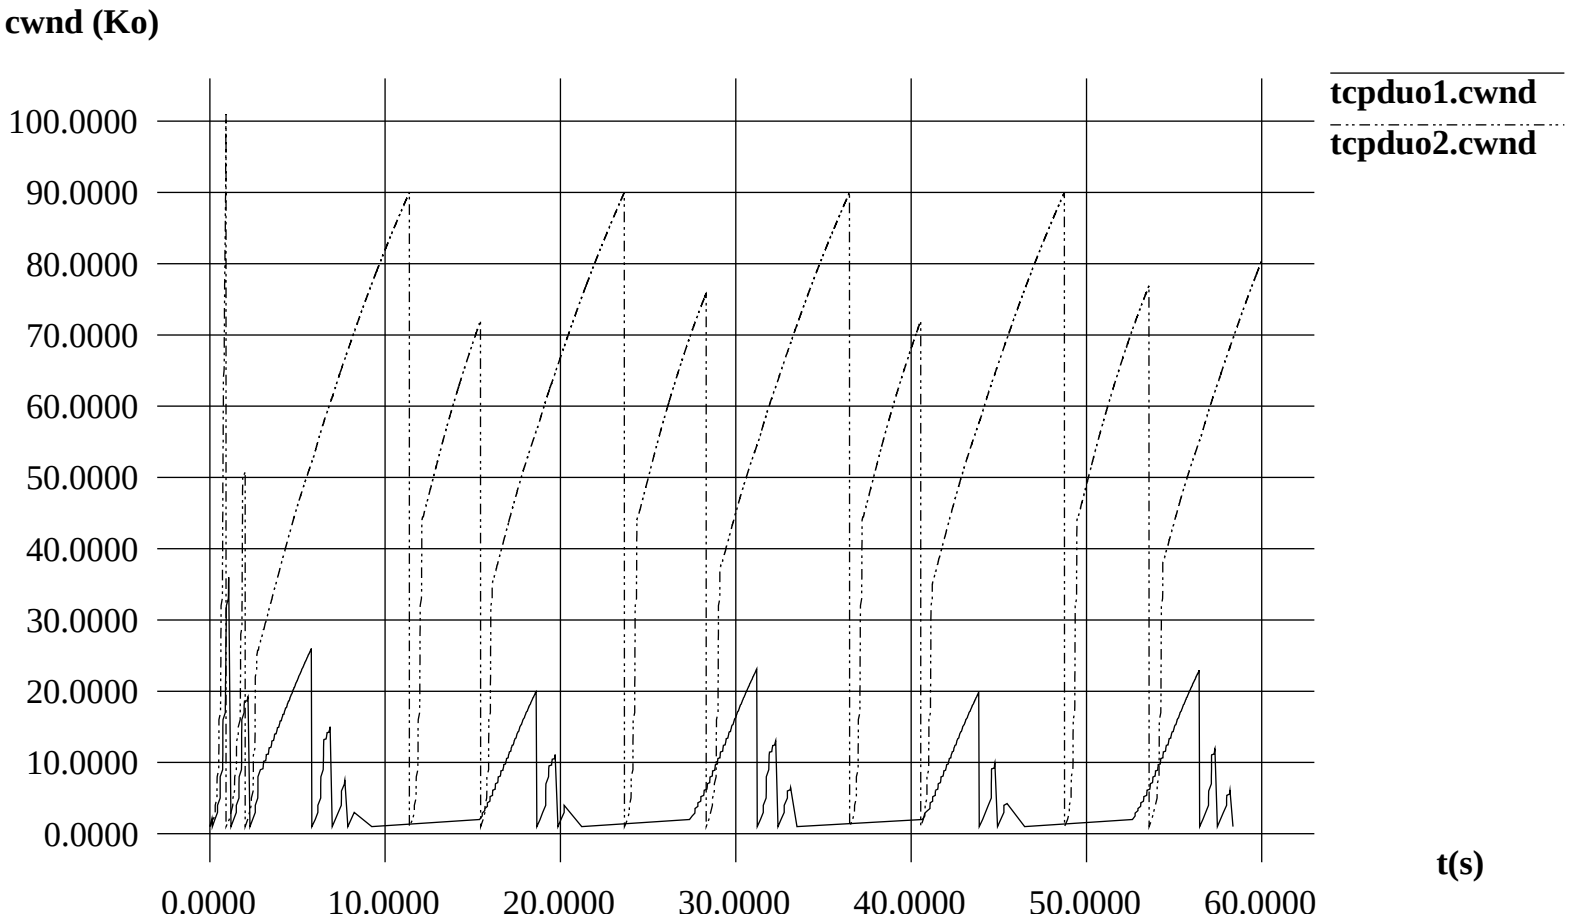


- oscillation de deux flots en phase de congestion

# Implémentations

*A trip to Nevada :*

- **TCP Tahoe** 1988
  - *slow start + congestion avoidance + multiplicative decrease*
  - **fast retransmit** (déclenche la retransmission d'un segment après 3 acquit. dupliqués, avant l'expiration de la tempo.)
  - décrit précédement... pb lorsque seulement 1 seg. est perdu
- **TCP Reno** 1990 (RFC 2582)
  - idem TCP Tahoe
  - **fast recovery** (pas de *slow start* après un *fast retransmit*)
- **TCP newReno** 1996 (RFC 3782)
  - idem TCP Reno
  - pas de *slow start* à la première congestion et ajustement de `cwnd`
  - SACK (RFC 2018)

# TCP : Tahoe

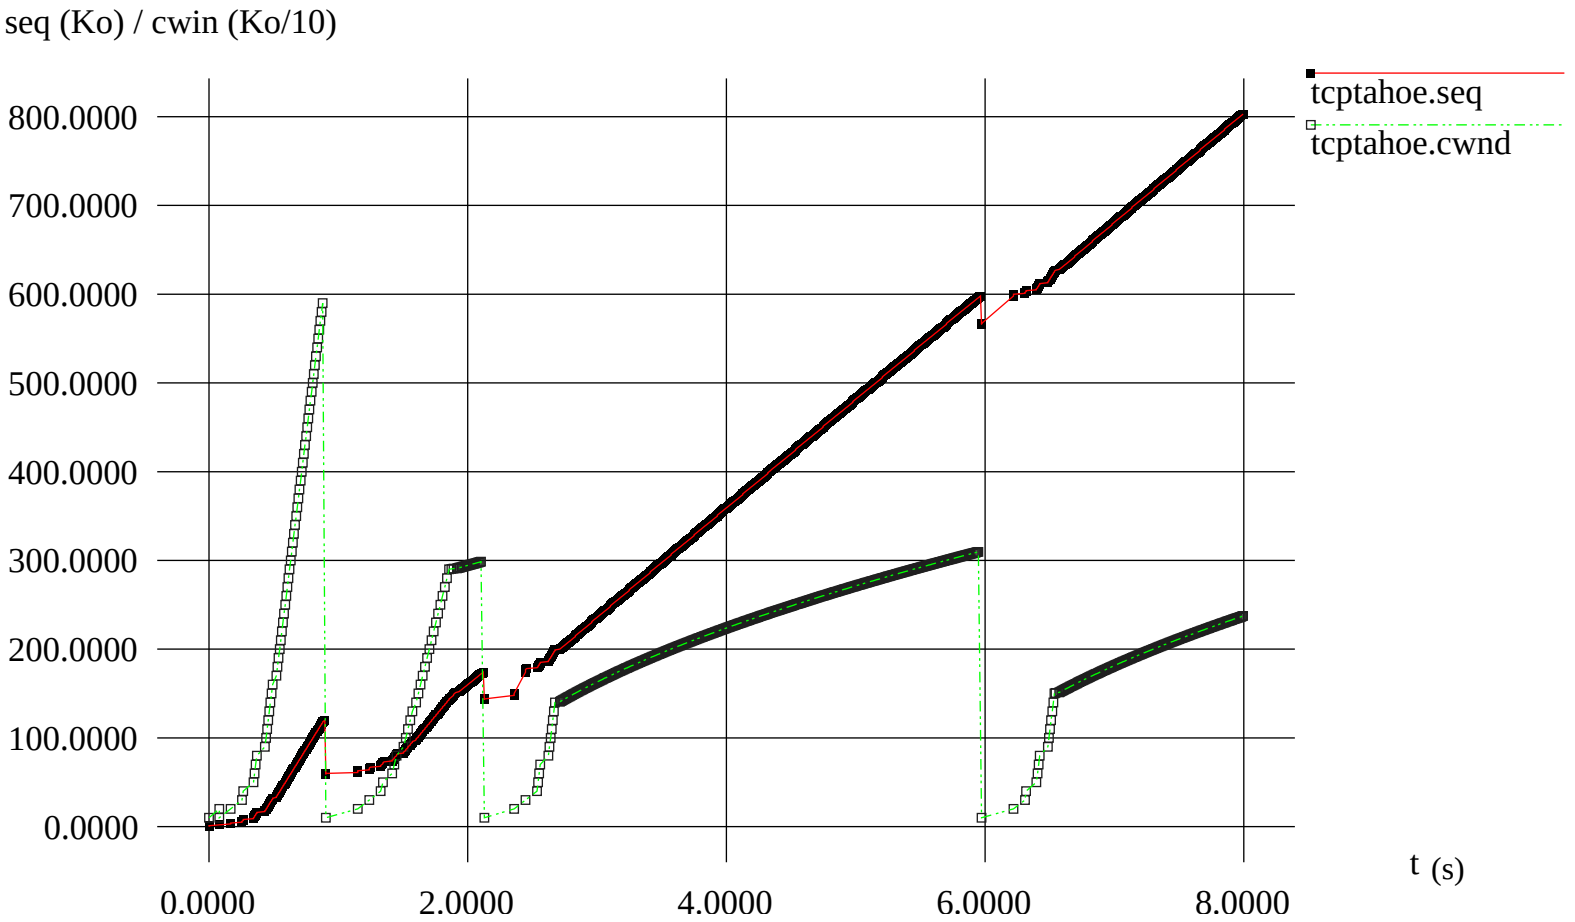


- slow start + congestion avoidance + multiplicative decrease + fast retransmit

# TCP : Reno

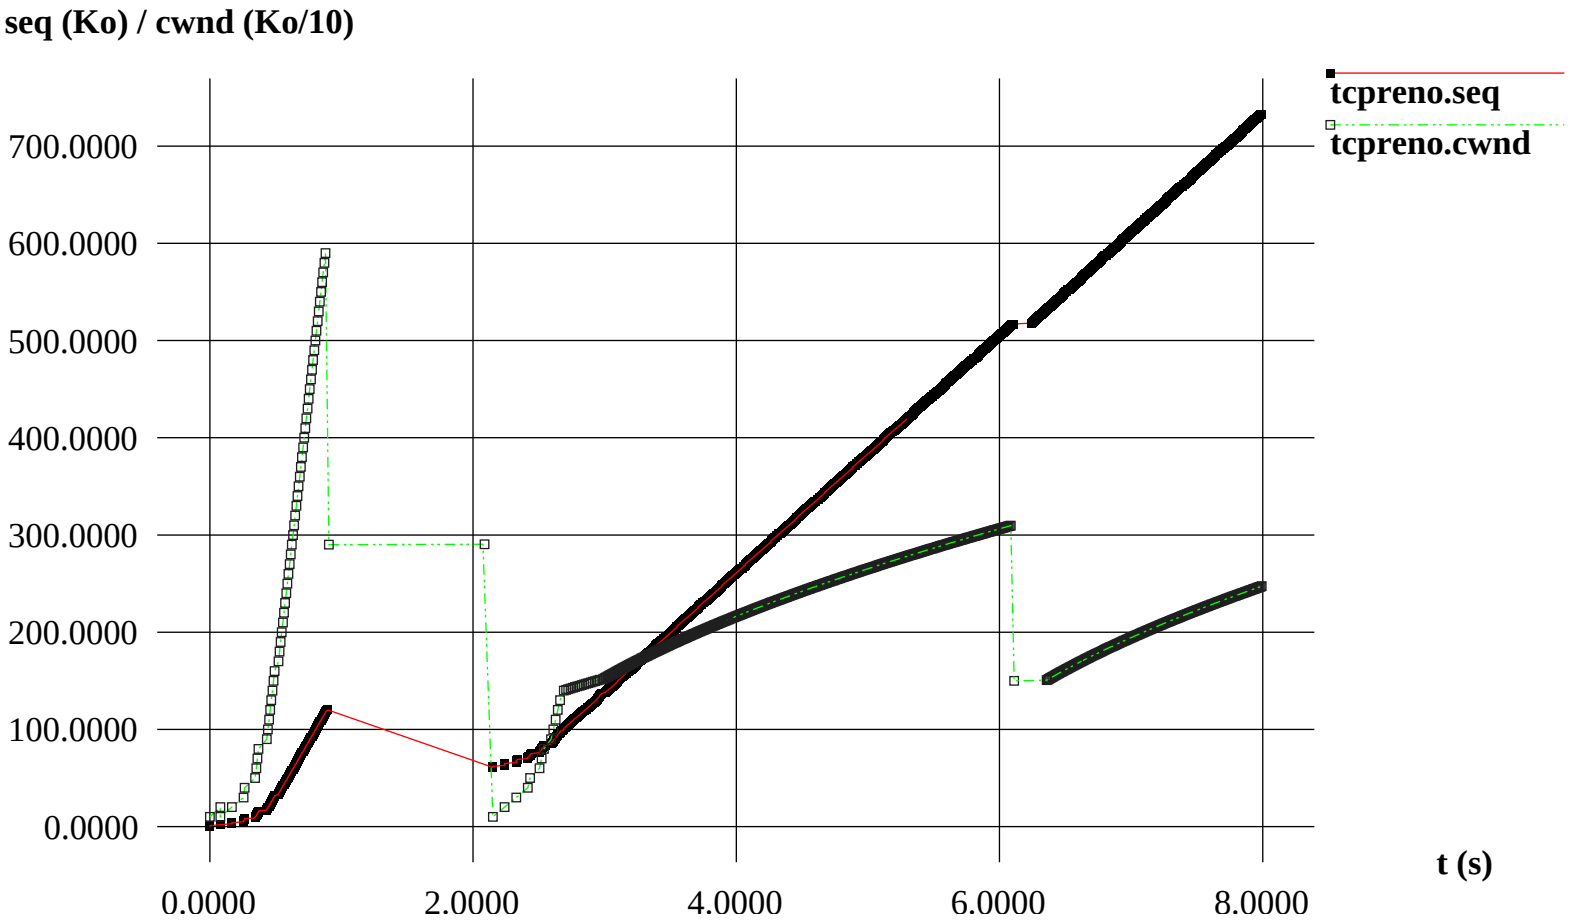


- TCP Tahoe + fast recovery

# TCP : newReno

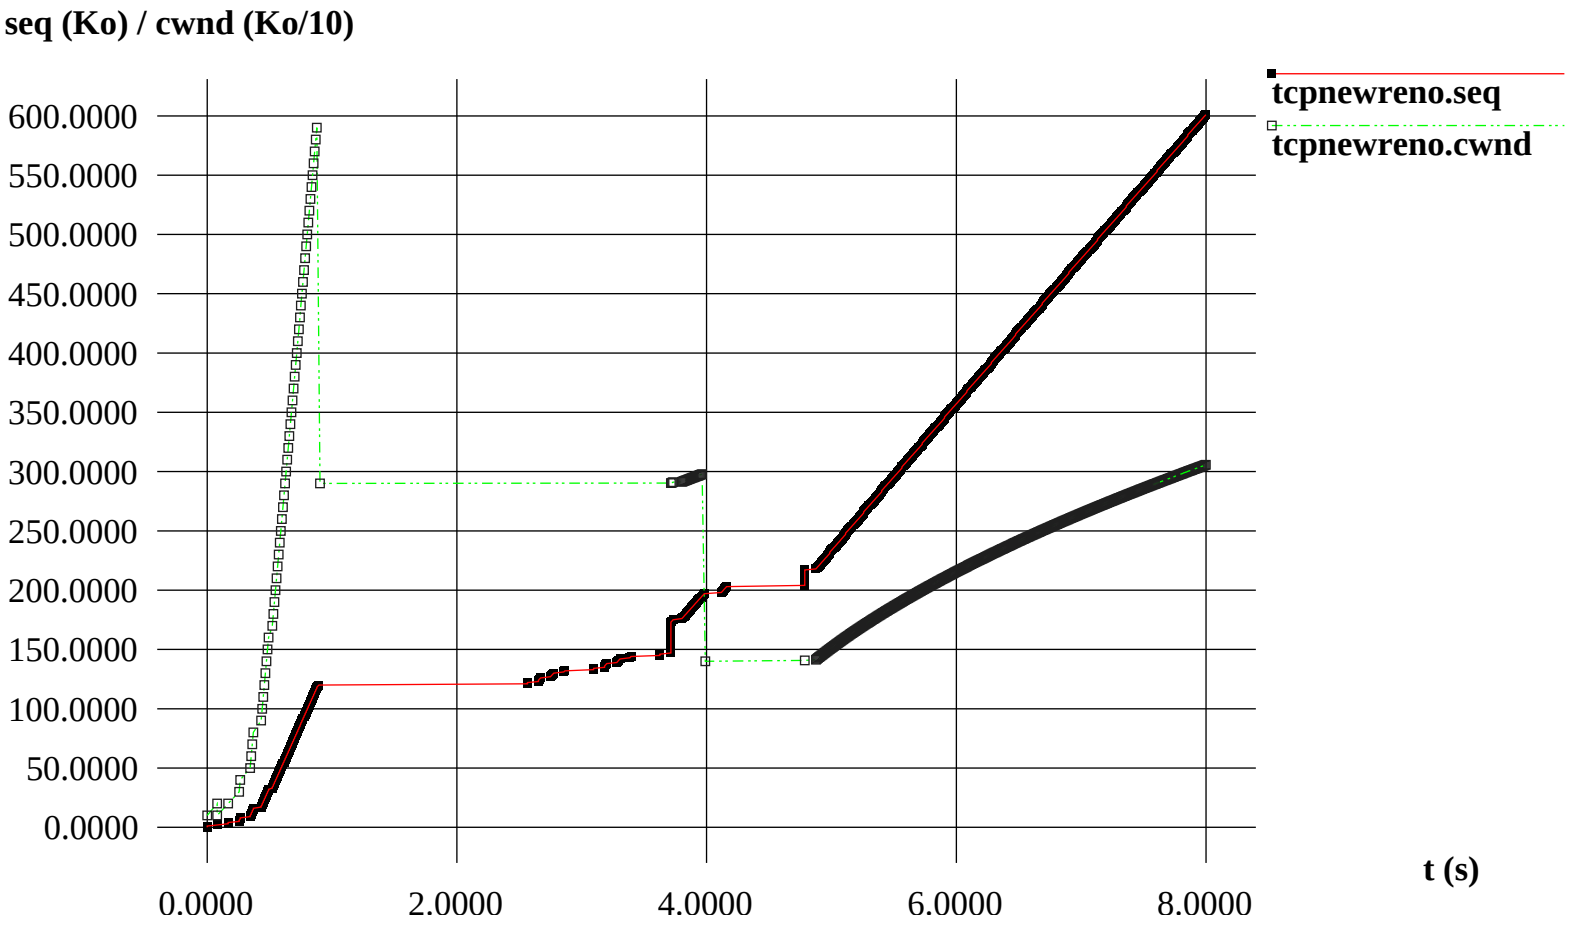


- TCP Reno - initial slow start